



ScienceDirect에서 목차를 확인할 수 있습니다.

알렉산드리아 공학 저널

저널 홈페이지: www.elsevier.com/locate/aej파킨슨병 진단을 위한 포괄적인 프레임워크
설명 가능한 인공지능 기반 머신러닝 기술S. 프리야다르시니 S.^a, K. 람쿠마르^b, Subramaniaswamy Vairavasundaram c,^{*}, K. 나라심한^c,
벤카테시^d, 렌가라잔 아미르타라잔^e, 찰살 코테차 d,^{*}^a SASTRA 사립대학교 전기전자공학과, 탄자부르, 인도^b SASTRA 사립대학교 컴퓨터공학과, 탄자부르, 인도^c 벨로르 공과대학교 컴퓨터공학과, 벨로르, 인도^d 삼비오시스 응용인공지능센터, 삼비오시스 공과대학, 삼비오시스 인터내셔널(인가 대학), 푸네, 인도

기사 정보

키워드:
파킨슨병
그래디언트 부스팅 알고리즘
자기공명영상 분석
설명 가능한 인공지능
조기 발견

추상적인

파킨슨병(PD)은 두 번째로 흔한 신경계 질환으로, 주로 노년층에게 영향을 미칩니다. 치료법이 없는 파킨슨병의 경우, 증상이 완전히 명확하지는 않지만 질병을 암시하는 초기 단계에서 발견하는 것이 중요합니다. 질병 발병 시점을 파악하는 것은 매우 중요합니다. 본 연구는 이를 예측할 수 있는 AI 기반 진단 방법을 설계 및 개발하는 것을 목표로 합니다. 파킨슨병의 초기 징후를 높은 정확도로 감지하여 보다 효과적인 질병 관리를 가능하게 합니다. 본 연구는 파킨슨병을 조기에 진단할 뿐만 아니라 임상에게 유용한 정보를 제공하는 방법을 개발하는 데 중점을 두고 있습니다. 인공지능 모델이 내린 결정을 해석하여 오진을 방지하는 도구를 사용합니다. 본 연구에서는 T2 강조 영상을 사용했습니다. 3D 자기공명영상(MRI) 데이터셋은 상세한 형태학적, 질감적, 구조적 분석을 위해 사용됩니다. 변화가 발생합니다. MRI 스캔은 뇌 추출, 영상 정합, 편향 보정, 정규화 및 분할 과정을 거쳐 전처리됩니다. 분할 후, 분할된 영역에 특징 추출이 적용됩니다. 방사선영상학 도구를 사용하여 피질하 영역을 분석한 결과 107개의 특징이 추출되었습니다. 상위 20개 특징은 다음과 같습니다. 피어슨 상관계수, 재귀적 특징 제거, 순위 모델을 통해 선택되었으며, 이는 다음과 같은 역할을 합니다. 머신러닝 모델의 클래스 예측을 위해 이러한 특징들을 분석했습니다. 또한 통계적 검증을 위해 통계 분석을 사용했습니다. 식별된 20개 특징이 타당하지 확인하기 위해 분산 분석(ANOVA), 쌍별 t-검정 및 Kruskal-Wallis H-검정을 수행했습니다. 예측에 있어 가장 중요한 요소로 식별된 특징들을 기반으로 여러 머신러닝(ML) 모델을 사용했습니다. 제공된 실제 MRI 스캔에 가장 적합한 분류기를 식별하기 위해 그래디언트 부스팅(GB) 알고리즘을 사용했습니다. 비교 대상 모델들 중에서 더 나은 예측 정확도를 달성했습니다. 데이터 불균형 문제를 해결하기 위해 SMOTE(합성 소수 집단 과표본 추출 기법)를 적용한 결과, 모델 성능이 크게 향상되었습니다. 정확도를 87%에서 96.8%로 향상시켰습니다. 또한, 여러 가지 설명 가능한 인공지능(XAI) 기법을 활용했습니다. 모델의 투명성과 해석 가능성을 높이기 위해 이러한 기법들이 도입되었습니다. 이 기법들은 다음과 같은 통찰력을 제공합니다. 식별된 각 특징이 분류기의 예측에 어떤 영향을 미치는지 분석하여 임상가가 진단 및 치료 계획을 세울 때 신뢰할 수 있는 결정을 내릴 수 있도록 지원합니다.

1. 서론

파킨슨병은 퇴행성 변화로 인해 운동 시스템과 운동 협응력이 저하되는 만성 운동 장애입니다.

뇌의 도파민 생성 뉴런에 영향을 미칩니다. 이는 운동 기능 장애와 같은 다양한 증상으로 나타납니다. 떨림, 경직, 운동 불안과 같은 비운동성 증상도 나타날 수 있습니다. 우울증, 불안, 수면 장애를 포함한 심리적 장애 문제점 및 인지 기능 저하 [1–3]. 이전 연구에서는 다음과 같은 점을 지적했습니다.

흑질(SN)의 철분 수치 감소는 특정 질환, 특히 PD의 조기 진단을 위한 잠재적 바이오마커로 사용될 수 있습니다 [4, 5]. 전통적으로 파킨슨병은 증상 관찰을 통해 진단되었는데, 이 방법은 환자 내 질병 확산 양상을 파악하는 데 도움이 됩니다. 파킨슨병 진단은 유효하며, 환자가 진단을 받은 후에만 확인할 수 있습니다. 파킨슨병의 영향을 받습니다. 파킨슨병에는 영구적인 치료법이 없기 때문에, 파킨슨병의 진행을 조기에 발견해야 합니다. 지난 20년 동안 다음과 같은 최신 영상 기술이 발전해 왔습니다.

^{*}교신 저자.

이메일 주소: priyadharshini@eie.sastra.ac.in (S. Priyadharshini), ramkumar@eie.sastra.edu (K. Ramkumar), subramaniaswamy.v@vit.ac.in (S. Vairavasundaram), knr@ece.sastra.edu (K. 나라심한), esvee@eie.sastra.edu (S. Venkatesh), amir@ece.sastra.edu (R. Amirtharajan), Director@sitpune.edu ~에 (K. 코테차).

<https://doi.org/10.1016/j.aej.2024.07.106>

접수일: 2024년 2월 28일; 수정 접수일: 2024년 7월 3일; 승인일: 2024년 7월 24일

2024년 7월 30일 온라인에서 이용 가능

1110-0168/© 2024 저작권자. 알렉산드리아 대학교 공과 대학을 대신하여 Elsevier BV에서 출판. 본 논문은 CC 라이선스에 따라 공개 액세스되는 논문입니다.

BY-NC-ND 라이선스 (<http://creativecommons.org/licenses/by-nc-nd/4.0/>).

MRI, 양전자 방출 단층 촬영(PET) 및 단일 광자 방출 컴퓨터 단층 촬영(SPECT)은 도파민 활동 평가를 향상시켰으며 PD를 초기 단계에서 식별하는 데 사용됩니다 [6,7].

모든 검사 중에서 MRI는 비침습적이고 고휘상도이며 방사선 노출이 없어 파킨슨병(PD)을 확인하고 모니터링하는 데 매우 중요하며, 질병 진행을 보다 안전하고 정확하게 파악할 수 있도록 합니다. T2 강조 MRI 영상은 자기 감수성 효과에 대한 민감도와 우수한 연조직 대비 덕분에 뇌 구조 변화 및 철 축적과 같은 PD 지표를 식별하는 데 필수적입니다. 반면 T1 강조 영상 및 FLAIR(Fluid-Attenuated Inversion Recovery) 영상은 이러한 특정 목적에 덜 효과적입니다 [8,9]. MRI 데이터 기반 의사결정 기법은 질병의 초기 단계에서 질병 발생을 감지하는 데 유용하지만, PD의 조기 진단에 영향을 미치는 몇 가지 단점이 있습니다. 이러한 한계 중 하나는 MRI 영상 데이터가 느리고 경미한 특징을 나타낼 수 있다는 점입니다. 이는 질병 진행을 식별하는 데 사용될 수 있지만, PD의 조기 발견을 위한 신뢰할 수 있는 분류 체계를 제공하지 못할 수 있습니다. 또한 이러한 방법은

높은 비용 때문에 많은 사람들이 감당하기 어렵다. 더욱이 MRI를 이용한 파킨슨병의 효과적인 진단은 의사의 전문성에 달려 있으며, 초기 단계에서는 인지 오류로 인한 오진의 위험이 존재합니다.

머신러닝(ML) 및 딥러닝(DL)과 같은 데이터 기반 모델을 사용하여 MRI 스캔에서 관찰되는 패턴과 관계를 분석함으로써 파킨슨병(PD)의 진행 양상을 성공적으로 파악할 수 있었습니다 [10, 11]. 이러한 방법들은 MRI 스캔에서 나타나는 미묘하고 경미한 특징들을 활용하더라도 질병 진행을 초기 단계에서 효과적으로 식별할 수 있으며, 임상 의사의 수동 평가에 내재된 인지 오류를 제거합니다. 그러나 ML/DL 알고리즘을 초기 질병 식별에 활용하는 것은 효과적이지만, 모델이 효율적으로 분류하기 위해서는 충분한 양의 학습 데이터가 필요합니다. 이러한 고정밀 모델의 복잡성으로 인해 평가의 투명성이 부족해져 임상 의사가 환자를 평가하고 치료 계획을 수립하는 데 어려움을 겪는 경우가 많습니다 [12, 13].

본 연구는 XAI와 ML을 통합하는 새로운 접근 방식을 제시합니다.




그림 1. XAI 및 ML 기술을 활용한 PD 조기 발견 및 모니터링을 위한 제안 프레임워크의 프로세스 흐름.

본 연구는 모델의 투명성과 해석 가능성을 높이기 위해 다양한 기법을 통합합니다. 이러한 통합은 자동화된 진단 시스템에 대한 임상적 수용도와 신뢰도를 향상시키는 것을 목표로 합니다. XAI(신규 인공지능)는 AI 모델의 의사결정 과정을 밝혀 임상 의사 '블랙박스' 결정의 근거를 이해할 수 있도록 지원하며, 파킨슨병의 핵심 진단 특징을 파악하고 기존 머신러닝 알고리즘으로는 얻을 수 없는 근본적인 메커니즘에 대한 이해를 심화시킵니다. 이러한 통찰력은 개별 위험 요인을 고려한 맞춤형 치료 계획을 수립하는 데 매우 중요하며, 치료 결과를 크게 향상시킬 수 있습니다. 본 연구는 파킨슨병 진단 정확도 향상을 위해 8개의 피질하 영역에 걸쳐 MRI 데이터에서 추출한 구조적, 형태학적, 질감적, 통계적 방사선학적 특징을 상세하게 분석하는 데 중점을 둡니다. 제안된 프레임워크에 XAI를 통합하면 임상 의사가 더욱 정확한 진단을 내리고 오진 위험을 줄이며 진단 과정에서 시기적절한 개입을 할 수 있도록 지원합니다. 제안된 프레임워크에 대한 자세한 개요와 기존 방법론의 한계점은 [그림 1](#)에 제시되어 있습니다.

본 연구 논문의 주요 기여 사항은 다음과 같습니다.

1. 실제 데이터를 활용하여 파킨슨병의 조기 발견을 향상시키고 진단 정확도를 크게 높이기 위해 3D MRI 영상과 GB 알고리즘을 결합한 새로운 프레임워크를 개발했습니다.
2. 다양한 XAI 방법론을 구현하여 파킨슨병 예측 분야에서 AI 기반 진단의 투명성과 신뢰성을 높이고, 더 폭넓은 임상적 수용을 촉진합니다.
3. 방사선영상학적 특징을 이용하여 하위군으로부터 107개의 특징을 추출하였다. 최적의 특징 선택 전략을 사용하여 20개의 핵심 특징을 식별함으로써 뇌의 특정 영역을 분석합니다.
4. SMOTE를 통해 데이터 불균형 문제를 효과적으로 해결함으로써 머신러닝 모델 예측 정확도의 견고성을 향상시켰으며, 모델 성능을 크게 개선하고 SMOTE 적용 후 진단 정확도를 87%에서 96.8%로 높였습니다.
5. 제안된 프레임워크는 파킨슨병의 전구 증상을 조기에 파악하는 데 도움이 되었고, 환자의 삶의 질을 향상시킬 수 있는 맞춤형 치료 접근법을 계획할 기회를 제공했습니다.

본 논문의 나머지 부분은 다음과 같이 구성됩니다. [2절에서는](#) 다양한 영상 처리 기술, 머신러닝 알고리즘 및 실행 가능한 인공지능(XAI) 기법을 중심으로 본 연구와 관련된 기존 문헌을 간략하게 살펴봅니다. [3절](#)에서는 제안된 시스템 개발에 사용된 방법론을 설명하고, 적용된 처리 방법과 특징 선택 전략을 상세히 기술합니다. [4절에서는](#) 6개의 머신러닝 모델 분류기의 성능 평가 결과를 종합적으로 다루고, 세 가지 XAI 접근 방식을 적용하여 예측에 관여하는 인과적 특징에 대한 심층적인 통찰력을 얻는 효과를 제시합니다. [5절](#)에서는 제안된 XAI 기반 프레임워크에 대한 상세한 논의와 다른 접근 방식과의 성능 비교를 제시합니다. 마지막으로 [6절에서는](#) 향후 연구 방향에 대한 논의와 함께 논문을 마무리합니다.

2. 관련 저작물

이 섹션에서는 제안된 프레임워크 개발에 도움이 된 연구의 문헌 검토를 제공합니다. 파킨슨병(PD)은 운동 및 비운동 증상을 특징으로 하는 진행성 신경 질환입니다. 인공지능(AI)은 PD 진단에 널리 활용되고 있는데, 이는 AI의 사용이 진단 정확도 향상과 조기 진단에 기여하기 때문이며, 이는 질병의 관리 및 치료에 필수적입니다. 기존 진단 기법은 임상적 판단에 의존하는 경우가 많고 주관적인 해석에 취약하기 때문에 진단 정확도와 신뢰성을 높이기 위해서는 AI를 기존 진단 기법에 통합해야 합니다. 파킨슨병(PD) 진단은 기존 임상 환경에서 많은 어려움을 수반합니다. [\[14\]](#)에서 저자는 PD 진단을 받은 환자의 15%가 엄격한 임상 기준을 충족하지 못했고, 실제 PD 환자의 20%가 진단받지 못했다는 사실을 발견하여 진단의 어려움과 AI의 필요성을 강조했습니다.

보다 엄격한 기준을 위해서입니다. 마찬가지로 [\[15\]](#)에서 저자들은 PD의 증상이 다른 신경퇴행성 질환의 증상과 혼동될 수 있고, 이 질병에 대한 신뢰할 수 있는 바이오마커가 없기 때문에 PD가 오진되는 방식에 대해 논의합니다. 이러한 어려움은 진단 정확도를 높이기 위해 전문가와 정기적으로 재평가하고 소통하는 것이 얼마나 중요한지를 강조합니다.

파킨슨병 진단에는 MRI, PET, SPECT 스캔과 같은 신경 영상 데이터, 도파민 운반체 수치와 같은 생체 지표, 알파-사누클레인, 타우와 같은 단백질 등 다양한 데이터 유형을 분석하는 것이 포함됩니다. [\[16\]](#)에서 저자들은 바이오마커가 파킨슨병의 초기 진단, 진행성 파킨슨병 평가, 그리고 루이체병(DLB)을 포함한 다른 질환과의 감별에 유용한 방법이라고 결론지었습니다. 구조적 MRI 및 신경멜라닌 민감성 MRI와 같은 신경영상 기법은 뇌 위축 또는 신경멜라닌 함량의 차이를 기반으로 파킨슨병과 루이체병을 구별합니다. DAT SPECT는 도파민 수송체 활용도를 평가하여 파킨슨병 진단을 매우 정확하게 확정하는 데 도움을 주며, F-DOPA PET는 흑질 세포 수 및 운동 증상과의 상관관계를 평가합니다. 예를 들어, [\[17\]](#)에서 저자는 파킨슨병의 조기 발견을 위해 MDVP 오디오 데이터에 머신러닝 접근법을 적용했으며, 선택된 랜덤 포레스트(RF) 분류기가 높은 정확도를 보였습니다. 조기 진단에서 해석 가능성의 중요성을 강조하는 머신러닝 모델은 [\[18\]](#)에서 도파민 수송체(DaTSCAN) 영상을 활용하여 제시되었습니다. 참고문헌 [\[19\]](#)에서는 PD 환자와 건강한 사람을 구분하기 위해 텍스트 분석과 머신러닝을 사용하여 F-18 FP-CIT PET 스캔을 이용한 PD 진단법을 연구했습니다. 참고문헌 [\[20\]](#)에서는 SPECT 영상에서 PD를 인식하기 위해 심층 컨볼루션 신경망(DCNN)을 사용하는 것을 강조하며, 모델의 해석 가능성을 점진적으로 다룹니다. 참고문헌 [\[21\]](#)에서는 확산 MRI의 텍스트 특징을 이용하여 PD를 검출하고 높은 분류 정확도를 달성했으며, 참고문헌 [\[22\]](#)에서는 임상 평가와 신경영상 샘플을 활용한 고급 PD 검출을 위한 포괄적인 AI 접근 방식을 제시합니다.

머신러닝(ML) 및 딥러닝(DL) 기술은 MRI 데이터를 효과적으로 활용하여 파킨슨병(PD)을 정확하고 조기에 진단할 수 있습니다. 이러한 기술은 기존 방식으로는 감지할 수 없는 특징적인 패턴과 바이오마커를 식별하여 진단 정확도를 향상시킵니다. 인공지능(AI)과 MRI를 통합하면 질병 모니터링 및 치료 계획 수립에 도움이 됩니다. MRI 데이터는 상세한 뇌 영상과 뛰어난 공간 해상도를 제공하기 때문에 파킨슨병 진단에 매우 적합합니다. MRI는 뇌의 질감, 모양, 부피 및 구조 변화를 포함한 형태학적 및 구조적 변화를 분석합니다.

복셀 기반 형태측정법(VBM)은 MRI 스캔을 이용하여 뇌 해부학적 구조의 차이를 연구하는 특징적인 신경영상 분석 기법입니다. 연구자들은 고해상도 MRI 데이터에 VBM을 적용하여 회백질 농도 및 뇌 형태의 변화를 측정하고 분석함으로써 신경 질환과 관련된 구조적 변화를 감지할 수 있습니다.

[\[23\]](#)에서는 VBM을 이용하여 약효 소실 증상을 보이는 파킨슨병 환자의 회백질 감소를 강조하고, 피질 위축과 운동 증상 간의 연관성을 제시했습니다. 이러한 연구 결과는 파킨슨병에서의 신경퇴행과 인지 기능 저하 및 운동 장애와의 관계에 대한 이해를 증진시킵니다. [\[24\]](#)에서는 MRI 스캔에 대한 고급 형태 분석 기법을 사용하여 파킨슨병 환자의 피질하 핵의 종단적 부피 및 형태 변화를 분석했습니다. [\[25\]](#)에서는 임상 및 방사선학적 특징을 통합하여 높은 정확도로 파킨슨병 아형을 식별하고 예측하는 방법을 강조했습니다. [\[26,27\]](#)에서는 베이지안 네트워크 분류기와 퍼지 k-최근접 이웃(KNN) 접근법을 파킨슨병 예측에 적용하여 복잡하고 고차원적인 데이터를 처리하는 데 이러한 방법의 효과를 강조했습니다. [\[28\]](#)에서는 구조적 MRI에서 얻은 질감 기반 마커가 파킨슨병의 운동 장애와 상관관계가 있음을 조사하여 질병 진행에 대한 유용한 바이오마커를 제시했습니다.

[\[29–31\]](#)에서 연구자들은 방사선학의 발전과 과제에 초점을 맞추어 개인 맞춤형 암 치료를 향상시킬 수 있는 잠재력과 PD를 다른 파킨슨병 증후군과 구별하는 데 있어서의 응용 가능성을 강조합니다.

인공지능은 파킨슨병 진단의 정확도를 크게 향상시켰지만, 고품질 뇌 데이터를 처리하고 해석하는 데에는 여전히 어려움이 남아 있습니다.

영상 데이터의 해석 가능성 부족은 연구를 지연시키고 임상 적용을 제한할 뿐만 아니라, 머신러닝(ML) 및 딥러닝(DL) 모델이 '블랙박스'처럼 작동하여 AI 기반 방법의 투명성이 부족해 의료 전문가의 수용을 저해합니다. 투명성이 확보되면 의료 전문가는 AI 기반 진단 도구를 신뢰할 수 있습니다. 이는 해석 가능한 AI(XAI)로의 전환을 촉진하고 AI 모델의 결정을 이해하기 쉽게 만들어 신뢰와 수용도를 높이며, 특히 의료 분야에서 더욱 중요합니다. [32]에서는 AI 모델의 해석 가능성 필요성을 논의하며 AI 결정의 투명성과 이해 가능성을 강조합니다. [33]에서는 T1 강조 MRI 데이터 세트를 사용하여 파킨슨병(PD)을 분류하는 설명 가능한 딥러닝 모델을 통해 분류에 영향을 미치는 중요한 뇌 영역을 식별하기 위해 살리언시 맵을 활용하는 방법을 제시합니다. [34]에서는 DAT-SPECT 이미지의 CNN 기반 분류에 대한 해석 가능성을 제공하기 위해 계층별 관련성 전파(LRP)를 사용하는 방법을 연구하여 자동화된 진단 도구에 대한 임상적 수용도와 신뢰를 높이는 데 있어 XAI의 중요성을 보여줍니다.

XAI는 해석 가능성을 향상시켜 의료 전문가가 AI 기반 인사이트를 더욱 쉽게 이해하고 신뢰할 수 있도록 합니다. 본 연구에서 제안하는 방사선학적 특징과 XAI를 활용한 분석은 복잡한 데이터에 대한 이해를 높여 명확하고 실행 가능한 인사이트를 제공합니다. 이 연구는 XAI 기술을 통합한 새로운 머신러닝 기반 분류 프레임워크를 활용하여 기술적 정확성과 임상적 유용성 간의 격차를 해소하고 의료 전문가가 AI 기반 인사이트를 더욱 쉽게 활용할 수 있도록 하는 것을 목표로 합니다. 파킨슨병 진단을 위한 신경영상 기법 비교 분석은 표 1에 제시되어 있습니다.

3. 제안된 방법

3.1. 데이터 수집

본 연구는 파킨슨병 진행 표지자 이니셔티브(PPMI) 데이터베이스의 MRI 스캔 자료를 활용하며, 해당 데이터베이스는 (www.ppmi-info.org/data)에서 확인할 수 있습니다. 분석을 진행하기 위해 이미지는 먼저 각 환자에 대해 DICOM(Digital Imaging and Communications in Medicine) 형식으로 다운로드되고 이후 NIfTI(Neuroimaging Informatics Technology Initiative) 형식으로 변환됩니다 [36].

이 변환을 통해 본 연구에 필요한 3D 분석이 가능해졌으며, 축면, 시상면, 관상면을 모두 확인할 수 있습니다. MRI 스캔은 독일 뮌헨에 위치한 SIEMENS 스캐너를 사용하여 얻었습니다.

이 데이터 세트에는 세 가지 범주로 분류된 500명의 환자에 대한 MRI 스캔이 포함되어 있습니다.

표 1. 인공

지능 및 머신러닝을 활용한 파킨슨병 진단용 신경영상 기술에 대한 최근 연구의 주요 결과 요약.

참조 연구 데이터 세트 세부 정보	데이터	방법론	관심 영역(ROI)	연구 결과
[31] 2021 65-PD 61-APS 30-MSA 75-HC	MRI 주사	RF 분류기, 방사선영상 특징 추출, 5겹 교차 검증, 훈련용 80% 분할, 테스트용 20% 분할	시상, 시상핵, 피질핵, 흑질, 소뇌 및 뇌간	PD 대 HC - 정확도 70% PD 대 APS - 92% 정확도 PD, APS, HC 비교 - 정확도 96%
[35] 2020 356-HC, 355- PD	dmri 주사	사용자 정의 네트워크, 10겹 교차 검증, 교차 엔트로피 손실, Adam 옵티마이저	12개의 ROI(대뇌 반구에 6개, 등쪽 전운동 피질, 보조 운동 영역 210개, 소뇌의 피질하 영역 36개)	정확도 97.8%
[21] 2022 123-PD 90-HC	MRI 데이터	방사선영상 특징 추출, 두 표본 t-검정, SVM을 이용한 특징 선택 및 5겹 교차 검증		78.07% -정확도 0.859 -AUC 민감도 78.80%, 특이도 76.08%. 임상 징후와 관련된 질감 특징은 파킨슨병 환자에서 유의미했습니다. 파킨슨병 환자 그룹 내 부피 변화는 유의미한 차이를 보이지 않았습니다.
[28] 2021 32-HC 39-파킨슨병 초기 37-파킨슨병 후기	MRI 데이터	통계 분석 및 1차/2차 텍스처 특징 추출 (ROI와 VOI 비교)	SN, 선조체, 시상 및 시상하핵	
[24] 2024 32- HC 34-PD	MRI	피질하 영역과 임상 증상 간의 부피 및 형태 변화 분석이 수행됩니다.	피질하 영역(피질핵 및 담핵)	PD는 좌측 담핵과 피질핵에서 유의미한 상관 관계를 보입니다. 좌측 피질핵은 임상 증상과 유의 상관관계를 나타냅니다. 정확도는 83.33%입니다.
[29] 2023 36-HC 47-PD	MRI	SVM 및 RF, 10겹 교차 검증, 방사선학적 특징, 사용자 정의 모델, 훈련 데이터 75%, 테스트 데이터 25%	SN 지역	

약어: APS - 비정형 파킨슨 증후군; MSA - 다계통 위축증; HC - 건강한 대조군; dmri - 확산 자기공명영상; RFE - 재귀적 특징 제거; VOI - 관심 영역; SVM - 서포트 벡터 머신; AUC - 곡선 아래 면적.

연구 대상군은 파킨슨병 환자 180명, 전구 증상 환자 160명, 건강 대조군 160명으로 구성되었습니다. MRI 스캔 매개변수에 대한 자세한 내용은 표 2에 제시되어 있습니다.

3.2. 데이터 전처리

본 연구의 MRI 처리 파이프라인은 그림 2에서 보여주는 바와 같이 상세한 분석을 위해 스캔 이미지를 준비하는 여러 고급 계산 기술을 포함합니다. 이 과정은 각 환자의 NIfTI 파일로 초기화하는 것으로 시작하며, 편향 보정, 정합 및 분할된 이미지를 생성하는 것을 목표로 합니다.

3.2.1. 뇌 추출

각 NIfTI 파일은 Robust Brain Extraction(ROBEX) 알고리즘을 사용하여 뇌 영역 추출 과정을 거칩니다. 이 알고리즘은 형태학적 연산과 확률 모델의 조합을 사용하여 뇌와 비뇌 영역 사이의 경계를 반복적으로 정제함으로써 뇌(1)와 비뇌 조직(0)을 구분하는 이진 마스크를 생성합니다 [37].

표 2. 영상

촬영 프로토콜의 매개변수.

영상 촬영 프로토콜	값
양식	MRI
연구 그룹	PD, 대조군, 전구기 기준선(BL)
방문하다	
획득 평면, 유형	시상면(3D) 3.0 테슬라
필드 강도	
각도	120.0도 지멘스
제조업체	(SAG 3D FLAIR)
행렬	X=256–512 픽셀 Y=256–512 픽셀 Z=20–60 픽셀 X=0.5–1.5 mm
픽셀 간격	Y=0.5–1.5 mm Z=2–5 mm
펄스 시퀀스	스핀 에코(SE)/반전 회복(IR) 1.0 mm 120–500 ms/1800–2200 ms/2000–
슬라이스 두께	
TE/TI/TR	5000 ms T2
가중치	




그림 2. 전처리 과정의 상세 단계.

3.2.2. 등록 뇌 추출 이미

저는 Antspyx 라이브러리를 사용하여 MNIPD25-T1MPRAGE-1 아틀라스에 정렬됩니다. 이를 통해 각 이미지가 아틀라스의 공간적 구성과 일치하게 됩니다. 이 라이브러리는 아핀 및 비선형 등록 기법을 사용하여 이미지를 정렬합니다 [38, 39]. 아핀 등록은 변환, 회전 및 크기 조정을 보장하고, 비선형 등록은 국부적인 변형을 조정합니다.

등록된 이미지로부터 정규화된 이미지는 식 (1)-(3)을 사용하여 얻습니다.

1. 최소 및 최대 강도 값 추정.

$$\text{최소값} = \min(I(x, y)); \text{최대값} = \max(I(x, y)), \tag{1}$$

2. 각 픽셀에서 최소 강도 값을 뺍니다.

$$\text{NormalizedImage}(x, y) = I(x, y) - \text{Minvalue}, \tag{2}$$

3. 정규화된 이미지의 각 픽셀을 강도 범위로 나눕니다.

$$\text{NormalizedImage}(x, y) = \frac{\text{정규화된 이미지}(x, y)}{\text{최대값} - \text{최소값}}, \tag{3}$$

여기서 I는 T2 MRI 이미지를 나타내고, I(x, y)는 픽셀 위치 (x, y)에서의 이미지 강도 값을 나타냅니다.

3.2.3. 바이어스 필드 보정

N4Bias 보정 알고리즘은 강도 불균일성을 보정하기 위한 목적으로 각 정규화된 이미지에 적용됩니다. 이 알고리즘은 바이어스 필드를 반복적으로 추정하고 이를 이미지에 적용하여 저주파 강도 불균일성을 모델링하고 보정합니다 [40].

3.2.4. 피질하 분할

편향 보정된 각 이미지에 대해 FMRIB 소프트웨어 라이브러리(FSL) 도구를 사용하여 아틀라스에 따라 8개의 특정 피질하 영역을 분할합니다. 이 도구는 확률적 아틀라스와 머신러닝 기법을 활용하여 영역을 정확하게 분할합니다.

3.2.5. 레이블 융합은 식

(4)에 나타난 바와 같이 각 복셀에 대한 각 레이블의 계산된 확률을 기반으로 하는 가중 투표를 통해 여러 분할을 결합하여 분할 정확도를 향상시키는 데 사용됩니다.

$$Y_i = \arg \max_j \in L \left(\sum_{k=1}^N S_{k,i,j} \cdot W_k \right) \quad (4)$$

여기서 $S_{k,i,j}$ 는 분할 k 에서 복셀 i 가 레이블 j 에 속할 확률이고, W_k 는 분할에 할당된 가중치이며, $\arg \max_j$ 는 레이블을 반환하는 함수이고, L 은 아틀라스의 레이블 집합이며, Y_i 는 레이블 융합을 통해 얻은 최종 분할 결과입니다.

3.2.6. 역 정합 분할된 영역은 역정

합을 사용하여 환자별 해부학적 공간으로 다시 매핑됩니다. 이 단계에서는 초기 정합 과정에서 얻은 변환 매개변수를 사용하여 분할된 영역을 원래 이미지에 다시 정렬합니다. MRI 전처리 파이프라인의 자세한 의사 코드와 알고리즘 분석은 표 3에 설명되어 있습니다. 여기에는 DICOM 파일 변환부터 정합 기법을 사용한 고급 이미지 분할 수행까지의 단계가 포함됩니다.

3.3. 피질하 영역 선택

흑질(SN)과 기저핵(BG)에서 도파민을 분비하는 신경세포의 손실은 파킨슨병(PD) 진단에 매우 중요합니다. 기저핵 하위 영역의 특징 또한 파킨슨병을 식별하는 데 중요한 역할을 합니다. 파킨슨병 환자는 일반적으로 대조군에 비해 피질 영역의 변화, 변형된 뇌구조 패턴, 그리고 더 큰 해마 부피를 보입니다. 글루타메이트, 감마아미노부티르산(사상하핵에 존재), 아세틸콜린(미상하핵에 존재)과 같은 신경전달물질은 뇌 영역 간의 신호 전달을 촉진합니다.

표 3
MRI 전처리 파이프라인의 의사 코드.

1단계: 처리 초기화 입력: 각 환자별 Nifti 파일 2단계: 뇌 추출 각 Nifti 파일에 대해: ROBEX 알고리즘을 적용하여 뇌 조직을 추출합니다. 뇌를 이진 마스크로 나타냅니다 (뇌인 경우 1, 뇌가 아닌 경우 0).
3단계: Atlas에 등록 각 뇌 추출 이미지에 대해: MNIPD25-T1MPRAGE-1 아틀라스를 로드합니다. Antspyx를 사용하여 이미지를 아틀라스에 정렬합니다. 4단계: 강도 정규화 등록된 각 이미지에 대해: 식 (1)을 사용하여 강도 값을 계산합니다.
식 (2) 및 (3)을 사용하여 이미지를 정규화합니다. 5단계: 바이어스 필드 보정 각 정규화된 이미지에 대해 N4Bias 보정 알고리즘을 적용합니다. 6단계: 피질하 분할 편향 보정된 각 이미지에 대해: FSL 도구를 사용하여 아틀라스를 기반으로 8개의 피질하 영역을 분할합니다. 7단계: 레이블 융합 각 초기 분할 세트에 대해: 각 복셀에 대해: 식 (4)를 사용하여 각 레이블의 확률을 계산합니다.
8단계: 역정합 각 분할된 이미지에 대해: 3단계에서 얻은 매개변수를 사용하여 역정합을 적용합니다. 분할된 영역을 원래의 환자별 해부학적 공간에 다시 매핑합니다. 알고리즘 종료 출력: 편향 보정, 정합 및 분할된 이미지

인지 및 운동 기능에 영향을 미칩니다. 구체적으로, SN은 운동 조정에 필수적인 미상핵과 피질핵에 영향을 미치는 반면, 담핵, 시상, 시상하핵 및 적핵은 운동 및 인지 과정을 조절합니다. 이러한 영역은 PD를 감지하는 데 중요하며 추가 분석에 사용됩니다 [41–43].

3.4. 파킨슨병의 등급 분류

본 연구에서 제시된 파킨슨병(PD) 등급 분류 과정은 그림 3에 나타나 있습니다. 이 과정은 아틀라스 기반 분할을 사용하여 16개의 피질하 뇌 영역을 식별하고, 각 영역의 부피, 형태 및 질감을 자세히 분석할 수 있도록 합니다. 특징 추출 방법을 사용하여 MRI 데이터 내의 주요 패턴을 식별하고, 이를 통해 PD 중증도 등급을 구분합니다 [44]. 'radiomics' 패키지는 이러한 패턴을 처리하여 MRI 데이터의 필수적인 특성을 나타내는 포괄적인 특징 집합으로 정제합니다. pyradiomics 패키지를 사용한 Python 기반 특징 추출 과정은 여러 단

계로 구성됩니다. 먼저 전처리된 MRI 이미지와 분할된 레이블을 불러옵니다. 그런 다음 복셀 크기 재샘플링, 정규화 및 특징 클래스 선택을 포함한 추출 설정을 구성합니다. pyradiomics 추출 프로세스를 실행하여 각 분할 영역에 대한 107개의 특징을 계산합니다. 결과적으로 PD 진행 분석에 중요한 포괄적인 방사선학적 특징 집합이 생성됩니다. 표 4에는 파킨슨병 진행 평가에 유용한 피질하 영역에서 추출된 다양한 유형의 방사선학적 특징에 대한 구체적인 설명과 전체 특징 수가 제시되어 있습니다.

특징 선택은 파킨슨병의 조기 진단에 가장 중요한 특징들을 선별하는 과정입니다. 본 연구에서는 2단계 지도 학습 기반 특징 선택 과정을 활용했습니다. 먼저, 107개의 방사선학적 특징에 대해 피어슨 상관관계(임계값 0.85)를 적용하여 관련성이 낮은 68개의 특징을 제외하고 39개의 특징으로 줄였습니다. 다음으로, 남은 39개의 특징에 대해 100개의 추정기와 42개의 랜덤 상태를 사용하는 랜덤 포레스트(RF) 분류기를 이용한 래퍼 기반 재귀적 특징 제거(RFE) 과정을 수행했습니다. 이를 통해 예측에 유의미한 영향을 미치지 않는 19개의 특징을 추가로 제외하고 최종적으로 20개의 특징을 선별했습니다.

마지막으로, 그림 4에 자세히 설명된 바와 같이, 이 20가지 특징에 순위 모델을 적용하여 파킨슨병 예측에서의 중요도를 기준으로 우선순위를 정했습니다.

이 단계는 가장 영향력 있는 특징을 강조하여 ML 모델이 정확한 분류를 위해 가장 판별력이 높은 데이터를 갖도록 했습니다. ML에서 불균형 데이터셋 문제를 해결하기 위해 본 연구에서는 모델 학습 전에 모든 클래스의 균형 잡힌 표현을 보장하기 위해 SMOTE라는 기법을 적용했습니다 [45]. 상세한 분할에서 균형 잡힌 학습에 이르는 이러한 체계적인 접근 방식은 PD 분류의 정확성과 신뢰성을 향상시키는 것을 목표로 합니다.

3.5. 머신러닝 분류기 및 XAI 기술

본 연구는 레이블이 지정된 데이터셋을 사용하여 파킨슨병(PD) 분류를 위한 최적의 머신러닝(ML) 모델을 선택하는 데 초점을 맞추고 있으며, 모델 예측 및 동작에 대한 정확하고 견고하며 이해하기 쉬운 설명을 제공하는 데 있어 XAI(확률적 인공지능)의 필요성을 강조합니다. 데이터셋은 ML 모델의 학습 및 테스트에 모두 사용됩니다. 앞서 논의한 바와 같이, 상위 20개 특징이 PD 분류를 위한 ML 모델의 입력으로 사용됩니다. 본 연구에서는 랜덤 포레스트(RF), 케빈 뉴턴(KNN), 엑스트라 트리(ET), 그레디언트 부스팅(GB), 의사결정 트리(DT), 캣부스트(CatBoost)를 포함한 6가지 ML 기반 분류기를 평가 지표를 기반으로 평가합니다.

본 연구에서는 머신러닝 모델의 의사결정을 설명하기 위해 XAI 기법을 활용합니다. 탐색된 XAI 방법 중 하나인 SHAP(Shapley-additive Explanations)는 특징 중요도의 전역적 척도를 제공합니다. LIME(Local Interpretable Model-agnostic Explanations)과 SHAPASH는 모두 모델이 예측에 도달하는 추론 과정에 대한 자세한 통찰력을 제공합니다. 대리 모델의 가중치는 각 입력 특징의 중요도를 정의하는 SHAP 값을 계산하는 데 사용됩니다. 식 (5)는 개별 특징에 대한 SHAP 값을 평가하는 데 사용됩니다.




그림 3. PD 등급 분류를 위해 제안된 전체 흐름 과정.

인스턴스.

$$(x) = \sum_i i(x) \tag{5}$$

여기서 (x) 는 인스턴스 x 에 대한 전체 SHAP 값을 나타내고 $i(x)$ 는 인스턴스 x 의 특징 i 에 대한 SHAP 값을 나타내며 각 특징에 중요도를 할당하는 SHAP 값을 계산하는 데 사용할 수 있습니다 [46]. SHAP 값은 모델에 대한 자세한 통찰력을 제공하여 예측에 기여하는 특징에 대한 중요한 정보를 제공하고 임상 적용에서 투명성과 가치를 높여주기 때문에 매우 유용합니다. 위터폴 플롯은 SHAP 값을 나타내는 데 사용되며, 이를 통해 예측에 기여하는 특징과 임상 적용에서의 투명성과 가치를 확인할 수 있습니다.

각 특징은 특정 예측에 기여하며, 별대 그래프 또는 막대 그래프는 특징의 전반적인 중요도를 보여줍니다. 의존성 그래프는 특징들 간의 의존 관계를 설명하고, 힘 그래프는 특정 특징의 예측을 이해하는 데 도움을 줍니다. 이러한 시각적 도구들을 함께 활용하면 모델을 이해하고, 문제를 해결하고, 개선하는 데 도움이 됩니다.

LIME은 입력 데이터의 변화를 도입하여 예측 변동을 평가합니다. 이 방법론은 블랙박스 모델의 의사 결정 과정을 이해하는 데 도움이 됩니다. 이 방법은 블랙박스 모델이 로컬에서 어떻게 작동하는 지에 대한 통찰력을 제공합니다 [47]. 식 (6)은 특정 인스턴스에 대한 LIME 방법의 수학적 표현을 나타냅니다.

$$\xi(x) = \operatorname{argmin}_{g \in G} L(f, g, w_x) + w(g) \tag{6}$$

표 4
ROI에서 추출한 특징 유형 및 특징 개수에 대한 설명입니다.

기능 유형	수 특징	설명
1차 통계적 특징	17	이는 복셀 강도의 평균, 분산, 왜곡도와 같은 기본적인 통계적 특성을 측정하며, 이는 필수적인 요소입니다. 뇌 조직에서 파킨슨병 관련 초기 변화를 감지합니다.
형태 기반(2D)	10	피질하 구조의 2차원 형태 특성(면적, 둘레, 원형도)을 분석합니다. 이는 다음과 같은 경우에 유용합니다. 파킨슨병에 전형적인 형태학적 변화를 식별합니다.
형태 기반(3D)	10	이 기술은 뇌의 3차원 구조 변화에 대한 상세한 정보를 제공하며, 이는 진단에 매우 중요합니다. 파킨슨병의 진행 양상 평가.
화색조 동시발생 행렬	24	복셀 강도 간의 공간적 관계를 포착하여 피질하 영역의 질감 변화에 대한 통찰력을 제공합니다. 파킨슨병의 징후입니다.
화색 레벨 런 길이 매트릭스	12	유사한 강도 값을 갖는 연속적인 복셀의 길이를 설명하여 질감의 균일성을 파악하는 데 도움을 줍니다. 파킨슨병과 관련된 변이.
화색 레벨 크기 영역 매트릭스	12	균일한 복셀 강도를 가진 영역의 크기를 평가하여 조직의 완전성 변화를 감지하는 데 도움을 줍니다. 파킨슨병과 관련된 패턴.
인접한 화색 톤 차이 행렬	12	인접한 복셀 간의 강도 차이를 측정하여 질감 및 구조적 변화를 강조합니다. 이는 중요한 요소입니다. 대뇌 피질하 영역의 미묘한 변화를 감지합니다.
화색 레벨 의존성 행렬	10	복셀 강도 간의 상관관계를 분석하여 포괄적인 분석에 필요한 질감 및 구조적 세부 정보를 드러냅니다. 파킨슨병 관련 변화에 대한 평가.
모든 기능을 망라한 목록 (총 107개)		뇌 구조를 특징짓기 위해 질감, 형태 및 구조 분석을 결합한 포괄적인 특징 세트 파킨슨병을 확실하게 감지합니다.

여기서 $\xi(x)$ 는 개별 인스턴스 x 에 대한 설명 가능한 모델 G 를 나타냅니다.
는 잠재적인 설명들을 나타내고, L 은 손실 함수를 나타냅니다.
설명 모델과 그 일치성을 측정하는 것
 f 는 원래 모델을 나타내고 w_x 는 w_x 를 나타냅니다.
샘플링된 데이터의 각 인스턴스에 할당된 가중치 요소,
각 사례의 영향력을 발생 빈도에 따라 조정합니다.
원본 데이터 세트에서의 중요도. 샘플링된 데이터의 경우
원본 데이터와 매우 유사할수록 w_x 의 중요성은 더욱 커집니다.
SHAPASH는 필수 데이터와 모델 정보를 제공합니다.
시각화에 중점을 둔 접근 방식에 더해, 다음과 같은 차이점이 있습니다.
사플리 값으로 가중치를 부여한 다양한 특징에 대한 모델의 예측값
특정 기능에 대한 이러한 방법들은 다음과 같이 요약됩니다.
이를 통해 정확한 예측을 하고 정보를 제공하는 모델을 만들 수 있었습니다.
그들의 선택에 대한 이해하기 쉬운 정당성.

4. 결과

본 연구의 비교 분석에서는 머신러닝 분류기를 활용했습니다.
질감, 형태 및 통계적 특징을 조사합니다.
MRI 스캔에서 추출한 관심 영역. 자세한 정보
ML 알고리즘과 그 구체적인 매개변수는 표 5에 제시되어 있습니다.
이러한 모델 개발에 사용된 소프트웨어 라이브러리는 다음과 같습니다.
CatBoost 버전 1.2.5 및 Scikit-learn 버전 1.2.2. 방사선영상학 기능-
500개의 피질하 분할 MR 데이터 세트에서 이미지를 추출했습니다.
이미지 데이터입니다. 데이터는 훈련 세트(80%)와 테스트 세트로 나누었습니다.
(20%). ML 분류기는 성능 지표를 평가했습니다.
참양성, 참음성, 거짓양성을 이용하여 PD를 탐지합니다.
거짓 음성. 식 (7) ~ (11)은 사용된 수학적 공식을 제공합니다.
이러한 지표를 계산하면 효과를 평가하는 데 도움이 됩니다.
모델의 정확도.




그림 4. 선택된 상위 20개 특징의 순위.

정확도 =

(참긍정 + 참부정)

(참양성 + 거짓양성 + 참음성 + 거짓음성)

(7)

정밀도 =

진정한 긍정적 결과

(참양성 + 거짓양성)

(8)

회상 =

진정한 긍정적 결과

(참양성 + 거짓음성)

(9)

특이성 =

참부정

(위양성 + 진음성)

(10)

F1 점수 =

(2 정밀도 재현율)

(정밀도 + 재현율)

(11)

데이터셋에 다양한 머신러닝 모델을 적용한 결과 다음과 같은 사실이 관찰되었다. 낮은 성능은 데이터셋 불균형 때문이라는 점을 파악하고, 이를 해결하기 위해 다음과 같은 조치를 취했습니다. 클래스 간 균형을 맞추기 위해 SMOTE 업샘플링 방법을 사용했습니다. 또한 모델 성능을 향상시킵니다. 표 6은 업샘플링 기법을 적용하기 전과 후의 모델 성능 지표를 보여줍니다. 데이터 품질 향상에 있어 SMOTE의 효과를 입증합니다. 또한, 특징들의 분포를 보여주기에 산점도를 사용했습니다. 그림 5는 특징 분포를 시각적으로 비교한 것입니다. 업샘플링 방법을 사용하기 전과 후. 본 연구에서는 다양한 머신러닝 분류기의 성능을 평가했습니다. 뇌 MRI 데이터를 이용한 파킨슨병 진단, 5개의 서로 다른 연구 결과를 분석 테스트 분할. 비교 대상 분류기는 RF, KNN, ET, GB, DT 및 Cat-Boost이며, 성능은 정확도, 정밀도, 표 7에 자세히 설명된 바와 같이 재현율, 특이도, F1 점수 및 계산 시간. 분류기 중에서 GB가 가장 우수한 성능을 보였습니다. GB는 다음과 같이 구성되었습니다. `n\_estimators: 1000, learning\_rate: 0.1, max\_depth: 5, `min_samples_s-plit: 2`, `min_samples_leaf: 5` 및 loss: 'log\_loss`. 이 설정은 96.8%의 최고 정확도, 97%의 정밀도, 그리고 재현율을 달성했습니다. 탐지율 94.2%, 특이도 96.6%, F1 점수 94.6%를 나타냈습니다. PD, DT는 평균적으로 최소 계산 시간을 기록하며 가장 빠릅니다. 노드 분할 과정이 간단하기 때문에 33.0초가 소요됩니다. RF 더 오랜 시간(평균 84.9초)이 소요되었는데, 이는 다음과 같은 이유 때문입니다. 여러 개의 트리를 구성합니다. GB는 효율성과 균형을 제공했습니다. 정확도가 높으며 평균 처리 시간은 76.78초입니다. 파킨슨병을 탐지하는 데 가장 효과적인 분류기. GB 분류기의 성능은 5분할 샘플링을 통해 평가되었습니다. 교차 검증을 통해 다른 분류기보다 일관되게 우수한 결과를 얻었습니다. 그림 6(a)에 나타낸 바와 같이, GB 모델의 혼동 행렬은 특히 다음과 같습니다. 파킨슨병의 전구 증상을 식별하는 데 있어 정확성을 강조합니다.

표 5 다양한 머신러닝 모델에 사용되는 사양입니다.

ML 분류기 모델	명세서
랜덤 포레스트 분류기	n_추장기: [500, 1000], 최대 깊이: [없음, 10, 20], 기준: ['gini', 'entropy'], 최소 샘플 분할: [2,5], max_features: ['sqrt', 'log']
KNN 분류기	n_neighbors: [3,5,7], weights: ['uniform', 'distance'], p: [1, 2], 알고리즘: '자통', 위 크기: [20,30]
엑스트라 트리 분류기	n_추장기: [500, 1000], 최대 깊이: [없음, 10, 20], 기준: 'gini', 최소 샘플 분할: [2,5], 최대 특징: ['제곱근', '로그']
그래디언트 부스팅 분류기	추정기 수: [500, 1000], 학습률: [0.1, 0.5], max_depth: [3,5], loss: 'log_loss', min_samples_split: [2,4], min_samples_leaf: [1,5]
의사결정 트리 분류기	max_depth: [없음, 10, 20], 기준: 'gini', 분할자: 'best', min_samples_split: 2, min_samples_leaf: 1
캐트부스트 분류기	반복 횟수: [100,200], 학습률: [0.1, 0.5], 깊이: [3,5], 손실 함수: '로그 손실'

그림 6은 초기 단계 탐지에 대한 강력한 예측 정확도를 보여줍니다. (b) PD, 대조군, 그림 6(c)에서 전구 증상 클래스는 모델의 탁월한 판별 능력을 강조합니다. 특히 ROC 곡선은 AUC(곡선 아래 면적)가 0.125임을 보여줍니다. PD군과 대조군 모두에서 AUC(곡선 아래 면적) 값이 0.99로 완벽했습니다. 전구증상 분류에서 AUC 값이 1.00으로 나타나 완벽한 분류를 보여줍니다. 높은 참양성률과 낮은 거짓양성률로 우수한 성능을 제공합니다. 비율. GB 모델은 높은 예측 정확도를 보이지만, 부족한 점이 있습니다. 설명 불가능성 때문에 임상적 유용성이 제한됩니다. 더 폭넓은 임상 적용을 위해서는 다음과 같은 점이 있습니다. 의사 결정 과정에 대한 명확성을 제공하고 입력 특징을 예측 결과와 직접 연결하는 XAI 기술을 통합하는 것이 필수적입니다. 이러한 통합을 통해 머신러닝 모델은 효과적일 뿐만 아니라,

또한 투명하고 신뢰할 수 있어 실용적인 유용성을 높입니다. 개인 맞춤형 환자 치료 및 보다 폭넓은 수용 촉진 의료계. 본 연구는 AI 기반 진단의 투명성을 높이기 위해 SHAP 및 LIME과 같은 고급 XAI 기술을 활용합니다. 그림 7(a)에 나타난 특징 중요도 플롯은 가장 중요한 특징들을 보여줍니다. 클래스 2에 대한 모델의 예측에 기여하는 특징으로는 다음과 같은 것들이 있습니다. 차이 엔트로피, 결합 엔트로피 및 차이 분산은 다음과 같습니다. 가장 높은 기여도를 보입니다. 이러한 특징들은 모델에 상당한 영향을 미칩니다. 예측 결과는 그들의 역할에 대한 추가 조사가 필요한 영역을 나타냅니다. 질병.

그림 7(b)는 LIME을 사용하여 전구 증상 사례 예측을 해석한 결과를 보여주며, 모델이 PD의 경우 18%, 8%를 예측함을 나타냅니다. 대조군의 경우 74%, 전구증상의 경우 74%입니다. LIME 설명은 다음과 같습니다. 차분 엔트로피와 결합을 이용한 예측에 대한 국소적 이해 표면은 상당한 양의 기여를 하는 엔트로피 특징을 가지고 있습니다. 불륨 비율 특징은 음의 기여도를 갖습니다. 이는 전문가가 지식에 비추어 모델의 추론을 검증하는 데 도움이 됩니다. 다양한 특징들이 특정 사례에 대한 예측에 어떤 영향을 미치는지. 전역적 XAI의 관점은 그림 7(c)의 SHAP 요약 플롯에 나타나 있습니다. 모든 예측에 걸쳐 각 특징이 미치는 영향을 보여줍니다. 특징 차이 엔트로피와 결합 엔트로피처럼 일반적으로 높은 SHAP 값을 갖는 것들이 있습니다. 이 값들은 여러 예측에서 그 중요성을 나타냅니다. 그래프는... 또한 각 특징의 기여도를 보여주며, 값이 높을수록 기여도가 높아집니다. 차이 엔트로피는 클래스 예측에 더 강력한 영향을 미칩니다. LIME과 SHAP을 통합함으로써, 본 연구는 지역적 및 모델의 의사결정 과정에 대한 전반적인 설명. 예를 들어, LIME의 로컬 설명은 다음과 같은 특징들을 보여주었습니다. 차이 엔트로피는 상당한 영향/긍정적인 기여를 했습니다. 전구 증상을 분류합니다. SHAP의 전반적인 설명은 일관적입니다. 핵심 기능의 중요성을 강조하여 어떤 기능이 중요한지 파악하는 데 도움이 되었습니다. 이러한 특징들은 전체 데이터 세트에서 가장 큰 영향을 미칩니다. 이러한 인사이트를 통해 모델의 예측을 검증하고 그 중요성을 강조합니다. 적절한 결정을 내리는 데 있어 차이 엔트로피와 결합 엔트로피의 특징 이는 의사 결정 및 추가 임상 연구 수행에 도움이 됩니다. 또한 이는 다음과 같은 이점을 제공합니다.

표 6 업샘플링 기법 적용 전후 모델 성능 비교.

모델	사용 전 정확도 스무트	사용 후 정확도 스무트
랜덤 포레스트	76.6%	89.2%
KNN	74.3%	87.8%
엑스트라 트리	84.7%	93.6%
구배	86%	96.8%
부스팅		
의사결정 트리	81.2%	90%
캐트부스트	78.7%	92%




그림 5. 산점도를 이용한 특징 분포도.

표 7. 다양

한 머신러닝 분류기의 비교.

모델	나뉘다	정확도(%)	정밀도(%)	상기하다 (안에 %)	특이도(%)	F1 점수(%)	총 소요 시간(초)
랜덤 포레스트	분할 1	89	90	89	88	91	90.23
KNN		88	89	79	89	84	53.68
엑스트라 트리		93	96	87	95	92	56.92
그래디언트 부스팅		95	96	92	95	94	78.63
의사결정 트리		87	85	76	87	80	41.72
캐트부스트	분할 2	90	94	84	93	88	43.86
랜덤 포레스트		88	90	81	81	91	82.54
KNN		89	94	83	93	85	34.91
엑스트라 트리		92	94	84	93	92	42.25
그래디언트 부스팅		96	98	92	97	95	66.04
의사결정 트리	분할 3	89	90	89	88	90	30.84
캐트부스트		92	90	86	92	88	26.46
랜덤 포레스트		90	96	82	95	98	80.25
KNN		87	85	76	89	79	41.45
엑스트라 트리		94	96	89	95	92	42.91
그래디언트 부스팅	분할 4	98	98	98	97	95	83.51
의사결정 트리		90	92	83	90	87	31.05
캐트부스트		91	92	83	91	87	33.29
랜덤 포레스트		89	94	83	93	88	92.33
KNN		88	89	79	89	86	40.69
엑스트라 트리	분할 5	96	98	92	97	94	49.84
그래디언트 부스팅		97	95	91	97	91	72.04
의사결정 트리		92	84	93	88	88	30.68
캐트부스트		93	96	85	95	90	33.57
랜덤 포레스트		90	95	81	95	92	79.42
KNN		87	84	76	88	80	40.67
엑스트라 트리		93	94	89	93	91	59.39
그래디언트 부스팅		98	98	98	97	98	83.72
의사결정 트리		92	81	90	80	85	30.73
캐트부스트		94	98	87	97	92	33.45

특히 의료와 같은 민감한 영역에서 투명성, 신뢰성 및 실질적인 통찰력을 제공합니다.

5. 토론

본 연구는 파킨슨병(PD) 및 전구기 단계의 조기 진단을 위해 뇌 영상에서 추출한 신경영상 특징을 분석했습니다. 표 8에 나타낸 바와 같이 20개의 유의미한 특징을 선정하고, 선정된 특징들을 대조군, 파킨슨병 환자군, 전구기 단계의 세 그룹 간에 통계적으로 유의미한 차이가 있는지 평가하기 위해 분산분석(ANOVA)을 시행했습니다. 분산분석 결과 모든 특징 간에 유의미한 차이($p < 0.05$)가 확인되었으며, 이는 해당 특징들이 파킨슨병을 구별하는 데 잠재력이 있음을 시사합니다.

생물학적 변이성과 의료 영상 데이터의 특수성으로 인해 이러한 특징들은 정규 분포를 따르지 않을 수 있으며 그룹 간에 다양한 분산을 나타낼 수 있습니다. 따라서 연구 결과의 견고성을 확보하기 위해 쌍별 t-검정 후 Kruskal-Wallis H-검정을 사용했습니다.

이 비모수 검정은 우리의 연구 결과가 정확함을 확인시켜 줍니다. 데이터가 정규 분포를 따르지 않더라도 잘못된 결론을 피하기 위해 쌍별 t-검정과 크루스칼-왈리스 H-검정을 실시한 결과, 선택된 특징들이 파킨슨병의 여러 단계를 구분하는 데 효과적임을 확인할 수 있었습니다.




그림 6. (a) 5겹 교차 검증 분할에 따른 GB 분류기의 정확도, (b) GB 분류기의 혼동 행렬, (c) GB 분류기 모델의 세 가지 다른 클래스에 대한 ROC 곡선.

5.1. 파킨슨병 진단에서 방사선영상학적 특징의 중요성

피질하 위축을 식별하기 위해 최대 직경을 측정하는 것과 같은 방사선학적 특징을 사용하여 PD를 감지하는 것은 생물학적 마커 역할을 합니다. 마찬가지로, 표면적 감소는 퇴행성 변화로 인한 신경 세포 손실을 시사할 수 있습니다. 뇌 영상의 밝기와 범위를 평가하는 강도 기반 특징은 PD 환자의 뇌에서 흔히 발견되는 철과 같은 물질의 변화를 나타낼 수 있습니다 [48,49]. 화색조 불균일성 및 그 분산과 같은 특징은 뇌 외관의 균일성을 포착하며, 이러한 특징의 편차는 뇌 조직에 대한 질병의 영향을 반영하여 PD의 조기 발견에 필수적인 통찰력을 제공합니다 [50–52].

선택된 영상 특징에 대한 물리적 해석은 다음과 같습니다.
파킨슨병 진행 과정에 대한 중요한 통찰력:

a) 최대 2D 직경(열), 최대 2D 직경(행), 최대 2D 직경(단면), 최대 3D 직경 및 표면적: 이러한 형태적 특징의 수치 값은 파킨슨병 환자군에서 더 작게 나타나는데, 이는 신경세포 및 기타 뇌세포의 손실로 인한 뇌 구조의 위축을 나타내며, 결과적으로 피질하 영역의 기능 및 구조적 완전성이 저하되었음을 의미합니다. 전구기 환자군의 중간 값은 초기 구조적 변화를 시사합니다. 대조군은 가장 유의미한 차이를 나타내며, 훨씬 더 큰 수치 값을 보여 건강한 뇌 형태를 반영합니다.

b) 중앙값, 90번째 백분위수, 범위 등의 1차 통계적 특징: 이러한 특징들은 복셀 강도의 분포를 나타내며, 평균값은 대조군 1.1, 전구기군 0.4, 파킨슨병군 0.1입니다. 파킨슨병군의 이러한 특징 값이 낮다는 것은 흑질(SN)에서 강도 감소 및 잠재적인 신경세포 손실을 시사합니다. 전구기 환자들은 중간값을 보여 초기 변화를 암시합니다. 대조군은 높은 값을 보여 다양하고 건강한 조직 강도를 나타냅니다. c) 피질하 영역의 질감 분석: 특징은 화색조 크기 영역 행렬(GLSZM)과 인접 화색조 차이 행렬(NGTDM)에서 추출됩니다. NGTDM에서는 활성도, 실행 분산, 정규화된 화색조 불균일도와 같은 주요 특징이 추출되며, 이는 피질하 영역의 질감 변화를 나타냅니다. 파킨슨병(PD) 그룹에서는 엔트로피 값이 낮고 최대 확률 값이 높을수록 구조가 덜 복잡하고 더 균일하여 퇴행성 변화를 나타냅니다. 전구기 그룹은 중간값을 보여 변화가 시작되었음을 시사합니다. 대조군에서는 엔트로피 값이 높고 최대 확률 값이 낮은 특징들이 복잡하고 건강한 조직 구조를 나타냅니다.

d) 배경 크기와 관련된 텍스처 매개변수: 화색조 동시 발생 행렬(GLCM)의 엔트로피, 최대 확률, GLSZM 특징과 같은 특징은 텍스처의 이질성을 나타냅니다. 엔트로피가 높을수록 텍스처의 이질성이 더 크다는 것을 의미합니다.




표 8
선택된 특징들에 대한 통계적 분석.

선택된 기능	PD	전구 증상	제어	p값	중요한
최대 2D 직경 기둥(형태)	0.33 ± 0.07	0.54 ± 0.56	1.09 ± 1.63	1.17	진실
최대2D 직경 행(모양)	0.31 ± 0.13	0.84 ± 0.40	1.12 ± 1.56	6.07	진실
최대2D 직경 슬라이스(모양)	0.33 ± 0.09	0.82 ± 0.09	1.03 ± 1.60	2.75	진실
최대 3D 직경(모양)	0.32 ± 0.07	0.53 ± 0.06	1.06 ± 1.57	3.55	진실
표면적(모양)	0.07 ± 0.72	0.85 ± 0.76	0.89 ± 1.12	6.16	진실
90백분위수(1차)	0.15 ± 0.18	0.45 ± 0.19	1.13 ± 0.15	9.58	진실
중앙값(1차)	0.13 ± 1.85	0.30 ± 0.16	1.18 ± 0.16	9.19	진실
범위(1차)	0.14 ± 1.84	0.30 ± 0.28	1.19 ± 0.19	3.73	진실
차이 엔트로피(gldcm)	0.19 ± 0.86	0.23 ± 0.78	1.04 ± 0.77	3.89	진실
IDN(gldcm)	0.21±1.09	0.41±1.10	0.68 ± 1.03	8.64	진실
결합 엔트로피(gldcm)	0.13 ± 0.63	0.55 ± 0.71	1.04 ± 1.06	1.88	진실
최대 확률(gldcm)	0.26 ± 0.71	-0.51 ± 0.54	1.24 ± 1.10	1.22	진실
의존성 엔트로피(gldm)	0.14 ± 0.79	0.37 ± 0.68	-0.68 ± 1.28	6.63	진실
회색 레벨 불균일성(gldm)	-0.06 ± 0.74	-0.21 ± 0.36	0.37 ± 1.18	1.08	진실
회색조 불균일성(gldrm)	-0.07 ± 0.71	-0.19 ± 0.37	0.33 ± 1.12	2.82	진실
회색조 불균일성 정규화(gldrm)	-0.11 ± 0.92	-0.47 ± 0.66	0.87 ± 1.05	2.82	진실
실행 분산(gldrm)	0.06 ± 1.12	0.22 ± 0.73	0.40 ± 1.29	3.82	진실
회색조 불균일성 정규화 (글스즈)	0.19 ± 0.89	0.43 ± 0.66	0.75 ± 0.94	4.04	진실
영역 엔트로피(glszm)	0.12 ± 0.87	-0.3 ± 0.68	0.62 ± 1.31	1.36	진실
바탕 (ngtdm)	-0.09 ± 0.73	-0.23 ± 0.53	0.45 ± 1.14	2.25	진실

배경의 복잡성; 최대 확률 특징은 인접 픽셀 간의 부정적 균일성을 나타내며, 이는 병리학적 상태를 의미합니다.
변화. GLSZM 값이 높을수록 유사성이 낮고 변화가 더 많다는 것을 의미합니다. 질감의 이질성.

표 9는 비교 분석의 결과를 제시합니다.
다양한 머신러닝 모델을 활용한 파킨슨병 진단에 대한 최근 연구 개요입니다.
제안된 방법이 방법론적 측면에서 최첨단 기술과 비교하여 상당한 개선점을 가지고 있음을 강조합니다.
최근 정확도를 평가했습니다. 본 연구에서는 다양한 XAI를 평가했습니다.
SHAP, LIME, SHAPASH를 포함한 여러 방법을 사용하여 다음과 같은 사실을 확인했습니다.
GB 모델은 가장 신뢰할 수 있고 임상적으로 수용 가능한 결정을 제공했습니다. XAI 방법의 통합은 그 중요성을 강조했습니다.
GLCM 기능, 특히 "차이 엔트로피" 기능을 살펴보면 다음과 같습니다.
GB 분류의 핵심 예측 변수입니다. 이러한 접근 방식을 통해 저희 모델은 다음과 같은 이점을 얻을 수 있었습니다.
정확하고 해석 가능한 결과를 도출하는 것이 중요합니다.
실제 의료 응용 분야.

5.2. 한계점 및 경영적 시사점

본 연구는 XAI 기술의 활용을 목표로 한다.

표 9
기존 파킨슨병 진단 방법과 본 논문에서 제안하는 방법의 비교.

참조 그리고 년	데이터셋 세부 사항	양식	방법론	지역 관심	연구 결과	주요 관찰 사항
[9], 2020	203-HC 66- 전구 증상 637-PD	MRI	인공신경망(다층 퍼셉트론), 방사선영상학 특징 추출, 5겹 교차 검증	피질하 지역	93.10% 정확도, 95.41% 재현율 97.28%, 정밀도, 94% - F1 점수	장점: 높은 정확도 및 정도 단점: 부족함 설명 가능성
[29], 2023	36-HC 47-PD	MRI	SVM 및 RF, 10겹 교차 검증 방사선영상 특징, 사용자 정의 모델, 75% 훈련, 테스트의 25%	SN 지역	83.33% 정확도	장점: 간단한 모델, 더 쉬운 해석 단점: 정확도가 낮음
[53], 2023	57-PD 74-MSA 70-HC	MRI 및 SWI 스캔	두 스캔에서 얻은 2640개의 방사선영상 특징, MSA와 PD 간의 LGBM 차이점 또한 MSA, PD 및 HC와 마찬가지로 5겹 교차 검증	피질하 지역	MSA vs PS vs HC - 81.4%- 정확도, 88% - AUC XAI 기술(예: SHAP) 기능에 사용되는 값 중요성	장점: 결합 다양한 방식이 개선됩니다 정확성 단점: 더 복잡함 처리 필요
제안된 방법	180-PD 160- 전구 증상 160-HC	3D-MRI 스캔	GB + 톨 (LIME, SHAP, SHAPASH) 방사선영상 특징 추출, 2겹 특징 선택 방법, SMOTE, 통계 분석, 5겹 교차 검증, 훈련 데이터의 80%, 나머지 데이터의 20% 시험.	피질하 지역	96.8% 정확도, 97% 정밀도 94.2%, 재현율 94.2% 96.6% 특이도, 94.6% F1 점수	장점: 높은 정확도, 종합적인 분석, 향상된 해석 가능성 XAI를 통해 단점: 계산상 강한.

약어: SWI - 자기 감수성 가중 영상, ANN - 인공 신경망, LGBM - 광 경사 부스팅 머신, MSA - 다발성 시스템 위축증

S. Priyadharshini 외		알렉산드리아 공학 저널 107 (2024) 568–582	
의료진이 AI 시스템의 결정을 적절하게 활용하고 이해할 수 있도록 포괄적인 교육 프로그램을 제공 합니다.		검증, 형식 분석, 개념화. S. Venkatesh: 검증, 방법론, 조사, 데이터 관리. Rengarajan Amir-tharajan: 원고 검토 및 편집, 검증, 방법론, 조사. Ketan Kotecha: 감독, 소프트웨어, 자료, 자금 확보.	
본 연구에서 제안하는 프레임워크는 PPMI 데이터베이스의 실제 사례를 사용하여 개발 및 검증되었으며, 실제 임상 환경에서의 적용 가능성을 보장합니다. 예측 전략 개발에 사용된 MRI 영상 및 데이터는 환자로부터 얻은 것으로, 연구 결과가 실제 임상 환경을 반영함을 보여줍니다. 또한, 실제 임상 환경에서 제안된 알고리즘의 성능을 더욱 검증하기 위해, 연구진은 소속 대학을 통해 주요 병원들과 협력 관계를 구축하는 데 주력하고 있습니다. 이러한 노력을 통해 본 연구 결과가 향후 연구 및 응용 분야에 활용될 수 있도록 할 것입니다. 본 프레임워크는 질병 진행을 정확하게 예측하지만, XAI를 활용한 신뢰성에도 불구하고 임상 의와 환자 모두에게 더욱 사용자 친화적인 인터페이스가 필요합니다. 파킨슨병은 후기에 갈수록 관리가 어려워지기 때문에 조기에 정확하게 진단하는 것이 매우 중요합니다. 향후 연구에서는 대규모 언어 모델(LLM)과 같은 제안 모델을 개발하여 진단 전략을 개선하고 환자에게 맞춤형 지침을 제공하는 데 집중해야 합니다. 또한, 모델의 일반화 특성을 확인하기 위해 더 많은 임상 검증을 거쳐야 합니다. 이와 관련하여 저자들은 소속 대학을 통해 병원들과 협력 관계를 구축하여 이 과정을 촉진하고자 노력하고 있습니다.		이해 충돌 신고	
		저자들은 본 논문에 보고된 연구 결과에 영향을 미칠 수 있는 어떠한 경쟁적인 재정적 이해관계나 개인적인 관계가 없음을 밝힙니다.	
		데이터 가용성	
		본 연구에 사용된 데이터는 공개 접근 데이터베이스인 파킨슨병 진행 표지자 이니셔티브(PPMI)에서 제공됩니다.	
		감사의 말씀	
		저자들은 본 연구에 재정적 지원을 제공해 주신 인도 과학기술부(DST) 산하 과학기술연구위원회(SERB)(CRG/2021/006697)와 연구 수행에 필요한 자원과 지원을 제공해 주신 인도 SASTRA 사립대학교에 감사를 표합니다. 본 연구는 인도 푸네 소재 Symbiosis International 사립대학교의 연구지원기금(RSF)의 지원을 받았습니다.	
6. 결론 및 향후 방향			
본 연구에서는 파킨슨병 초기 진단을 위한 XAI 통합 머신러닝 분류 모델 프레임워크를 개발했습니다. 이 프레임워크는 질병 예측 정확도를 향상시킬 뿐만 아니라, XAI 기술을 활용하여 예측 결과에 대한 통찰력을 제공하고 예측에 영향을 미치는 요인을 정확하게 파악함으로써 효과적인 진단 계획 수립을 지원합니다.			
본 연구에서는 파킨슨병(PD), 대조군, 전구기 환자군에서 추출한 500개의 실제 MRI 영상 데이터를 이용하여 6가지 머신러닝(ML) 알고리즘을 비교 분석했습니다. 제안된 프레임워크는 기존의 2D 슬라이스 방식 대신 3D 슬라이스를 사용하여 방사선학적 특징을 추출함으로써, 기존의 2D 방식에서 발생하는 정보 손실을 방지합니다. 추출된 특징들 중에서 각 군 간에 유의미한 차이를 보이는 상위 20개 특징을 2겹 교차 검증법을 통해 선별했습니다. 선별된 상위 20개 특징은 분산 분석(ANOVA, p값 < 0.05)을 통해 검증되었으며, 파킨슨병 단계를 구분하는 데 효과적임을 입증했습니다. GB 모델은 제공된 실제 데이터에서 다른 ML 알고리즘 대비 96.8%의 우수한 정확도를 달성했습니다. GB 모델에 XAI(확률 인공지능) 모델을 통합하여 예측 결과의 근거를 분석했습니다. 이러한 XAI 기법은 핵심적인 GLCM(일반화된 선형 모델) 특징(차이 엔트로피 및 결합 엔트로피)을 강조하여 모델의 해석 가능성을 높이고 임상 의의 파킨슨병 초기 진단에 도움을 줍니다. GLCM 특징은 뇌 조직 질감 저하를 나타내며 뇌 조직의 균일성과 구조적 변화에 대한 통찰력을 제공하는데, 이는 파킨슨병의 초기 진단에 매우 중요합니다. 본 연구는 XAI가 파킨슨병 진단 및 관리를 향상시켜 환자 예후를 개선할 수 있는 잠재력을 강조합니다. 또한 의료 전문가가 AI 정보를 효과적으로 활용할 수 있도록 맞춤형 교육 프로그램의 필요성을 강조합니다. 제안된 파킨슨병 진단 도구의 성능을 향상시키기 위해 향후 연구에서는 다중 모달 신경 영상 데이터셋의 적용 가능성을 탐색하고 딥러닝 및 강화 학습과 같은 고급 AI 기술을 활용하는 데 집중할 수 있습니다. 더 나아가, 향후 연구에서는 더 많은 바이오마커를 통합하고 XAI 기술을 적절히 수정하여 개인 맞춤형 파킨슨병 관리 및 환자 예후 개선을 위한 강력하고 임상적으로 적용 가능한 솔루션을 개발할 수 있습니다.		참고 자료	
		[1] W. Poewe, K. Seppi, CM Tanner, GM Halliday, P. Brundin, J. Volkmann, A.- E. Schrag, AE Lang, 파킨슨병, Nat. Rev. This. Prim. 3 (2017) 17013, https://doi.org/10.1038/nrdp.2017.13 .	
		[2] Z. Shu, P. Pang, X. Wu, S. Cui, Y. Xu, M. Zhang, 통합 노모그램 전뇌 MRI에서 얻은 비운동 증상 및 백질 기반 방사선학 바이오마커를 사용하여 초기 단계 파킨슨병을 식별합니다. Front. Aging Neurosci. 12 (2020) 1–15, https://doi.org/10.3389/fnagi.2020.548616 .	
		[3] F. Salawu, A. Danburam, A. Olokoba, 파킨슨병의 비운동 증상: 진단 및 관리, Niger. J. Med. 19 (2010) 126–131, https://doi.org/10.4314/njm.v19i2.56496 .	
		[4] W. Zeng, J. Cai, L. Zhang, Q. Peng, 파킨슨병의 철 침착: 미니 리뷰, Cell. Mol. Neurobiol. 44 (2024), https://doi.org/10.1007/s10571-024-01459-4 .	
		[5] L. Ma, M. Gholam Azad, M. Dharmasivam, V. Richardson, RJ Quinn, Y. Feng, D. L. Pountney, KF Tonissen, GD Mellick, I. Yanatori, DR Richardson, 파킨슨병: 치료 전략을 밝히는 열쇠로서의 철 및 산화환원 생물학의 변화, Redox Biol. 41 (2021), https://doi.org/10.1016/j.redox.2021.101896 .	
		[6] H.-M. Zeng, H.-B. Han, Q.-F. Zhang, H. Bai, 알츠하이머병의 진단 및 연구에 있어서 현대 신경영상 기술의 응용, 신경 재생 연구 16(2021) 73, https://doi.org/10.4103/1673-5374.286957 .	
		[7] T. Mortezaazadeh, H. Seyedarabi, B. Mahmoudian, JP Islamian, 이미징 파킨슨병의 감별 진단에서의 양식: 기하와 과제, 이집트. J. Radiol. Nucl. Med. 52 (2021), https://doi.org/10.1186/s43055-021-00454-9 .	
		[8] N. Tambasco, F. Paolini Paoletti, A. Chiappiniello, V. Lisetti, P. Nigro, P. Eusebi, P. Chiarini, M. Romoli, E. Brahimi, S. Simoni, M. Filidei, P. Floridi, R. Tarducci, L. Parnetti, P. Calabresi, T2* 가중 MRI 값은 다음에서 운동 및 인지 기능 장애와 상관관계가 있습니다. 파킨슨병, 뉴로바이올. 80세(2019) 91–98, https://doi.org/10.1016/j.neurobiolaging.2019.04.005 .	
		[9] S. Chakraborty, S. Aich, H.-C. Kim, 인공 신경망을 이용한 파킨슨병 진단을 위한 3T MRI 스캔에서 관심 있는 복셀의 3D 텍스처, 형태학적 및 통계적 분석, Healthcare 8 (2020) 34, https://doi.org/10.3390/healthcare8010034 .	
		[10] M. Obayya, MK Saeed, M. Maashi, SS Alotaibi, AS Salama, MA Hamza, 심층 학습 및 EEG를 이용한 새로운 자동화된 파킨슨병 식별 접근법, PeerJ Comput. Sci. 9 (2023), https://doi.org/10.7717/peerj-cs.1663 .	
		[11] MA 이슬람, MZ Hasan Majumder, MA Hussein, KM Hossain, MS Miah, 필기 및 음성 데이터셋을 이용한 파킨슨병 탐지를 위한 기계 학습 및 딥러닝 알고리즘 검토, Heliyon 10 (2024) e25469, https://doi.org/10.1016/j.heliyon.2024.e25469 .	
		[12] S. Sivaranjini, CM Sujatha, 다중 아틀라스 기반 분할을 사용하여 파킨슨병의 인지 기능 장애 평가를 위한 파질하 구조의 형태학적 분석, Cogn. Neurodyn 15 (2021) 835–845, https://doi.org/10.1007/s11571-021-09671-4 .	
		[13] B. Garcia Santa Cruz, A. Husch, F. Hertel, 뇌영상을 이용한 파킨슨병 진단 및 예후를 위한 기계 학습 모델: 일반 개요, 주요 과제 및 향후 방향, Front. Aging Neurosci. 15 (2023), https://doi.org/10.3389/fnagi.2023.1216163 .	

S. Priyadharshini 외

[14] A. Schrag, N. Quinn, 1 파킨슨병의 임상 진단은 얼마나 유효한가, (2002) 529–534.

[15] E. Tolosa, A. Garrido, SW Scholz, W. Poewe, MD Unit, N. Service, U. De Barcelona, 파킨슨병 진단의 어려움, 20(2022) 385–397. [https://doi.org/10.1016/S1474-4422\(21\)00030-2](https://doi.org/10.1016/S1474-4422(21)00030-2).Challenges.

[16] KY Yamashita, S. Bhoopatiraju, BD Silvergate, GT Grossberg, 파킨슨병의 바이오마커: 최신 연구 현황, Biomark. Neuropsychiatry 9 (2023), <https://doi.org/10.1016/j.bionps.2023.100074>.

[17] A. Govindu, S. Palwe, 기계를 이용한 파킨슨병의 조기 발견 학습, 프로세디아 컴퓨팅. 과학. 218 (2022) 249–261, <https://doi.org/10.1016/j.procs.2023.01.007>.

[18] PR Magesh, RD Myloth, RJ Tom, DaTSCAN 이미지에 LIME를 사용한 파킨슨병 조기 발견을 위한 설명 가능한 기계 학습 모델, Comput. Biol. 메드. 126(2020) 104041, <https://doi.org/10.1016/j.combiomed.2020.104041>.

[19] HJ Yoon, K. Cho, WG Kim, YJ Jeong, JE Jeong, DY Kang, 파킨슨병 진단을 위한 F-18 FP-CIT 뇌 PET 영상의 전역적 및 질병적 특징 분석을 통한 이상성, Med. (US) 100 (2021) E26961, <https://doi.org/10.1097/MD.00000000000026961>.

[20] T. Pianpanit, S. Lolak, P. Sawangjai, T. Sudhawiengkul, T. Wilaiprasitporn, SPECT 이미지와 해석 가능한 AI를 이용한 파킨슨병 인식: 튜토리얼, IEEE Sens. J. 21 (2021) 22304–22316, <https://doi.org/10.1109/JSEN.2021.3077949>.

[21] D. Shi, X. Yao, Y. Li, H. Zhang, G. Wang, S. Wang, K. Ren, 관심 영역 및 휴식 상태 기능적 자기공명영상 기반 방사선학 접근법을 사용한 파킨슨병 분류, Brain Imaging Behav. 16(2022) 2150–2163, <https://doi.org/10.1007/s11682-022-00685-y>.

[22] N. Islam, MSA Turza, SI Fahim, RM Rahman, 고급 파킨슨병 탐지: 임상 평가 및 신경영상 샘플을 활용하는 포괄적인 인공지능 접근법, Int. J. Cogn. Comput. Eng. 5 (2024) 199–220, <https://doi.org/10.1016/j.ijcce.2024.05.001>.

[23] H. Zhai, W. Fan, Y. Xiao, Z. Zhu, Y. Ding, C. He, W. Zhang, Y. Xu, Y. Zhang, 파킨슨병의 화백질 구조의 복셀 기반 형태 측정(wearing-off 포함), Brain Imaging Behav. 17(2023) 725–737, <https://doi.org/10.1007/s11682-023-00793-3>.

[24] W. Yang, X. Bai, X. Guan, C. Zhou, T. Guo, J. Wu, X. Xu, M. Zhang, B. Zhang, J. Pu, J. Tian, 파킨슨병에서 피질핵의 종방향 부피 및 모양 변화, Sci. Rep. 14(2024) 1–9, <https://doi.org/10.1038/s41598-024-58187-4>.

[25] MR Salmanpour, M. Shamsaei, A. Rahmim, 파킨슨병의 하위 유형을 최적으로 식별하고 예측하기 위한 특징 선택 및 기계 학습 방법, Comput. Methods Prog. Biomed. 206(2021) 106131, <https://doi.org/10.1016/j.cmpb.2021.106131>.

[26] DA 모랄레스, Y. Vives-Gilabert, B. Gomez-Ans, E. 베고예체아, P. 라라나가, C. Bielza, J. Pagonabarraga, J. Kulisevsky, I. Corcuera-Solano, M. Delfino, 베이저안 네트워크 분류기를 이용한 파킨슨병에서의 치매 발생 예측, Psychiatry Res. Neuroimaging 213 (2013) 92–98, <https://doi.org/10.1016/j.pscychresns.2012.06.001>.

[27] H.-L. Chen, C.-C. Huang, X.-G. Yu, X. Xu, X. Sun, G. Wang, S.-J. Wang, 파지 c-최고인것 접근법을 이용한 파킨슨병 탐지를 위한 효율적인 진단 시스템, Expert Syst. Appl. 40 (2013) 263–271, <https://doi.org/10.1016/j.eswa.2012.07.014>.

[28] N. Betrouni, C. Moreau, AS Rolland, N. Carrière, M. Chapin, G. Kuchcinski, R. Lopes, R. Viard, L. Defebvre, D. Devos, 구조적 영상에서 얻은 질감 기반 마커는 파킨슨병의 운동 장애와 상관관계가 있다, Sci. Rep. 11 (2021) 1–10, <https://doi.org/10.1038/s41598-021-81209-4>.

[29] S. Gore, A. Dhole, S. Kumbhar, J. Jagtap, A. Thakare, S. Gudadhe, 고급 텍스트 기반 바이오마커를 사용한 파킨슨병 분류를 위한 방사선학, MethodsX 11 (2023) 102359, <https://doi.org/10.1016/j.mex.2023.102359>.

[30] P. Lambin, E. Rios-Velazquez, R. Leijenaar, S. Carvalho, RGPM Van Stiphout, P. Granton, CML Zegers, R. Gillies, R. Boellard, A. Dekker, HJWL Aerts, Radiomics: 고급 기능 분석을 사용하여 의료 이미지에서 더 많은 정보 추출, Ecedur. J. Cancer 48 (2012) 441–446, <https://doi.org/10.1016/j.소유자.2011.11.036>.

[31] P. Tupe-Waghmare, A. Rajan, S. Prasad, J. Saini, PK Pal, M. Ingalhalikar, 임상적인 T1 강조 MRI의 방사선학은 파킨슨병을 다계통 위축증 및 진행성 핵상마비와 구분할 수 있습니다. Eur. Radiol. 31 (2021) 8218–8227, <https://doi.org/10.1007/s00330-021-07979-7>.

[32] Z. Yu, K. Wang, Z. Wan, S. Xie, Z. Lv, 질병 예측을 위한 인기 있는 딥러닝 알고리즘: 리뷰, Clust. Comput. 26(2023) 1231–1251, <https://doi.org/10.1007/s10586-022-03707-y>.

[33] M. Camacho, M. Wilms, P. Mouches, H. Almgren, R. Souza, R. Camicioli, Z. Ismail, O. Monchi, ND Forkert, 대규모 다기관 T1 가중 MRI 데이터베이스에서 훈련된 딥러닝을 사용한 파킨슨병의 설명 가능한 분류, NeuroImage Clin. 38 (2023) 103405, <https://doi.org/10.1016/j.nicl.2023.103405>.

[34] M. Nazari, A. Kluge, I. Apostolova, S. Klutmann, S. Kimiaei, M. Schroeder, R. Buchert, 임상적으로 불확실한 파킨슨병 증후군 진단에서 도파민 수송체 SPECT의 자동 분류를 위한 합성 신경망의 수용도를 향상시키기 위한 설명 가능한 AI, Eur. J. Nucl. Med. Mol. Imaging 49 (2022) 1176–1186, <https://doi.org/10.1007/s00259-021-05569-9>.

[35] JJ Bouza, C.-H. Yang, D. Vaillancourt, BC Vemuri, MVC-Net: 응용 프로그램을 포함한 매니폴드 값 이미지용 컨볼루션 신경망 아키텍처, (2020). <http://arxiv.org/abs/2003.01234>.

[36] X. Li, PS Morgan, J. Ashburner, J. Smith, C. Rorden, 첫 번째 단계는 신경영상 데이터 분석: DICOM에서 NIfTI로의 변환, J. Neurosci. Methods 264 (2016) 47–56, <https://doi.org/10.1016/j.jneumeth.2016.03.001>.

[37] SM Smith, 빠르고 견고한 자동 뇌 추출, Hum. Brain Mapp. 17 (2002) 143–155, <https://doi.org/10.1002/hbm.10062>.

[38] Y. Xiao, V. Fonov, MM Chakravarty, S. Beriault, F. Al Subaie, A. Sadikot, G. B. Pike, G. Bertrand, DL Collins, 파킨슨병 코호트의 다중 대비 인구 평균 뇌 MRI 아틀라스 데이터 세트, Data Br. 12 (2017) 370–379, <https://doi.org/10.1016/j.dib.2017.04.013>.

[39] LJ Isaksson, S. Raimondi, F. Botta, M. Pepa, S.G. Gugliandolo, S.P. De Angelis, G. Marvaso, G. Petralia, O. De Cobelli, S. Gandini, M. Cremonesi, F. Cattani, P. Summers, B.A. Jereczek-Fossa, 전립선암 방사선학에서 MRI 이미지 정규화 기술의 효과, Phys. 메드. 71 (2020) 7–13, <https://doi.org/10.1016/j.ejmp.2020.02.007>.

[40] NJ Tustison, BB Avants, PA Cook, Yuanjie Zheng, A. Egan, PA Yushkevich, J. C. Gee, N4ITK: 개선된 N3 바이어스 보정, IEEE Trans. Med. Imaging 29 (2010) 1310–1320, <https://doi.org/10.1109/TMI.2010.2046908>.

[41] J. Li, Y. Zhang, Z. Huang, Y. Jiang, Z. Ren, D. Liu, J. Zhang, R. La Piana, Y. Chen, 파킨슨병의 운동 하위 유형에서 나타나는 피질 및 피질하 형태학적 변화, Npj Park. Dis. 8 (2022) 167, <https://doi.org/10.1038/s41531-022-00435-3>.

[42] CJ 박, J. 엄, KS 박, YW 박, SJ 정, YJ 김, SS 안, J. 김, P. H. Lee, YH Sohn, S.-K. Lee, 파킨슨병에서 치매 전환을 예측하기 위한 해석 가능한 다변수 가져책 방사선학 모델, Npj Park. Dis. 9 (2023) 127, <https://doi.org/10.1038/s41531-023-00566-1>.

[43] J.-H. Deng, H.-W. Zhang, X.-L. Liu, H.-Z. Deng, F. Lin, 자기공명영상에 기반한 파킨슨병의 형태학적 변화: 피질하 구조 분할 및 형태 분석에 대한 마니 리뷰, World J. Psychiatry 12 (2022) 1356–1366, <https://doi.org/10.5498/wjpw.v12.i12.1356>.

[44] Y. Wu, J.-H. Jiang, L. Chen, J.-Y. Lu, J.-J. Ge, F.-T. Liu, J.-T. Yu, W. Lin, C.-T. Zuo, J. Wang, 방사선학적 특징과 서포트 벡터 머신을 사용하여 파킨슨병 환자 및 정상 대조군을 구별함, Ann. Transl. Med. 7 (2019), <https://doi.org/10.21037/atm.2019.11.26>.

[45] NV Chawla, KW Bowyer, LO 홀, WP Kegelmeyer, SMOTE: 합성 소수 오버샘플링 기법, J. Artif. Intell. Res. 16 (2002) 321–357, <https://doi.org/10.1613/jair.953>.

[46] S. Lundberg, S.-I. Lee, 모델 예측 해석에 대한 통합적 접근 방식, Adv. 신경 정보 처리 시스템 2017-12월 (2017) 4766–4775, <http://arxiv.org/abs/1705.07874>.

[47] M. Ribeiro, S. Singh, C. Guestrin, “왜 당신을 신뢰해야 합니까?": 모든 분류기의 예측 설명, 2016년 북미 지부 협회 회의록. Comput. Linguist. Demonstr., Association for Computational Linguistics, Stroudsburg, PA, USA, 2016: pp. 97–101. <https://doi.org/10.18653/v1/N16-3020>.

[48] SJ Chung, HS Lee, HS Yoo, YH Lee, PH Lee, YH Sohn, 초기 파킨슨병의 선조체 도파민 고갈 패턴: 예후적 관련성, Neurology 95 (2020) E280–E290, <https://doi.org/10.1212/WNL.0000000000009878>.

[49] LI Wallis, MNJ Paley, JM Graham, RA Grünewald, EL Wignall, HM Joy, P. D. Griffiths, 파킨슨병에서 가져책 절반 침착에 대한 MRI 평가, J. Magn. Reson. Imaging 28 (2008) 1061–1067, <https://doi.org/10.1002/jmri.21563>.

[50] D. Molina, J. Perez-Beteta, A. Martínez-González, J. Martino, C. Velásquez, E. Arana, VM Pérez-García, 자기공명영상에서 얻은 뇌종양 이상성 측정에 대한 회색 레벨 및 공간 이산화의 영향, Comput. Biol. Med. 78 (2016) 49–57, <https://doi.org/10.1016/j.combiomed.2016.09.011>.

[51] NY Shin, M. Bang, SW Yoo, JS Kim, E. Yun, U. Yoon, K. Han, KJ Ahn, SK Lee, MRI에서 얻은 피질 두께를 이용한 파킨슨병의 경도 인지 장애에서 치매로의 전환 예측: 기계 학습 기반 모델, Radiology 300(2021) 390, <https://doi.org/10.1148/radiol.2021203383>.

[52] NJ Tustison, J. Gee, 텍스트 분석을 위한 런 길어 행렬, Insight J. 1 (2022) 1–6, <https://doi.org/10.54294/ex0itu>.

[53] S. Bu, H. Pang, X. Li, M. Zhao, J. Wang, Y. Liu, H. Yu, 특발성 파킨슨병과 다발성 시스템 위축증의 감별 진단을 위한 기존 T1 가중 영상 및 자기 감수성 가중 영상의 다중 매개변수 방사선학, BMC Med. 이미지 23(2023) 1–10, <https://doi.org/10.1186/s12880-023-01169-1>.

[54] G. Balakrishnan, A. Zhao, MR Sabuncu, J. Guttat, AV Dalca, VoxelMorph: a 변형 가능한 의료 영상 정합을 위한 학습 프레임워크, IEEE Trans. Med. 이미지 38(2019) 1788–1800, <https://doi.org/10.1109/TMI.2019.2897538>.

582