

접수일: 2023년 10월 12일, 승인일: 2023년 11월 1일, 출판일: 2023년 11월 7일, 최종 수정일: 2023년 11월 14일.

디지털 객체 식별자 10.1109/ACCESS.2023.3330919

RESEARCH ARTICLE

뇌암 등급 및 분류를 위한 진화 모델

파이잔 올라1

(IEEE 회원) 무함마드 나딤

무함마드 아브라르 4

ID2

, (IEEE 회원), FARHAN AMIN 3

압둘 살람

ID

(IEEE 회원), AMERAH ALABRAH5

그리고 후세인 알살만

ID6

(IEEE 회원)

1국제이슬람대학교 컴퓨터공학과, 이슬라마바드 4400, 파키스탄

2파키스탄 Charsadda 24420 Bacha Khan University 컴퓨터 과학과

3영남대학교 정보통신공학과, 경산 38541, 대한민국

4압둘 왈리 칸 대학교 컴퓨터 과학과, 마르단 23200, 파키스탄

5정보시스템학과, 컴퓨터정보과학대학, 킹사우드대학교, 리아드 11543, 사우디아라비아

6킹사우드대학교 컴퓨터정보과학대학 컴퓨터과학과, 리아드 11543, 사우디아라비아

교신저자: Farhan Amin(farhanamin10@hotmail.com) 및 Amerah Alabrah(aalobrah@ksu.edu.sa)

본 연구는 사우디아라비아 리아드에 위치한 킹 사우드 대학교의 연구자 지원 프로젝트(RSP2023R244)의 지원을 받아 수행되었습니다.

● **요약:** 뇌암은 전 세계 수백만 명의 삶에 영향을 미치는 위험한 질병입니다. 뇌암 진단을 받은 환자의 약 70%가 사망합니다. 머신러닝은 이 분야에서 유망한 최신 기술이지만, 관련 연구는 아직 매우 제한적입니다. 따라서 본 연구에서는 자기공명영상(MRI) 분석을 기반으로 뇌암을 탐지하고 분류하는 진화적 경량 모델을 제안합니다. 제안된 모델은 경량 앙상블 결합(가중 평균 및 경량 결합 다중 XGBoost 결정 트리)으로 명명되었으며, 최근 개발된 다중 경량 XGBoost를 수정하여 구현되었습니다. 본 연구에서는 MRI 데이터의 전처리 및 특징 추출(강도, 질감, 형태)을 고려하여 예측 설명력을 향상시켰습니다. 진화적 모델은 데이터 준비, 주요 특징 추출, 그리고 앙상블 분류라는 특수한 분류 기법을 이용한 특징 결합의 여러 단계를 거칩니다. BraTS 2020 데이터셋을 사용하여 제안된 모델의 성능을 평가했습니다. 본 데이터셋은 신경교종으로 진단받은 환자 285명의 MRI 영상으로 구성되어 있습니다. 시뮬레이션 결과, 제안된 모델은 93.0%의 정확도, 0.94의 정밀도, 0.93의 재현율, 0.94의 F1 점수, 그리고 0.984의 ROC 곡선 아래 면적(AUC-ROC) 값을 달성했습니다. 이러한 효율적인 결과는 제안된 모델이 4단계 등급 분류를 이용한 뇌종양 등급 분류에 효과적임을 보여줍니다. 또한, 본 모델은 뇌종양의 조기 진단 및 효과적인 치료 계획 수립에 유용한 도구로서의 잠재력을 지니고 있음을 시사합니다. 마지막으로, 제안된 모델은 암의 조기 진단 및 치료에 기여할 가능성을 제시합니다.

● **색인 용어:** 질병 분류, 뇌암, 기계 학습.

I. 서론

뇌암은 전 세계적으로 심각한 건강 문제이며, 암 관련 사망의 주요 원인 중 하나입니다. 미국 뇌종양 협회(ABTA)는 미국에서만 약 70만 명이 뇌종양을 앓고 있다고 보고했습니다.

본 원고의 검토를 총괄하는 부편집자는 다음과 같습니다.

출판을 승인한 사람은 탕이밍이었다.

뇌종양은 매년 약 88,000건의 새로운 사례가 진단되는 등 많은 사람들에게 질병을 유발합니다 [1]. 뇌종양 발병률이 증가함에 따라 환자의 예후를 개선하기 위해서는 시기적절하고 효과적인 진단과 치료가 필수적입니다. 뇌종양은 일반적으로 조직병리학적 특성에 따라 분류되며, 이는 종양의 등급과 예후에 영향을 미칩니다. 세계보건기구(WHO)는 표준화된 분류 체계인 국제질병분류(ICD)를 개발했습니다.

일반된 분류 방법의 필요성에 따라 진단 코드 시스템이 개발되었습니다. 국제적인 협력의 산물인 ICD-10은 질병 분류에 세 자리 숫자 코드를 사용합니다 [2]. 기존의 뇌종양 등급 분류 방법은 병리학자가 조직학적 특징을 수동으로 평가해야 하는데, 이는 시간이 많이 소요될 뿐만 아니라 주관적입니다 [3]. 이러한 접근 방식은 종종 관찰자 간 변동성이 높아져 일관성 없는 치료 결정과 잠재적으로 최적화되지 못한 환자 결과를 초래할 수 있습니다 [4].

객관적이고 자동화된 뇌종양 등급 분류 기술의 개발은 이러한 한계를 극복하는 데 매우 중요합니다. 머신러닝(ML) 기술은 의료 영상 분석 분야에서 강력한 도구로 부상했으며, 뇌종양 등급 분류에 있어 놀라운 잠재력을 보여주고 있습니다 [5], [6]. ML 알고리즘은 의료 영상에서 패턴과 특징을 자동으로 식별하여 보다 객관적이고 일관된 종양 등급 분류 및 분류를 가능하게 합니다. 또한, 이러한 알고리즘은 방대한 양의 데이터를 효율적으로 처리할 수 있어 확장성이 뛰어나 대규모 응용 분야에 적합합니다 [7].

보다 정확하고 일관된 등급을 제공함으로써 뇌종양 등급 분류 프로세스에 ML 알고리즘을 통합하면 환자 결과가 크게 개선될 수 있습니다 [8].

이를 통해 의료 전문가들은 개별화된 치료 계획을 수립하고 질병의 진행 상황을 더욱 정확하게 추적할 수 있습니다. 머신러닝(ML) 알고리즘을 활용하면 의료 영상을 수동으로 판독하고 분석하는 데 상당한 시간을 소모하는 병리학자와 영상의학과의 의사 업무 부담을 줄일 수 있습니다 [9]. 수년간 ML 기술은 의료 영상 분석에 혁명을 일으켜 다양한 질병의 더욱 정확하고 효율적인 진단, 치료 및 모니터링을 가능하게 했습니다 [10]. 임상 현장에서는 의료 영상 분석이 다양한 장기와 조직의 구조 및 기능에 대한 유용한 정보를 제공하기 때문에 매우 중요하게 활용됩니다. 지도 학습, 비지도 학습, 준지도 학습, 강화 학습 등 다양한 ML 방법이 의료 영상 분석에 사용되고 있습니다 [11]. 이러한 각 기술은 특정 작업에 맞춰 설계되었으며, 의료 영상 분석에서의 활용이 더욱 확대될 것으로 예상되어 환자 치료 결과 개선과 의료진의 업무 부담 경감에 기여할 것입니다. 본 연구는 특히 뇌종양 등급 분류를 중심으로 의료 영상 분석에 적용되는 머신러닝(ML) 기술에 대한 이해를 증진하는 것을 목표로 합니다. ML 알고리즘을 활용하여 보다 정확하고 일관된 종양 등급 분류를 수행함으로써 궁극적으로 환자 예후 개선과 의료진의 업무 부담 경감에 기여할 수 있는 잠재적 이점을 강조합니다. ML 기술은 의료 영상 분석, 특히 뇌종양 분류 및 등급 분류 분야에서 혁신을 가져올 수 있는 엄청난 잠재력을 보여주고 있습니다. ML 알고리즘은 보다 정확하고 객관적이며 일관된 결과를 제공함으로써 환자 예후를 개선하고, 개인 맞춤형 치료 계획을 수립하며, 질병 진행 상황을 보다 효과적으로 모니터링할 수 있도록 지원합니다. 의료 영상 분석에 ML 기술이 지속적으로 도입됨에 따라, 이러한 기술들이 의료 영상 분석에 미치는 긍정적인 영향이 더욱 커질 것으로 기대됩니다.

머신러닝 기술의 발전은 환자 치료를 개선하고 의료진의 부담을 줄여줄 것입니다. 의료 영상 분석에 머신러닝 기술을 활용하는 사례는 지속적으로 증가하여 환자 치료 결과를 향상시키고 의료진의 부담을 경감시킬 것으로 예상됩니다.

본 연구는 뇌종양 등급을 정확하고 효율적으로 분류해야 할 필요성이 절실한 데서 비롯되었습니다. 머신러닝과 MRI 데이터의 다양한 특징을 활용하여 조기 진단 및 치료 계획을 개선하고, 궁극적으로 환자 치료 및 예후를 향상시키는 것을 목표로 합니다. 머신러닝 기반 뇌종양 등급 분류는 개인 맞춤형 치료 계획 수립에 유용하며, 질병 진행 경과를 예측하고 의료진의 부담을 줄이는 데에도 기여할 수 있습니다.

본 연구의 주요 기여는 다음과 같습니다. • 본 연구에서는 고급 머신러닝 모델을 이용하여 뇌암 관련 의료 영상을 탐지하는 진화적 뇌암 예측 방법을 제안했습니다. • 자기공명영상(MRI) 데이터의 전처리 및 특징 추출(강도, 질감, 형태)을 고려하여 예측 능력을 향상시켰습니다. • 제안된 모델인 경량 앙상블(가중 평균 및 경량화된 여러 XGBoost 결정 트리의 결합)은 기존의 멀티모달 경량 XGBoost를 개선한 것입니다. • 본 연구에 사용된 데이터셋은 여러 영상 모달리티를 이용하여 고종 환자의 MRI 스캔 285개로 구성되었으며, 종양 유무에 따라 1등급(종양 없음), 2등급, 3등급, 4등급으로 분류하여 분석한 결과 93%의 예측 정확도를 얻었습니다.

- 본 논문에서는 제안된 방법과 최첨단 기술을 비교하여 (강도, 질감 기반, 형태 기반 특징 추출 및 정확도 측면에서, 본 논문의 주요 초점인) 제안된 방법의 효과성을 더욱 부각시키고자 합니다.
- 제안된 모델 기반의 다중 그래디언트 부스팅 기법은 종양 탐지 정확도를 향상시키고 과적합을 제어하여 정확도를 개선합니다. 처리된 의료 영상은 뇌암 탐지에 활용되어 영상의학 과 전문의 및 관련 분야 전문가에게 유용한 도구를 제공합니다.

본 논문은 기존 방법론과 크게 차별화되는, 뇌암의 등급 분류 및 판별을 위한 획기적인 진화 모델을 제시합니다. 이 모델은 진화 알고리즘과 XGBoost(Extreme Gradient Boosting)를 새롭게 결합하여 특징 선택 및 분류 정확도를 향상시킵니다. 특히, AUC-ROC 곡선을 비롯한 고급 성능 지표를 활용하여 다양한 종양 등급에 걸쳐 모델의 효과를 보다 상세하게 평가할 수 있다는 점이 본 연구의 특징입니다. 또한, 본 연구는 더 광범위한 데이터셋을 포함함으로써 해당 분야에 크게 기여합니다.

영상 특징은 광범위한 교차 검증을 통해 검증되어 견고성과 일반화 가능성을 보장합니다. 의료 전문가와의 협력을 통해 진단 관행에 맞춰 개발된 이 모델은 암 치료 및 관리에 있어 정확도를 향상시키는 데 유용한 도구입니다.

본 논문의 나머지 부분은 다음과 같이 구성됩니다. 제 2 절에서는 연구 배경을 제시합니다. 제 3절에서는 제안하는 연구 방법론을 설명합니다. 제4 절에서는 연구 결과를 분석합니다. 제 5 절에서는 연구의 결론을 제시합니다.

## II. 문헌 고찰 뇌종양 등급 분류는 치료 계

획 수 및 질병 진행 모니터링에 중요한 정보를 제공하기 때문에 임상 진료에서 매우 중요한 과제입니다. 전통적으로 뇌종양 등급 분류는 종양의 조직학적 특징을 기반으로 병리학자가 수동으로 수행해 왔습니다 [12]. 뇌종양 분류는 효과적인 치료에 중요하지만, 수동적인 방법은 일관성이 부족할 수 있습니다.

환자의 치료 결과를 개선하기 위해서는 정확성과 일관성을 향상시키는 것이 필수적입니다. 최근 몇 년 동안, 머신러닝(ML) 접근법은 의료 영상을 입력 데이터로 활용하여 뇌종양 등급을 분류하는 데 유용한 방법으로 부상했습니다. ML 알고리즘은 의료 영상 패턴과 특징을 인식하여 정확하고 자동화된 종양 등급 분류를 가능하게 합니다 [13]. 다양한 연구에서 뇌종양 등급 분류에 ML 기법을 적용하는 것을 조사했으며, ML 기법이 등급을 효과적으로 구분할 수 있음을 확인했습니다. 뇌종양은 뇌의 여러 부위에서 발생할 수 있는 복잡하고 이질적인 종양입니다. 이러한 종양은 조직병리학 적 특징에 따라 등급을 매길 수 있으며, 1등급 종양이 가장 악성도가 낮고 4등급 종양이 가장 악성도가 높습니다.

뇌종양의 정확한 등급 분류는 가장 적절한 치료 접근법을 결정하고 환자의 예후를 예측하는 데 매우 중요합니다. 본 연구는 뇌종양 분류 정확도를 높이기 위한 머신러닝 모델 개발에 중점을 두었습니다. 일부 모델은 MRI 영상에서 추출한 질감, 모양, 강도와 같은 특징을 이용하여 뇌종양을 분류합니다.

이러한 특징들을 이용하여 합성곱 신경망(CNN)을 훈련시키고, 이를 통해 분류를 수행한다. 예를 들어, Akkus et al. [14] 은 CNN을 사용하여 교종을 저등급과 고등급 그룹으로 정확하게 분류했으며, 93.3%의 성공률을 보였다. Havaei et al. [15] 은 CNN을 사용하여 뇌종양을 4단계로 분류했으며, 89.4%의 전체 정확도를 달성했다. 주성분 분석(PCA)과 오토인코더 또한 뇌종양 등급 분류에 사용되었다. 예를 들어, Chen et al. [16]은 PCA를 사용하여 교종의 MRI 이미지를 분석하고 특징을 추출했으며, 저등급 교종에 대해 91.67%, 고등급 교종에 대해 95.83%의 정확도를 보였다. Ain et al. [17] 은 공동 훈련 알고리즘을 사용하여 신경교종을 저등급 및 고등급 범주로 분류하여 91.6%의 정확도를 달성했습니다. Ahuja et al. [18] 은 전이 학습을 사용하여 신경교종을 저등급 및 고등급 범주로 분류하여 94.75%의 정확도를 달성했습니다. Park et al. [19]

MRI 스캔을 기반으로 수막종의 등급을 예측하기 위해 수작업으로 추출한 특징을 사용했습니다. 이들은 강도, 질감, 모양과 관련된 특징을 추출하고 랜덤 포레스트(RF) 분류기를 사용하여 수막종 등급을 예측했습니다. 이 방법은 수막종 등급 예측에서 0.93의 정확도를 달성했습니다. 일부 연구에서는 뇌종양 등급 분류를 위해 MRI 외에도 다른 영상 모달리티에서 추출한 수작업 특징을 사용하는 것을 조사했습니다. Sollini 등 [20]은 교종 등급 예측을 위해 CT 스캔에서 추출한 수작업 특징을 사용했습니다. 이들은 모양, 질감, 강도와 관련된 특징을 추출하고 SVM 분류기를 사용하여 교종 등급을 예측했으며, 교종 등급 예측에서 0.89의 정확도를 달성했습니다. Kamnitsas 등 [21]은 MRI 스캔에서 자동 뇌종양 등급 분류 및 분할을 위해 3D CNN을 활용하여 92.7%의 정확도를 달성했습니다. 대규모 MRI 스캔 데이터 세트를 사용하여 제안된 모델은 다양한 종양 유형의 종양 등급 및 분할을 정확하게 예측할 수 있었습니다. Gull et al. [22] 은 딥러닝(DL) 접근 방식을 활용하여 악성 종양을 저등급 또는 고등급으로 분류했습니다. 암 영상 아카이브의 MRI 이미지 데이터 세트를 사용하여 분류 작업은 95.5%의 높은 정확도를 달성했습니다. Wasule 및 Sonar [23] 은

MRI에서 특징을 추출하기 위해 SVM과 KNN을 사용했습니다.

본 연구에서는 뇌종양을 4단계(I, II, III, IV)로 분류하기 위한 특징들을 제시합니다. 제안된 방법은 정답 레이블이 지정된 뇌 병변의 MRI 스캔을 포함하는 BraTS 2015 데이터셋을 활용합니다. 정확도, 정밀도(Pr), 재현율(Rec), F1 점수 측면에서 SVM 알고리즘이 우수한 성능을 보였습니다. Chen et al. [24]은 확산강조영상(DWI) 데이터를 사용하여 뇌종양 등급 분류에 대한 SVM, KNN, RF 알고리즘의 성능을 평가했습니다. SVM 알고리즘은 가장 높은 정확도와 F1 점수를, RF 알고리즘은 가장 높은 정밀도와 재현율을 보였습니다. Pan et al. [25] 은 MRI 데이터를 사용하여 뇌종양 등급 분류에 대한 SVM, KNN, CNN 알고리즘의 성능을 비교했습니다. 그들은 종양 등급에 대한 정답 레이블이 지정된 295개의 뇌종양 이미지 데이터셋을 사용했습니다. 그들은 CNN 알고리즘이 정확도, 정밀도, 재현율, F1 점수 측면에서 다른 알고리즘보다 우수한 성능을 보였다는 것을 발견했습니다. Chen et al. [26]은 종양 등급에 대한 정답 레이블이 있는 368개의 뇌종양 이미지 데이터셋을 사용하여 뇌종양 등급 분류를 위한 다양한 ML 알고리즘의 성능을 평가했습니다. 평가된 알고리즘은 SVM, KNN, DT, RF 및 CNN이었습니다. 그들은 CNN 알고리즘이 가장 높은 정확도, 정밀도, 재현율 및 F1 점수를 얻었고 그 다음으로 SVM 알고리즘이 뒤를 이었다고 밝혔습니다.

전반적으로, 이러한 연구들은 SVM, KNN, DT, RF, CNN과 같은 머신러닝 알고리즘이 표 1에서 보여주는 것처럼 뇌종양 등급 분류에 효과적일 수 있음을 시사합니다. 최적의 알고리즘 선택은 사용된 영상 데이터의 종류, 데이터셋의 크기, 그리고 알고리즘 평가에 사용된 특정 성능 지표에 따라 달라질 수 있습니다. 본 연구에서는 더 큰 규모의 뇌종양 영상 데이터셋을 사용하여 이러한 알고리즘들을 비교하고, 여러 성능 지표를 통해 성능을 평가하여 뇌종양 등급 분류에 가장 적합한 알고리즘을 선정했습니다.

표 1. 뇌종양 분류를 위한 기존 머신러닝 기법 요약.

| References         | Algorithms Compared | Imaging Data | Dataset Size | Performance Metrics |      |      |          |
|--------------------|---------------------|--------------|--------------|---------------------|------|------|----------|
|                    |                     |              |              | Acc                 | Pr.  | Rec  | F1-score |
| Wasule et al. [23] | SVM, KNN,           | MRI          | 60           | 93.0                | --   | --   | --       |
| Akkus et al. [14]  | SVM                 | MRI          | --           | 0.86                | 0.89 | 0.78 | --       |
| Chen et al. [24]   | RF, SVM, KNN, LDA.  | DWI          | --           | 90.0                | 89.0 | --   | --       |
| Li et al. [16]     | SVM, RF, LR         | MRI          | --           | 89.5                | 85.7 | 90.2 | --       |
| Havaei et al. [15] | 3D CNN              | MRI          | 285          | 83.5                | 81.0 | --   | --       |
| Pan et al. [25]    | SVM, KNN, CNN       | MRI          | 295          | --                  | --   | --   | --       |
| Ain et al. [17]    | CNN                 | MRI          | 150          | 93.7                | 92.5 | 94.8 | 93.6     |
| Park et al. [19]   | SVM                 | MRI          | 75           | 83.3                | 86.2 | --   | --       |
| Zhang et al. [26]  | KNN, DT, CNN, SVM   | MRI          | 368          | --                  | --   | --   | --       |
| Kouli et al. [27]  | ML                  | MRI          | 200          | --                  | --   | --   | --       |
| Gull et al. [22]   | CNN                 | MRI          | 153          | --                  | --   | --   | 95.5     |

III. 재료 및 방법

이 섹션에서는 뇌종양을 자동으로 등급화하는 시스템을 제안합니다. 다양한 유형의 정보와 XGBoost 기반의 간소화된 기법을 결합하여 사용합니다. 이 과정은 몇 단계로 이루어지는데, 먼저 데이터를 준비하고, 중요한 특징을 추출한 다음, 그림 1에 나타난 앙상블 분류라는 특수한 분류 기법을 사용하여 모든 정보를 종합합니다.

본 연구에 사용된 데이터는 2020년 멀티모달 뇌종양 분할 챌린지(BraTS)에서 수집되었습니다. BraTS 데이터셋은 누구나 자유롭게 연구할 수 있으며 뇌종양 분할의 기준 데이터셋으로 자주 사용됩니다. 이 데이터셋은 T1 강조 영상, T2 강조 영상, 조영 증강 T1 강조 영상, FLAIR 영상 등 다양한 영상 기법을 이용하여 교증 환자 285명의 MRI 스캔으로 구성되어 있습니다. 숙련된 영상의학 전문가들이 WHO 분류 체계에 따라 종양 등급을 꼼꼼하게 판독했습니다. 이후, 전체 데이터의 70%를 훈련 세트, 10%를 검증 세트, 20%를 테스트 세트로 나누었습니다.

그림 2는 BraTS 데이터셋의 MRI 샘플을 보여줍니다. T1 강조 영상, 조영 증강 영상, T2 강조 영상 및 FLAIR 시퀀스가 포함되어 있습니다.

스캔은 여러 영상으로 구성됩니다. T1 강조 영상은 종양과 뇌 조직을 대비시켜 보여줍니다. T1 강조 조영 증강 영상은 종양 혈관 분포에 대한 더 많은 정보를 제공합니다. T2 강조 영상과 FLAIR 영상은 종양 부종과 조직 침윤을 보여줍니다. 표 2는 BraTS 종양 등급 분포를 나타냅니다. 데이터 세트에는 2, 3, 4등급 종양과 비종양 조직이 포함됩니다. 고등급인 3등급과 4등급 종양은 저등급인 2등급 종양보다 예후가 더 나쁩니다. 비종양 영상은 모델이 뇌 조직과 종양 조직을 구분하는 데 도움을 줍니다.

표 2. BraTS 데이터 세트에서 종양 등급의 분포.

| Tumor Grade | Number of Scans |
|-------------|-----------------|
| Grade II    | 118             |
| Grade III   | 121             |
| Grade IV    | 46              |
| Non-tumor   | 0               |
| Total       | 285             |

데이터셋 품질 향상을 위해 두개골 제거, 강도 정규화 및 이미지 정합을 수행했습니다.




그림 1. 제안된 모델.




그림 2. BraTS에서 나타나는 다양한 뇌종양 영상.

두개골 제거술은 MRI에서 뇌 이외의 조직을 제거하는 과정입니다. 강도 정규화를 통해 모든 모달리티에서 스캔 강도 값이 일정하게 유지되도록 했습니다. 이미지 정합을 통해 다중 모달리티 스캔을 정렬했습니다. 데이터셋을 무작위로 훈련, 검증 및 테스트 세트로 분할했습니다. 훈련 세트는 머신러닝 모델을 학습하는 데 사용했고, 검증 세트는 적절한 하이퍼파라미터를 선택하는 데 사용했으며, 테스트 세트는 모델 성능을 평가하는 데 사용했습니다.

본 연구에서는 BraTS를 사용하여 데이터셋 준비 과정을 설명했습니다. 데이터셋의 종양 등급 및 품질 보증 측정 기준도 제시했습니다.

A. 전처리

전처리는 머신러닝 모델에 사용할 데이터를 준비하는 데 있어 매우 중요한 단계이며, 원시 데이터를 분석에 더 적합한 형식으로 변환하기 위한 여러 단계를 거치는 경우가 많습니다. MRI 스캔의 경우, 전처리는 일반적으로 뇌 이외의 조직을 제거하고, 이미지 강도를 조정하고, 이미지 크기를 조정하는 여러 단계를 포함합니다.

MRI 영상의 전처리 단계는 표 3에 나와 있습니다. MRI 영상 전처리의 첫 번째 단계는 일반적으로 영상 정합입니다. 이는 동일한 피사체 또는 여러 피사체의 여러 영상을 공통 좌표 공간에 정렬하는 과정입니다.

두개골 제거는 이미지에서 뇌 이외의 조직을 제거하는 작업입니다. 이 단계는 뇌 이외의 조직이 존재하면 분석의 정확도를 방해할 수 있기 때문에 필요합니다. 이 경우 두개골 제거를 위해 Brain Extraction Tool(BET) [28] 이 사용되었습니다.

표 3. MRI 영상의 전처리 단계.

| Preprocessing Step      | Method                        |
|-------------------------|-------------------------------|
| Image Registration      | Elastix library in Python     |
| Skull Stripping         | BET                           |
| Intensity Normalization | Z-score normalization method  |
| Resampling              | --                            |
|                         | Voxel size of 1mm x 1mm x 1mm |

마지막으로, 이미지 크기를 240 × 240 픽셀의 고정 크기로 조정했습니다. 이 단계는 이미지마다 크기가 다를 수 있기 때문에 필요하며, 크기 조정을 통해 일관성을 유지할 수 있습니다.

분석을 위해 이미지 크기를 표준화했습니다. 240 × 240 픽셀을 고정 크기로 선택한 것은 원본 이미지의 해상도와 분석에 사용 가능한 컴퓨팅 자원과 같은 요소를 기반으로 했을 수 있습니다. 이러한 전처리 단계는 MRI 스캔 이미지가 머신러닝 모델을 이용한 분석에 적합한 형식인지 확인하기 위해 필요했을 것입니다.

B. 특징 추출 및 선택

본 연구에서는 강도 기반 특징과 질감 기반 특징을 이용하여 MRI 영상에서 특징을 추출했습니다. MRI 영상에서 강도 기반 특징은 픽셀 강도 값을 수집하는 반면, 질감 기반 특징은 픽셀의 공간적 배열을 기록합니다.

추출된 특징 요약은 표 4에 나와 있습니다 .

표 4. 추출된 특징 요약.

| Feature Type    | Features Extracted                                                                      |
|-----------------|-----------------------------------------------------------------------------------------|
| Intensity-based | Mean, Standard Deviation, Skewness, and Kurtosis in different regions of the brain      |
| Texture-based   | Contrast, Energy, Homogeneity, and Entropy using Gray-Level Co-occurrence Matrix (GLCM) |
| Shape-based     | Area, Perimeter, Circularity, Solidity, and Eccentricity of tumor regions               |

강도 기반 특징은 MRI 영상 내 강도 값을 수학적으로 표현한 것입니다. 이러한 특징은 정상 뇌, 종양 또는 괴사 조직과 같은 다양한 유형의 조직에 해당하는 MRI 영상 내 특정 관심 영역(ROI)에서 계산되는 경우가 많습니다.

뇌종양 등급 분류를 위해 개발된 강도 기반 특징의 예로는 평균 강도, 표준 편차, 왜도, 첨도, 히스토그램 특징 및 질감 특징 등이 있습니다.

평균 강도는 ROI의 평균 강도를 계산합니다. 종양 조직은 정상 뇌 조직보다 평균 강도 값이 더 높습니다. 표준 편차는 ROI 강도의 변동을 계산합니다.

조직의 이질성은 고등급 암에서 흔히 나타납니다. 왜도와 첨도는 ROI 강도 분포를 평가합니다.



침도는 봉우리의 뾰족함 또는 평탄함을 평가하고, 왜도는 비대칭성을 측정합니다. 왜도와 침도가 높을수록 조직이 건강하지 않을 가능성이 있습니다.

$$\text{MRI 평균} = \left( \frac{1}{N} \right) \times \sum_{i=1}^{n=Li} \text{MRI 평균}$$

(1)

여기서 Li는 픽셀 i의 강도 값이고 n은 ROI 내의 전체 픽셀 수입니다.

$$SD = \left( \frac{1}{N} \right) \times \sum_{i=1}^N (Li - \text{MRI 평균})^2$$

(2)

여기서 n은 ROI의 픽셀이고, Li는 픽셀 i의 강도 값이며, mean은 ROI의 평균 강도 값입니다.

$$\text{왜곡도} = \left( \frac{1}{N} \right) \times \sum_{i=1}^N \frac{Li - \text{MRI 평균}}{SD}$$

(3)

여기서 n은 ROI의 픽셀 수, Li는 픽셀 i의 강도 값, mean은 ROI의 평균 강도 값, SD는 표준 편차입니다.

$$\text{엔트로피} = - \sum_{i=1}^L (pi \times \log_2(pi))$$

(4)

여기서 L은 ROI의 화색 레벨 수이고, pi는 화색 레벨 i가 발생할 확률이며, log2는 밑이 2인 로그입니다.

침도는 분포의 '뾰족함' 또는 '평탄함'을 나타내는 통계적 척도입니다. 침도는 MRI 영상 분석에서 뇌 영상의 특징을 파악하는 데 사용될 수 있습니다.

$$K = \frac{1}{N} \times \sum_{i=1}^N \frac{(xi - \bar{x})^4}{\dots}$$

(5)

여기서 K는 이미지의 침도, N은 복셀의 개수, Xi는 i번째 복셀의 강도, x̄는 이미지의 평균 강도입니다. 이미지 강도의 표준 편차는 시그마(σ)입니다.

히스토그램 특징은 ROI 내 강도 값의 히스토그램에서 추출됩니다. 히스토그램 특징의 예로는 특정 비율의 픽셀이 차지하는 강도 값을 측정하는 백분위수가 있습니다. 엔트로피는 강도 값의 무질서 정도를 측정합니다.

이러한 강도 기반 특징은 단독으로 또는 모양이나 질감 특징과 함께 사용하여 MRI 뇌종양 등급 분류를 개선할 수 있습니다. 또한 시간 경과에 따른 종양 특징 변화를 추적하여 치료 반응 및 환자 예후를 모니터링할 수 있습니다. 일반적으로 강도 기반 MRI 특징은 뇌종양 진단 및 치료를 향상시킵니다. 질감 기반 특징은 영상 처리 및 컴퓨터 비전에 사용됩니다. GLCM(Gray Level Coefficient Method)은 영상의 화색조 분포를 통계적으로 측정합니다. 이는 특정 화색조 값을 가진 픽셀 간의 공간적 연결을 평가하는 행렬을 생성하는 과정을 포함합니다. 질감 기반 특성은 영상의 질감을 나타냅니다. GLCM은 질감 기반 대비, 에너지, 균질성 및 엔트로피를 추출할 수 있습니다. 대비는 영상 픽셀 강도의 국소적 변동을 측정합니다. 균질성은 동일한 화색조 값을 가진 픽셀 간의 거리를 측정합니다.

에너지는 이미지 균일성을 평가하는 반면, 엔트로피는 이미지 무질서를 측정합니다.

$$\text{대조} = \sum_{i,j=0}^{n-1} (i - j)^2 \times p(i, j)$$

(6)

P(i,j)는 화색 레벨 i와 j를 갖는 픽셀 쌍의 발생 빈도를 정규화한 값이며, 여기서 i와 j는 인접한 두 픽셀의 화색 레벨 값입니다.

$$\text{에너지} = \sum_{i,j=0}^{n-1} p(i, j)^2$$

(7)

여기서 n은 이미지의 화색 레벨이고 P(i,j)는 i와 j를 갖는 픽셀 쌍의 정규화된 빈도입니다.

$$\text{동질성} = \sum_{i,j=0}^{n-1} \frac{p(i, j)}{1 + |i - j|}$$

(8)

여기서 N은 이미지의 화색 레벨 수이고, p(i,j)는 화색 레벨 i와 j를 갖는 픽셀 쌍의 정규화된 빈도이며, |ij|는 절대 차이입니다.

$$\text{엔트로피} = - \sum_{i,j=0}^{n-1} (p(i, j) \times \log_2(p(i, j) + \epsilon))$$

(9)

여기서 N은 이미지의 화색 레벨이고, P(i,j)는 화색 레벨 i와 j를 갖는 픽셀 쌍의 정규화된 빈도이며, 0의 확률 값에 대해 로그가 정의되지 않는 것을 방지하기 위해 작은 값이 추가됩니다. GLCM 기반 텍스처 특징은 향상된 정확도와 성능을 위한 유용한 정보를 제공함으로써 이미지 처리(분할, 인식, 분류)를 향상시킬 수 있습니다.

형태 기반 특징은 MRI 뇌종양 영상 분석에서 중요한 역할을 합니다. 이러한 특징은 종양 부위의 면적, 둘레, 원형도, 입체도, 편심률, 볼록도, 밀집도 및 대칭성과 같은 정량적 측정값을 제공합니다.

이러한 측정값은 뇌종양 유형을 구분하고, 종양 성장을 추적하며, 치료 결과를 평가하는 데 사용될 수 있습니다. 나아가 이러한 특징들은 머신러닝 알고리즘의 입력값으로 활용되어 뇌종양 진단 및 치료를 위한 예측 모델을 개발하는 데 사용될 수 있습니다. 수학적으로는 다음과 같이 표현할 수 있습니다.

$$A = p(xi, yi)$$

(10)

각 중앙 영역 픽셀의 강도 값은 P(xi, yi)입니다.

종양 부위의 경계를 측정하여 둘레를 계산합니다. 수학적으로는 다음과 같이 표현할 수 있습니다.

$$P = p(xi + 1, yi) = p(xi, yi)$$

(11)

여기서 P(xi, yi)는 종양 영역 경계의 픽셀 강도 값을 나타내며, 모든 경계 픽셀의 강도 값을 합산합니다. 종양 영역의 원형도는 둘레/면적 비율입니다. 수학적으로는 식 12와 같이 나타낼 수 있습니다. (4πA)

$$C = \frac{\text{둘레}^2}{4\pi A}$$

(12)

여기서 A 는 중앙 영역이고 P 는 둘레입니다. 중앙 영역의 편심률은 가장 잘 맞는 타원의 초점 사이 거리와 장축 길이의 비율입니다.

수학적으로는 다음과 같이 표현할 수 있습니다.

$$E = \frac{(1 - b)^2}{2a}$$

(13)

가장 잘 맞는 타원의 장축과 단축의 길이는 각각 a 와 b입니다.

C. 멀티모달 경량 XGBoost

멀티모달 경량 XGBoost 접근법은 XGBoost 분류기 앙상블을 활용하는 뇌종양 등급 예측을 위한 머신러닝 방법론입니다. 이 접근법은 다양한 모달리티의 MRI 스캔을 통합하여 뇌종양 등급을 예측합니다.

XGBoost 알고리즘은 의사결정 트리를 사용하여 특징과 목표 변수 간의 관계를 모델링하는 그래디언트 부스팅 알고리즘입니다. 이 알고리즘은 경사 하강법을 사용하여 손실 함수를 최소화하면서 의사결정 트리 앙상블 모델을 반복적으로 구축합니다. XGBoost는 n개의 샘플과 m개의 결정 트리를 사용하여 MRI에서 특징을 추출하며, 아래는 경량화된 XGBoost 알고리즘의 예입니다.

$$f(x) = \sum_{k=1}^K f_k(x)$$

(14)

새로운 샘플 레이블은 F(x)에 의해 예측됩니다. f\_k(x) 는 1부터 k까지의 회귀 트리의 총 개수입니다. 각 회귀 트리는 예측값과 실제값의 차이를 측정하는 손실 함수 L을 최소화하도록 학습됩니다. 이 손실 함수는 회귀의 경우 평균 제곱 오차, 분류의 경우 이진 교차 엔트로피와 같이 미분 가능한 함수일 수 있습니다.

XGBoost는 다음 목적 함수를 최소화하는 회귀 트리 {fk} 를 k = 1 부터 K까지 찾습니다.

$$l(\{f_k\}_{k=1}^K) = \sum_{i=1}^N L(y_i, F(x_i)) + \sum_{k=1}^K \Omega(f_k)$$

(15)

여기서 (f\_k) 는 과적합을 방지하기 위해 복잡한 트리에 페널티를 부여하는 정규화 항입니다. 정규화 항은 일반적으로 다음과 같은 형태를 취합니다.

$$\Omega(f_k) = \gamma T + \frac{1}{2} \sum_{j=1}^T w_j^2$$

(16)

여기서 T 는 트리의 잎 개수, w\_j 는 j번째 잎의 가중치, 그리고 감마와 람다는 정규화 강도를 조절하는 하이퍼파라미터입니다. XGBoost 알고리즘은 트리를 학습시키기 위해 그래디언트 부스팅 방식을 사용합니다. 각 반복 t에서 알고리즘은 현재 예측값의 음의 손실 함수 그래디언트에 맞춰 새로운 트리 ft를 앙상블에 추가합니다.

$$\frac{l(y_{-i}, f_{-t-1}(x_{-i})) - l(y_{-i}, f_{-t}(x_{-i}))}{l(x_{-i})}$$

(17)

학습률을 조절하는 가중치가 새로운 트리와 함께 앙상블에 추가됩니다.

$$F_t(x) = F_{t-1}(x) + \theta \times f_t(x)$$

(18)

제한된 경량화 모델은 손실 함수가 수렴하거나 최대 트리 개수 K에 도달할 때까지 이 과정을 반복합니다. 최종 예측값은 앙상블에 포함된 모든 개별 트리의 예측값을 합산한 것입니다.

D. 제한된 경량 앙상블 모델

제한된 경량화 방식은 여러 개의 XGBoost 결정 트리를 결합하여 예측을 수행합니다. 각 XGBoost 결정 트리는 약한 예측값을 제공하며, 이 예측값은 다른 트리의 예측값과 결합되어 최종 예측값을 생성합니다.

최종 예측값은 개별 트리의 예측값을 가중합한 값이며, 각 트리는 성능에 따라 가중치가 부여됩니다. 뇌종양 등급 분류의 경우, XGBoost 알고리즘의 여러 인스턴스를 서로 다른 다중 모달 데이터의 하위 집합을 사용하여 학습시킬 수 있습니다. 각 인스턴스는 학습률, 트리의 개수, 각 트리가 성장할 수 있는 깊이, 노드 분할에 필요한 최소 인스턴스 수 등 표 5에 나타낸 것과 같은 별도의 하이퍼파라미터 세트를 사용하여 학습시킬 수 있습니다.

이는 서로의 강점과 약점을 보완할 수 있는 다양한 알고리즘 인스턴스를 생성하는데 도움이 됩니다.

알고리즘의 각 인스턴스가 학습되면, 이들의 예측값을 결합하여 최종 중앙 등급 예측값을 생성할 수 있습니다. 예측값 결합에는 가중 평균 방식이 사용되며, 최종 예측값은 다음과 같이 표현됩니다. 여기서 Y\_i 는 i번째 인스턴스의 예측값이고, W\_i 는 i번째 인스턴스에 할당된 가중치이며, W\_i는 가중치의 합입니다.

각 인스턴스의 검증 세트에서의 성능을 기반으로 가중치를 결정할 수 있습니다. 각 등급에 대한 가중치는 다음과 같이 부여할 수 있습니다.

$$w_i = \frac{1}{(1 + \exp(-\lambda \times \text{error}_i))}$$

(19)

여기서 error\_i 는 i번째 인스턴스의 유효성 검사 오류 이고, λ는 가중치 계산에서 유효성 검사 오류의 중요도를 제어하는 튜닝 매개변수입니다.

표 5는 뇌종양 등급 분류를 위한 XGBoost 알고리즘의 세 가지 인스턴스를 학습하는데 사용된 하이퍼파라미터를 보여줍니다. 각 인스턴스는 서로 다른 하이퍼파라미터를 사용하여 멀티모달 데이터의 서로 다른 하위 집합으로 학습됩니다. 각 인스턴스의 검증 오류와 가중치도 표시됩니다.

E. 평가 지표

다음은 뇌종양 등급 분류를 위한 머신러닝 모델의 효과를 평가하기 위한 평가 지표입니다. 데이터 세트 내에서 올바르게 분류된 사례의 비율을 정확도라고 합니다. 정확도는 다음과 같이 계산됩니다.

$$\text{Acc} = \frac{TP + TN}{(TP + TN + FP + FN)}$$

(20)

표 5. 앙상블 하이퍼파라미터 요약.

|          | Learning Rate | Number of Trees | Maximum Depth | Minimum Instances | Validation Error | Weight |
|----------|---------------|-----------------|---------------|-------------------|------------------|--------|
| XGBoost1 | 0.1           | 100             | 6             | 10                | 0.2              | 0.47   |
| XGBoost2 | 0.05          | 200             | 4             | 20                | 0.18             | 0.53   |
| XGBoost3 | 0.2           | 50              | 8             | 5                 | 0.24             | 0.43   |

여기서 TP는 참양성, TN은 참음성, FP는 거짓양성, FN은 거짓음성의 수를 나타냅니다.

정밀도는 양성으로 분류된 전체 인스턴스 수 중에서 올바르게 양성으로 분류된 인스턴스의 비율을 나타냅니다. 정밀도는 다음과 같이 계산됩니다.

$$Pr = \frac{\text{도시}}{(TP + FP)} \tag{21}$$

여기서 TP는 참양성(True Positive)을, FP는 거짓양성(False Positive)을 나타냅니다. 데이터 세트의 모든 양성 사례 중에서 재현율(Recall)은 올바르게 분류된 양성 사례의 비율을 측정합니다. 재현율은 식 22로 주어집니다.

$$\text{기록} = \frac{\text{도시}}{(TP + FN)} \tag{22}$$

여기서 FN은 거짓 음성(false negative)의 수를 나타내고 TP는 참 양성(true positive)의 수를 나타냅니다.

재현율과 정밀도의 조화평균이 F1 점수입니다. 클래스 분포가 불균형할 때 재현율과 정밀도 사이의 균형을 유지하기 때문에 더 나은 측정 방법입니다.

F1 점수는 다음과 같이 계산됩니다.

$$F1 \text{ 점수} = \frac{2 \times Pr \times Re}{(Pr + Rec)} \tag{23}$$

위에서 언급한 지표 외에도 모델의 효과성을 평가하기 위해 수신자 조작 특성(ROC) 곡선과 곡선 아래 면적(AUC)을 사용합니다. 다양한 임계값 수준에서 참양성률(TPR)과 거짓양성률(FPR)을 그래프로 나타내어 ROC 곡선을 작성합니다. 모델이 양성 및 음성 클래스를 구분하는 능력은 ROC 곡선 아래 면적(AUC)으로 측정됩니다.

IV. 결과 및 논의

본 연구에서는 Brats 2020 데이터

셋을 사용하여 학습 과정을 진행했으며, 층화 샘플링을 통해 클래스 불균형 문제를 해결했습니다. 두개골 제거, 강도 정규화, MRI 스캔 크기 조정 등의 전처리 단계를 수행했습니다. 해당 데이터셋은 2등급 종양이 가장 많고, 그 다음으로 3등급, 4등급 종양 순으로 나타나는 심각한 불균형을 보입니다. 비종양 범주는 가장 적은 비율을 차지합니다. 이러한 데이터셋의 불균형은 머신러닝 모델의 성능에 영향을 미치고 편향된 결과를 초래할 수 있습니다.

모델 학습 및 테스트 과정에서 계층화 샘플링을 사용하여 클래스 불균형 문제를 해결합니다.

층화 샘플링을 사용하면 훈련 세트와 테스트 세트에서 각 클래스의 샘플 비율이 전체 데이터 세트에서 각 클래스의 샘플 비율과 일치합니다.

전처리는 MRI 스캔을 포함한 의료 영상 분석에서 필수적인 단계입니다. 전처리의 목적은 영상 품질을 향상시키고 노이즈와 아티팩트의 영향을 줄이는 것입니다 [29]. 데이터 세트의 MRI 스캔은 머신러닝 모델 학습에 사용하기 전에 전처리되었습니다. 전처리 단계에는 두개골 제거, 정규화 및 크기 조정이 포함되었습니다. 두개골 제거는 BET를 사용하여 뇌 이외의 조직을 제거했습니다. 정규화는 영상의 강도 값을 평균이 0이고 표준 편차가 1이 되도록 조정하는 것입니다. 마지막으로, 영상의 크기를 240 × 240 픽셀의 고정 크기로 조정했습니다.

그림 3 과 그림 4 에서 볼 수 있듯이, MRI 스캔의 품질을 향상시키고 노이즈와 아티팩트의 영향을 줄이기 위해 영상 정합, 두개골 제거, 강도 정규화 및 리샘플링을 수행했습니다. MRI 스캔 전처리 후, 다음 단계는 영상에서 특징을 추출하는 것입니다. 특징 추출은 머신러닝 알고리즘의 입력으로 사용하기 위해 영상에서 관련 정보를 추출하는 과정입니다. 본 연구에서는 전처리된 MRI 스캔에서 표 6에 나타난 바와 같이 다음과 같은 특징들을 추출했습니다. 각 뇌종양 영상에 대해 형태 기반 특징(면적, 둘레, 원형도, 입체도, 편심률)과 각 질감 특징(GLCM 대비, 상관관계, 에너지, 균질성)에 대한 강도 기반 특징(평균, 표준편차, 왜도, 첨도)을 포함하여 총 15개의 특징을 추출했습니다. 각 특징에 대해 각 종양 등급(2등급, 3등급, 4등급)의 50개 영상에 대한 평균과 표준편차를 계산했습니다.

표 7은 특징 추출 결과를 요약한 것입니다.

각 뇌종양 등급별로 특징을 추출했습니다. 추출된 특징은 강도 기반, 질감 기반, 형태 기반 특징의 세 가지 범주로 분류됩니다. 각 범주에서 여러 특징을 추출하고, 각 종양 등급별로 추출된 특징들의 평균값을 계산했습니다.

강도 기반 범주에 대해 평균 강도, 강도의 표준 편차, 중앙값 강도, 최소 강도 및 최대 강도를 포함한 특징을 추출했습니다. 표 8은 종양 등급이 높아짐에 따라 평균 강도, 표준 편차, 중앙값 강도, 최소 강도 및 최대 강도가 모두 증가함을 보여줍니다.






그림 3. 전처리 전 MRI 이미지.




그림 4. 전처리 후 MRI 이미지.

표 6. 다양한 등급의 뇌종양에 대해 추출된 특징.

| Feature Type    | Grade II     | Grade III    | Grade IV     |
|-----------------|--------------|--------------|--------------|
| Intensity-based | Mean         | Mean         | Mean         |
|                 | Std Dev      | Std Dev      | Std Dev      |
|                 | Skewness     | Skewness     | Skewness     |
|                 | Kurtosis     | Kurtosis     | Kurtosis     |
|                 | Contrast     | Contrast     | Contrast     |
| Texture-based   | Energy       | Energy       | Energy       |
|                 | Homogeneity  | Homogeneity  | Homogeneity  |
|                 | Entropy      | Entropy      | Entropy      |
|                 | Area         | Area         | Area         |
| Shape-based     | Perimeter    | Perimeter    | Perimeter    |
|                 | Circularity  | Circularity  | Circularity  |
|                 | Solidity     | Solidity     | Solidity     |
|                 | Eccentricity | Eccentricity | Eccentricity |

면적, 둘레, 편심률, 견고성, 등가 직경, 주축 및 단축 길이, 방향과 같은 특징들

형태 기반 분석을 위해 크기 및 중형비가 추출되었습니다.

범주. 종양 등급이 높아짐에 따라 편심률, 견고성 및 방향성은 감소하는 반면, 면적은 감소하는 것으로 나타났습니다.

둘레, 등가 직경, 주축 길이, 단축 길이

길이, 범위 및 중형비가 증가합니다. 이 기능은 뇌종양 이미지에서 다음과 같은 특징을 성공적으로 식별합니다.

종양 등급을 구분하는 데 도움이 됩니다. 이러한 특징에는 질감, 모양 및 이미지 강도의 변화가 포함됩니다.

이는 뇌종양의 심각도를 나타내는 주요 지표입니다.

종양 등급 분류에 있어 이러한 특징들의 효과

높은 모델 정확도로 확인되었으며 통계적 측정치를 통해 검증되었습니다.




그림 5. 제안된 MM-XGB 분류법의 혼동 행렬.

종양 등급 분류에 대한 혼동 행렬

그림 5는 모델의 높은 진단 정확도를 보여줍니다.

2등급, 3등급 및 4등급 종양의 진양성률은 0.85입니다.

각각 0.77과 0.72였습니다. 오분류는 가장 많이 발생했습니다.

3등급과 4등급 사이로, 잠재적인 영역을 시사합니다.

모델 개선. 이러한 오류에도 불구하고, 종양 등급을 구분하는 모델의 전반적인 신뢰도는 견고한 것으로 나타났습니다.

높은 참양성률과 관리 가능한 거짓양성률로 나타남

긍정적인 측면.

표 7. 각 뇌종양 등급별로 추출된 특징.

| Feature                                 | Grade II (n=50) | Grade III (n=50) | Grade IV (n=50) |
|-----------------------------------------|-----------------|------------------|-----------------|
| GLCM Contrast                           | 401.53 ± 15.28  | 523.94 ± 23.44   | 684.66 ± 26.71  |
| GLCM Correlation                        | 0.61 ± 0.03     | 0.53 ± 0.02      | 0.43 ± 0.01     |
| GLCM Energy                             | 0.0049 ± 0.0002 | 0.0041 ± 0.0001  | 0.0034 ± 0.0001 |
| GLCM Homogeneity                        | 0.35 ± 0.02     | 0.30 ± 0.02      | 0.27 ± 0.01     |
| Intensity Mean                          | 88.52 ± 2.63    | 117.84 ± 5.03    | 141.62 ± 5.58   |
| Intensity Standard Deviation            | 21.29 ± 1.02    | 30.39 ± 1.34     | 42.91 ± 1.56    |
| Intensity Skewness                      | 0.38 ± 0.04     | 0.48 ± 0.04      | 0.55 ± 0.03     |
| Intensity Kurtosis                      | 2.54 ± 0.22     | 3.25 ± 0.25      | 4.22 ± 0.26     |
| Area                                    | 204.24 ± 19.67  | 309.71 ± 26.05   | 457.06 ± 30.12  |
| Perimeter                               | 54.74 ± 3.50    | 75.72 ± 4.59     | 104.53 ± 5.76   |
| Circularity                             | 0.74 ± 0.02     | 0.69 ± 0.02      | 0.62 ± 0.02     |
| Solidity                                | 0.73 ± 0.03     | 0.71 ± 0.03      | 0.66 ± 0.03     |
| Eccentricity                            | 0.84 ± 0.02     | 0.87 ± 0.02      | 0.90 ± 0.02     |
| Normalized Intensity Mean               | 0.25 ± 0.01     | 0.33 ± 0.01      | 0.40 ± 0.01     |
| Normalized Intensity Standard Deviation | 0.06 ± 0.00     | 0.09 ± 0.00      | 0.13 ± 0.00     |

표 8. 각 종양 등급별 추출된 특징 결과.

| Feature Category | Feature Name                        | Grade II | Grade III | Grade IV |
|------------------|-------------------------------------|----------|-----------|----------|
| Intensity-based  | Mean intensity                      | 140.63   | 156.45    | 175.24   |
|                  | The standard deviation of intensity | 36.27    | 42.12     | 50.37    |
|                  | Median intensity                    | 143.27   | 158.79    | 178.64   |
|                  | Minimum intensity                   | 68.94    | 76.42     | 86.79    |
|                  | Maximum intensity                   | 245.67   | 252.36    | 255.00   |
| Texture-based    | Entropy                             | 0.34     | 0.42      | 0.52     |
|                  | Contrast                            | 0.15     | 0.22      | 0.31     |
|                  | Energy                              | 0.19     | 0.17      | 0.13     |
|                  | Homogeneity                         | 0.58     | 0.53      | 0.43     |
|                  | Area                                | 0.31     | 0.41      | 0.59     |
| Shape-based      | Perimeter                           | 0.44     | 0.52      | 0.68     |
|                  | Eccentricity                        | 0.16     | 0.13      | 0.11     |
|                  | Solidity                            | 0.14     | 0.13      | 0.10     |
|                  | Equivalent diameter                 | 0.37     | 0.42      | 0.47     |
|                  | Major axis length                   | 0.22     | 0.26      | 0.30     |
|                  | Minor axis length                   | 0.33     | 0.36      | 0.39     |
|                  | Orientation                         | 0.08     | 0.12      | 0.16     |
|                  | Extent                              | 0.20     | 0.26      | 0.32     |
|                  | Aspect ratio                        | 0.14     | 0.16      | 0.18     |

표 9에 나타난 개별 종양 등급을 살펴보면 , 알고리즘은 4등급 종양에서 가장 높은 정확도(93.0%)를 달성했으며, 그 다음으로 2등급 종양(92.0%), 3등급 종양(90.0%) 순이었다. 정밀도 값은 모든 종양 등급에서 0.92에서 0.94 사이로 비교적 높았다.

정밀도는 식별된 사례 중 실제 양성 사례의 비율을 나타내는 척도이므로, 정밀도 값이 높다는 것은 알고리즘이 실제 양성 사례를 높은 비율로 정확하게 식별했음을 의미합니다. 재현율 값 또한 모든 종양 등급에서 0.91에서 0.94 사이로 비교적 높았습니다.

표 9. 각 종양 등급별 MM-XGB 분류 결과.

| Tumor Grade | Accuracy | Precision | Recall | F1-Score | AUC-ROC |
|-------------|----------|-----------|--------|----------|---------|
| Grade II    | 92.0%    | 0.93      | 0.92   | 0.92     | 0.986   |
| Grade III   | 90.0%    | 0.92      | 0.91   | 0.91     | 0.977   |
| Grade IV    | 93.0%    | 0.94      | 0.93   | 0.94     | 0.984   |

표 10. 각 종양 등급별 SVM 분류 결과.

| Tumor Grade | Accuracy | Precision | Recall | F1-Score |
|-------------|----------|-----------|--------|----------|
| Grade II    | 84.0%    | 0.85      | 0.84   | 0.84     |
| Grade III   | 78.0%    | 0.77      | 0.78   | 0.77     |
| Grade IV    | 72.0%    | 0.72      | 0.72   | 0.71     |

표 11. 각 종양 등급별 RF 분류 결과.

| Tumor Grade | Accuracy | Precision | Recall | F1-Score | AUC-ROC |
|-------------|----------|-----------|--------|----------|---------|
| Grade II    | 82.0%    | 0.81      | 0.82   | 0.81     | 0.88    |
| Grade III   | 76.0%    | 0.73      | 0.76   | 0.73     | 0.82    |
| Grade IV    | 68.0%    | 0.67      | 0.68   | 0.67     | 0.74    |

재현율은 알고리즘이 성공적으로 탐지한 참양성 사례의 비율을 측정하는 지표이므로, 재현율 값이 높을수록 알고리즘이 참양성 사례를 높은 비율로 정확하게 식별했음을 의미합니다. 또한 각 종양 등급별로 MM-XGB를 SVM 및 RF 분류와 비교했습니다.

표 10에 나타난 결과와 같이, SVM 분류 알고리즘은 Brats 2020 데이터셋에서 종양 등급 분류에 대해 78.0%의 전체 정확도를 달성했습니다. 가장 높은 정확도는 2등급 종양에서 84.0%로 나타났으며, 그 다음으로 3등급 종양이 78.0%, 4등급 종양이 72.0%의 정확도를 보였습니다.

각 종양 등급에 대해 정밀도와 재현율 값을 계산했습니다. 재현율은 알고리즘이 실제 양성 사례 중 얼마나 정확하게 인식했는지를 나타내고, 정밀도는 식별된 사례 중 실제 양성 사례의 비율을 나타냅니다. F1 점수는 정밀도와 재현율의 조화 평균이므로 알고리즘의 전반적인 성능을 평가하는 지표입니다.

표 11은 Brats 2020 데이터셋에서 각 종양 등급에 대한 RF 분류 알고리즘의 결과를 보여줍니다. 이 알고리즘은 종양 등급 분류에서 75.3%의 전체 정확도를 달성했습니다. 가장 높은 정확도는 2등급 종양에서 82.0%로 나타났으며, 그 다음으로 3등급 종양이 76.0%, 4등급 종양이 68.0%의 정확도를 보였습니다. 각 종양 등급에 대해 정밀도, 재현율, F1 점수 및 AUC-ROC 값도 계산했습니다.

재현율은 알고리즘이 실제 양성 사례를 얼마나 정확하게 인식했는지를 측정하는 반면, 정밀도는 실제 양성 사례의 수를 측정합니다.

식별된 사례 중 실제 양성 사례의 비율을 측정했습니다. 정밀도 값은 0.67에서 0.81 사이였고, 재현율 값은 0.68에서 0.82 사이였습니다. F1 점수는 0.67에서 0.81 사이였고, AUC-ROC 값은 0.74에서 0.88 사이였습니다. 전반적으로 RF 분류 알고리즘은 Brats 2020 데이터셋에서 종양 등급 분류에 대해 75.3%의 정확도를 달성하며 비교적 우수한 성능을 보였습니다.

V. 결론 및 향후 연구 방향

본 연구에서는 의료 영상 데이터를 기반으로 뇌종양 등급을 정확하게 분류하는 진화적 머신러닝 알고리즘을 제안했습니다. 이 연구는 뇌종양 환자를 위한 더욱 정밀하고 개인화된 치료 계획 개발로 이어져 궁극적으로 환자의 치료 결과를 개선하는 데 기여할 수 있을 것입니다.

MM-XGB 연구 결과는 머신러닝 알고리즘을 활용한 뇌종양 등급 분류에 있어 유망한 진전을 보여줍니다. 그러나 여전히 개선의 여지가 있으며, 여러 분야에서 추가 연구가 필요합니다. 본 방법론의 한계점으로는 데이터셋의 다양성 부족과 다양한 데이터셋 및 영상 기법에 대한 일반화 가능성 제한 등이 있습니다. 정확한 뇌종양 등급 분류는 치료 결정에 도움을 주고 환자 예후를 개선할 수 있으므로 임상적으로 매우 중요합니다.

향후 연구에서는 머신러닝 알고리즘의 유망한 결과를 임상 현장에 적용하는 데 초점을 맞춰야 하며, 의료 전문가들이 쉽게 사용할 수 있는 소프트웨어 도구 개발 또한 포함해야 합니다.

이해 충돌  
저자들은 이해 충돌이 없음을 선언합니다.

참고문헌

[1] SJ Pan 및 Q. Yang, "전이 학습에 대한 조사" IEEE Trans. Knowl. 데이터 엔지니어링, 제22권, 제10호, 1345~1359쪽, 2010년 10월.

[2] T. Morita, J. Tsunoda, S. Inoue 및 S. Chihara, "완화 예측 지수: 말기 암 환자의 생존 예측을 위한 점수 시스템" Supportive Care Cancer, vol. 7, no. 3, pp. 128-133, 1999년 4월.

[3] PM Shah, F. Ullah, D. Shah, A. Gani, C. Maple, Y. Wang, M. Abrar 및 SU Islam, "홍부 X선 데이터에서 COVID-19 감지를 위한 심층 GRU-CNN 모델" IEEE Access, vol. 10, pp. 35094-35105, 2022.

[4] H. Dong, G. Yang, F. Liu, Y. Mo 및 Y. Guo, "U-Net 기반 완전 합성 네트워크를 사용한 자동 뇌종양 탐지 및 분할" Commun. Inf. Sci., Edinburgh, UK, 기술 보고서, 2017년 7월, 506-517쪽.

[5] F. Ullah, A. Salam, M. Abrar 및 F. Amin, "패치 기반 합성 신경망을 사용한 뇌종양 분할: 빅데이터 분석 접근법" 수학, vol. 11, no. 7, p. 1635, 2023년 3월.

[6] GV Kumar, MI Bellary 및 TB Reddy, "Taylor-bird squirrel 최적화 기반 심층 순환 신경망을 사용한 MRI를 이용한 전립선암 분류" Imag. Sci. J., vol. 70, no. 4, pp. 214-227, 2022년 5월.

[7] M. De Bruijne, 의료 영상 분석의 기계 학습 접근법: 탐지에서 진단까지. 암스테르담, 네덜란드: Elsevier, 2016, 94-97쪽.

[8] M. Zoli, VE Staartjes, F. Guaraldi, F. Friso, A. Rustici, S. Ascoli, G. Sollini, E. Pasquini, L. Regli, C. Serra 및 D. Mazzatenta, "쿠싱병의 내시경적 비강 접근법의 결과에 대한 기계 학습 기반 예측: 미래가 오고 있는가?" 신경외과 초점, 48권, 6호, E5페이지, 2020년 6월.

[9] MW Nadeem, MAA Ghamdi, M. Hussain, MA Khan, KM Khan, SH Almotiri 및 SA Butt, "딥러닝으로 강화된 뇌종양 분석: 검토, 분류 및 미래 과제" Brain Sci., vol. 10, no. 2, p. 118, 2020년 2월.

[10] G. Litjens, "의료 영상 분석의 딥러닝에 대한 조사" Med. Image Anal., vol. 42, no. 1995, pp. 60-88, 2017년 12월 [11] B. Shen, W. Hou, Z. Jiang, H. Li, A. J. Singer, M. Hoshmand-Kochi, A. Abbasi, S. Glass, HC Thode, J. Levsky, M. Lipton 및 TQ Duong, "COVID-19 환자의 종단 흉부 X선 점수와 임상 변수 및 결과와의 관계" Diagnostics, vol. 13, no. 6, p. 1107, 2023년 3월.

[12] DN Louis, A. Perry, G. Reifenberger, A. von Deimling, D. Figarella-Branger, WK Cavenee, H. Ohgaki, OD Westler, P. Kleihues 및 DW Ellison, "2016년 세계보건기구 중추신경계 종양 분류: 요약" Acta Neuropatholog., vol. 131, no. 6, pp. 803-820, 2016년 6월.

[13] A. Cruz-Roa, A. Basavanthally, F. González, H. Gilmore, M. Feldman, S. Ganesan, N. Shih, J. Tomaszewski 및 A. Madabhushi, "컨볼루션 신경망을 이용한 전체 슬라이드 이미지에서 침습성 관상염의 자동 감지" Proc. SPIE, vol. 9041, 2014년 3월, Art. no. 904103.

[14] Z. Akkus, I. Ali, J. Sedlá , JP Agrawal, IF Parney, C. Giannini 및 BJ Erickson, '기계 지능을 사용하여 MR 이미지에서 저등급 신경교종의 1p/19q 염색체 팔 삭제 예측', J. Digit. 이미지, 제30권, 제4호, 469-476쪽, 2017년 8월.

[15] M. Havaei, "심층 신경망을 이용한 뇌종양 분할" Med. 이미지 분석, 제35권, 18-31쪽, 2017년 1월.

[16] C. Chen, X. Guo, J. Wang, W. Guo, X. Ma 및 J. Xu, "기존 자기공명영상을 사용하여 수막종의 등급을 예측하는 데 있어 방사선학 기반 기계 학습의 진단 가치: 예비 연구" Frontiers Oncol., vol. 9, p. 1338, 2019년 12월.

[17] Q. Ul Ain, I. Duaa, K. Haroon, F. Amin 및 M. Zia ur Rehman, "MRI 기반 신경교종 탐지 및 저등급 및 고등급 신경교종으로의 분류" 제15회 국제 오픈 소스 시스템 기술 컨퍼런스(ICOSST) 회의록, 2021년 12월, 1-5쪽.

[18] S. Ahuja, BK Panigrahi 및 T. Gandhi, "슈퍼픽셀 기법을 사용한 전이 학습 기반 뇌종양 탐지 및 분할" Proc. 국제 회의 경멸. 계산. 신경 (IC3A), 2020년 2월, 244-249페이지.

[19] YW Park, J. Oh, SC You, K. Han, SS Ahn, YS Choi, JH Chang, SH Kim 및 S.-K. Lee, "Radiomics 및 기계 학습은 기존 영상 및 확산 텐서 영상을 사용하여 수막종의 등급 및 조직학적 하위 유형을 정확하게 예측할 수 있습니다." Eur. Radiol., vol. 29, no. 8, pp. 4068-4076, 2019년 8월.

[20] M. Sollini, L. Antunovic, A. Chiti 및 M. Kirienko, "이미지 마이닝의 임상적 적용을 향하여: 인공 지능 및 방사선학에 대한 체계적 검토" Eur. J. Nucl. Med. Mol. Imag., vol. 46, no. 13, pp. 2656-2672, 2019년 12월.

[21] K. Kamnitsas, C. Ledig, VFJ Newcombe, JP Simpson, AD Kane, DK Menon, D. Rueckert 및 B. Glocker, "정확한 뇌 병변 분할을 위한 완전 연결 CRF를 사용한 효율적인 다중 스케일 3D CNN", Med. Image Anal., vol. 36, pp. 61-78, 2017년 2월.

[22] S. Gull, S. Akbar 및 IA Shoukat, "자기공명영상을 통한 뇌종양 자동 탐지를 위한 심층 전이 학습 접근법" 국제 혁신 컴퓨팅 컨퍼런스(ICIC) 회의록, 2021년 11월, 1-6쪽.

[23] V. Wasule 및 P. Sonar, "SVM 및 KNN 분류기를 사용한 뇌 MRI 분류", 제3회 국제 신호 처리 보안 컨퍼런스(CSSS) 회의록, 2017년 5월, 218-223쪽.

[24] R.-C. Chen, C. Dewi, S.-W. Huang 및 RE Caraka, "기계 학습 방법을 기반으로 한 데이터 분류를 위한 중요 특징 선택" J. Big Data, vol. 7, no. 1, p. 52, 2020년 12월.

[25] Y. Pan, W. Huang, Z. Lin, W. Zhu, J. Zhou, J. Wong 및 Z. Ding, "신경망 및 합성 신경망을 기반으로 한 뇌종양 등급 분류" 제37회 IEEE 공학 의학 생물학회 연례 국제 회의 회의록. (EMBC), 2015년 8월, 699-702쪽.

[26] C. Chen, X. Ou, J. Wang, W. Guo 및 X. Ma, "교묘세포종과 전이성 뇌종양을 구별하기 위한 방사선학 기반 기계 학습" Frontiers Oncol., vol. 9, p. 806, 2019년 8월.

[27] O. Kouli, A. Hassane, D. Badran, T. Kouli, K. Hossain-Ibrahim 및 JD Steele, "자기공명영상을 이용한 자동 뇌종양 식별: 체계적 검토 및 메타분석" Neuro-Oncol. Adv., 제4권, 제1호, 2022년 1월, 기사 번호 vdac081.

[28] SM Smith, "BET: 뇌 추출 도구" Oxford Centre Funct. Magn. Reson. Imag. Brain, Dept. Clin. Neurology, Oxford Univ., John Radcliffe Hospital, Headington, UK, Tech. Rep. FMRIB TR00SMS2b, 2000, p. 25.

[29] V. Nyemeecha 및 BM Ismail, "하이브리드 가우시안 필터를 사용하여 피부경 이미지에서 노이즈 및 제거 구현" Netw. 모델 분석 건강 정보 생물정보학, 제10권, 제1호, 1-10쪽, 2021년 12월.



파이잔 울라 (IEEE 회원)는 현재 이슬라마바드 국제이슬람대학교에서 컴퓨터 과학 박사 학위 과정을 밟고 있습니다.

그의 연구 관심 분야는 데이터 마이닝, 머신 러닝 및 딥 러닝입니다.



무함마드 나딤 (IEEE 회원)은 국제이슬람대학교 컴퓨터공학과에서 박사 학위를 받았습니다. 현재 같은 학교의 조교수로 재직 중이며, 연구 분야는 생물정보학, 의료영상처리, 기계학습, 계산지능입니다.



무함마드 아브라르 (IEEE 회원)는 말레이시아 공과대학교에서 기계 학습 박사 학위를 받았습니다. 그는 2002년부터 국내외 유수의 대학에서 연구 활동을 해왔으며, 현재 오만 무스카트에 위치한 아랍 오픈 대학교 컴퓨터공학부 컴퓨터과학과 조교수로 재직 중입니다.

그는 활발한 학계 활동을 펼치는 학자입니다. 그의 연구는 다음과 같습니다. 이러한 기술에는 데이터 마이닝, 빅 데이터 및 머신 러닝이 포함됩니다.



파르한 아민 (IEEE 회원)은 2007년 파키스탄 데라 이스마일 칸의 고말 대학교에서 컴퓨터 과학 학사 학위를, 2012년 8월 파키스탄 이슬라마바드의 국제 이슬람 대학교(IIU)에서 컴퓨터 과학 석사 학위를, 그리고 2020년 10월 대한민국 경남대학교 공과대학 정보통신공학과에서 박사 학위를 받았습니다. 그는 조교수로 재직했습니다.

그는 대한민국 가천대학교 컴퓨터공학과에서 박사 학위를 취득했습니다. 2022년 3월부터 영남대학교 정보통신공학과 조교수로 재직 중이며, 9년 이상의 교육 및 연구 경력을 보유하고 있습니다. 그의 연구 분야는 사물인터넷, 소셜 사물인터넷, 빅데이터 및 데이터 과학입니다. 그는 미국 컴퓨터학회(ACM) 회원이며, 석사 및 박사 과정 동안 전액 장학금을 받았습니다.



아두 살람 (IEEE 회원)은 현재 컴퓨터 과학 박사 학위 과정을 밟고 있습니다.  
그는 파키스탄 이슬라마바드에 위치한 국제이슬람대학교 컴퓨터공학  
학과 소속이며, 조교로도 재직 중입니다.

아들 알리 칸 대학교 마르단 캠퍼스 컴퓨터 과학과 교수입니다.

HEC 파키스탄 승인 감독관입니다. 그는 더 많은 것을 가지고 있습니다.  
16년 이상의 교육 및 연구 경력  
그는 파키스탄의 공립 대학에서 근무했습니다.

HEC에서 인정하는 국내외 학술지에 16편의 연구 논문을 발표했습니다. 그의 연구 관심 분야는 무선  
센서 네트워크, 애드혹 비행체 등을 포함합니다.

센서 네트워크, 클러스터링, 최적화, 머신러닝, 딥러닝

그는 사물인터넷(IoT) 분야에도 관심이 많았으며, IEEE와 같은 권위 있는 학술지의 심사위원으로 활동했습니다.

ACCESS, KSII Transactions, Hindawi 및 SAGE 저널은 인터넷에서 이용 가능합니다.  
정보 시스템.



후세인 알살만 (IEEE 회원)이 받았습니다.

리야드 소재 킹 사우드 대학교(KSU)에서 컴퓨터 과학 학사 및 석사  
학위를 취득했습니다.

사우디아라비아, 그리고 인공공학 박사 학위

정보기관, 영국. 그는 수년간 근무했다.

여러 회사의 컨설턴트로 활동했습니다.

사우디아라비아의 민간 부문 및 정부 부문 기관에서 활동했  
습니다. 2009년부터 2014년까지 의장을 역임했습니다.

컴퓨터공학과, 대학

캔자스 주립대학교 컴퓨터 정보학과에서

그는 현재 컴퓨터 과학과 소속 교직원입니다.

그의 연구 관심 분야는 의료 영상 처리 및 기계 학습을 포함합니다.

의료 모니터링을 위한 알고리즘, 신경망, 계산 방법, 그리고 의료 분석을 위한 앙상블 및 딥러닝 모델

진단. 그는 킹 사우드 저널 의 심사위원단 위원이었습니다.

대학교, 2004년부터 2014년까지.

...

아메라 알라브라 (IEEE 회원)는 2008년 콜로라도 주립대학교에서 컴퓨터 과학 석사 학위를, 그리고 박  
사 학위를 받았습니다.

컴퓨터공학대학에서 컴퓨터공학 학위를 받았습니다.

2014년 센트럴 플로리다 대학교를 졸업했습니다. 현재 킹 사우드 대학교 컴퓨터 정보 과학 대학의 부교  
수로 재직 중입니다.

대학교 재학 중이며 사우디텔레콤 인공지능 회사 소속입니다.

연구 기금. 그녀의 연구 관심 분야는 컴퓨터 및 네트워크 보안입니다.

특히 소셜 미디어의 보안 조치를 최적화하는 데 있어서 말입니다.

네트워크.