



열려 있는

심층 3D 중첩 학습 최적화를 통한 파킨슨병 조기 진단을 위한 생체 모방 특징 선택

S. Priyadharshini¹, K. Ramkumar², SubramaniaswamyVairavasundaram³,
K. Narasimhan¹, S.Venkatesh¹, P. Madhavasarma¹ 및 Ketan Kotecha⁴

파킨슨병(PD)은 전 세계 수백만 명의 삶의 질에 영향을 미치는 가장 흔한 신경퇴행성 질환 중 하나입니다. 이 질환에 걸릴 확률은 나이가 들수록 증가하며, 특히 노년층에서 흔하게 나타납니다. 조기 발견은 질병의 진행을 늦추고 환자가 더 오랫동안 양질의 삶을 유지할 수 있도록 약물 치료를 시작하는 데 도움이 될 수 있습니다. 자기공명영상(MRI) 기반 뇌 영상은 파킨슨병을 조기에 진단하고 주요 생체지표를 파악하기 위한 활발한 연구 분야입니다. 기존의 MRI 데이터를 이용한 연구는 주로 파킨슨병 진단을 위해 기저핵(BG) 영역의 부피, 구조 및 형태학적 변화에 초점을 맞추었습니다. 최근 연구자들은 파킨슨병에 대한 보다 포괄적인 이해와 뇌 조직 변화 분석을 위해 뇌의 다른 영역을 연구하는 것의 중요성을 강조하고 있습니다. 따라서 파킨슨병(PD)의 조기 진단 및 치료 계획 수립을 위해, 본 연구에서는 새로운 3D-CNN(3D Convolutional Neural Network) 딥러닝 아키텍처를 이용하여 전뇌 MRI 영상으로부터 PD 발병 시점을 학습하는 데 초점을 맞추었습니다. 기존의 3D-ResNet 딥러닝 모델은 다양한 하이퍼파라미터 조정 및 아키텍처 변경을 거쳐 90%의 정확도를 달성했습니다. 본 연구에서는 새로운 3D-CNN 아키텍처를 개발하고, 여러 차례의 어블레이션 연구를 통해 93.4%의 향상된 정확도를 얻었습니다. 3D-CNN과 3D-ResNet 모델의 특징을 정규상관분석(CCA)을 이용하여 결합한 결과, 95%의 정확도를 달성했습니다.

모델 성능을 더욱 향상시키기 위해 다양한 최적화 기법을 활용한 특징 융합 및 최적화 기법을 적용했습니다. 생물학적 영감을 기반으로 한 고래 최적화 기법을 수렴도 분석을 통해 최적의 기법으로 선정했습니다. 이 기법의 성능을 다른 방법들과 비교한 결과 97%의 정확도를 달성했습니다. 본 연구는 파킨슨병 진단 기법 개선에 있어 중요한 진전을 이루었으며, 심층 중첩 3D 학습과 생물학적 영감 기반 특징 선택의 중요성을 강조합니다.

핵심어: 심층 중첩 3D 학습, 특징 융합, 특징 최적화, 자기공명영상
다중 분류, 파킨슨병

파킨슨병(PD)은 노인에게 두 번째로 흔한 신경계 질환입니다. 임상상은 일반적으로 떨림, 경직, 서동증(느린 움직임), 인지 저하와 같은 운동 및 비운동 증상을 포함한 다양한 증상을 관찰하여 파킨슨병을 진단합니다. 지난 20년 동안 연구계에서 이 분야를 탐구해 왔음에도 불구하고, 파킨슨병은 여전히 직접적인 임상적 치료법이 없는 질환입니다. 전통적인 진단 방법은 임상 데이터, 신경 영상 데이터 및 단백질 바이오마커를 기반으로 하며, 이를 통해 파킨슨병의 단계를 평가합니다. 자기공명영상(MRI)은 파킨슨병을 진단하는 데 사용되는 비침습적 의료 영상 기술로, 3차원(3D) 해부학적 이미지를 생성하여 뇌 구조의 변화를 감지하고 흑질(SN)의 철 침착을 확인할 수 있습니다.¹ 다양한 이완 기법을 사용하여 뇌의 다양한 해부학적 및 형태학적 구조를 연구합니다.

1SASTRA 사립대학교 전기전자공학과, 탄자부르, 인도. 2SASTRA 사립대학교 컴퓨터학과, 탄자부르, 인도. 3벨로르 공과대학교 컴퓨터공학과, 벨로르, 인도. 4삼비오시스 응용인공지능센터, 삼비오시스 인터내셔널(사립대학교), 푸네, 인도. 이메일: vsubramaniaswamy@gmail.com; head@scaai.siu.edu.in

T1 강조 영상, T2 강조 영상, 양성자 밀도 영상, FLAIR(Fluid Attenuated Inversion Recovery) 영상과 같은 다양한 MRI 스캔 기법을 사용하여 심층적인 분석을 위한 정보를 얻었습니다. 특히 T2 MRI는 MR 신호에서 철 축적 변화를 매우 효과적으로 감지하여 파킨슨병 환자의 철 함량 변화를 밝혀낼 수 있는 것으로 나타났습니다.

T2 강조 영상은 파킨슨병과 관련된 도파민 신경 세포 손실로 인한 흑질의 구조적 변화를 식별하는 데 사용됩니다.

최고 인공지능(AI), 특히 심층 신경망의 등장으로 의료 영상 처리 분야는 혁명적인 변화를 겪었으며, 그 결과 기존 AI 접근 방식보다 더 나은 진단 정확도를 달성했습니다.²

인공지능 연구 커뮤니티는 지난 20년간 MRI 데이터를 이용하여 정상인과 파킨슨병 환자를 분류하기 위해 서포트 벡터 머신(SVM), 랜덤 포레스트(RF), 베이지 분류기 등 다양한 머신러닝(ML) 기법을 적용해 왔으며, 정확도를 크게 향상시켰습니다. ML은 특징 추출 및 특징 선택과 같은 데이터 파이프라인 방법론을 활용합니다. 최근 연구자들은 정상인과 파킨슨병 환자의 특징을 추출하기 위해 복셀 기반 차이(VBD) 기법에 관심을 보이고 있습니다. 주성분 분석(PCA)은 분류 정확도 향상을 위해 특징의 차원을 축소하는 데 사용되어 왔습니다. 그러나 이러한 모든 방법은 파킨슨병 진단에 적합한 특징을 추출하기 위해 해당 분야에 대한 심층적인 이해를 필요로 합니다. 또한 확장성 측면에서 한계가 있으며 대규모 데이터셋 처리가 어려움, 관련 특징을 수동으로 선택하는 데 크게 의존합니다. 이러한 문제들을 해결하기 위해, 딥러닝(DL) 기반의 인간 개입 없는 자동 특징 검출 기법이 앞서 언급한 문제들을 해결할 수 있는 유력한 대안으로 떠오르고 있습니다.

딥러닝(DL) 알고리즘은 특히 다중 클래스 분류 문제에서 우수한 성능을 보여왔습니다. 딥러닝 알고리즘의 한 종류인 컨볼루션 신경망(CNN)은 의료 진단 애플리케이션을 위한 오디오, 비디오 및 이미지 데이터를 포함하는 영상 데이터 처리에서 최첨단 결과를 달성했습니다.^{3,4} 의료 영상 분야의 주요 과제는 환자 데이터 확보의 어려움으로, 수백만 개의 매개변수를 사용하는 CNN은 소규모 데이터 세트에서 과적합될 수 있다는 점입니다. 이러한 문제는 전이 학습 접근법을 사용하여 데이터 포인트 수를 늘리고 CNN이 희소 데이터로부터 효과적으로 학습할 수 있도록 함으로써 해결할 수 있습니다. 전이 학습을 적용하면 기존 머신러닝 기법에 비해 딥러닝 알고리즘의 성능이 크게 향상됩니다.⁵

최근 몇 년 동안 Residual Networks(ResNets), EfficientNets, Vision Transformers(ViTs)와 같은 사전 학습된 딥러닝 아키텍처가 연구 커뮤니티에서 널리 사용되었습니다.^{6–10} 이러한 아키텍처는 MRI, SPECT(단일 광자 방출 컴퓨터 단층 촬영), DaTscan(도파민 수용체 스캔) 및 기타 신경 영상과 같은 다양한 유형의 데이터를 처리하여 정확한 진단을 내리는 데 매우 효과적인 것으로 입증되었습니다.

본 연구는 제안된 프레임워크를 ViT 및 EfficientNet과 비교하여, 제안된 프레임워크의 파킨슨병(PD) 탐지 효율성을 검증하기 위한 엄격한 벤치마크를 제공합니다.

인공지능(AI)은 의료 분야, 특히 효과적인 진단을 위해 해석 가능한 특징을 가진 MRI 데이터 처리에서 놀라운 발전을 보여왔으며, 의사의 의사결정 과정을 지원해 왔습니다. 그러나 이러한 모델들이 검증 데이터를 처리할 때 일반화 성능에 대한 불확실성이 중요한 과제로 남아 있습니다. 이러한 문제를 해결하기 위해 하이브리드 딥러닝 아키텍처를 활용한 새로운 파킨슨병(PD) 진단 방법을 제안합니다. 제안된 프레임워크에서는 3D-CNN과 3D-ResNet 모델을 각각 다중 클래스 분류를 위해 분석합니다. 구체적으로, 각 모델은 입력 데이터에서 특징을 추출하여 서로 다른 특징 집합을 생성합니다. 추출된 특징들은 정규 상관 분석(CCA)을 사용하여 융합함으로써 두 모델의 상호 보완적인 정보를 통합합니다. 특징 융합 후, 고래 최적화 알고리즘(WOA)을 적용하여 가장 관련성이 높은 특징들을 선택함으로써 특징 집합을 정제합니다. 마지막으로, 선택된 특징 집합에 다양한 머신러닝 알고리즘을 적용하여 다중 클래스 분류를 수행합니다. 이 접근 방식은 딥러닝 모델의 장점을 활용하고 분류 성능 향상을 위해 특징 집합을 최적화함으로써 포괄적인 분석을 보장합니다. 제안된 접근 방식을 통해 기존 연구 결과와 비교하여 파킨슨병의 조기 진단에서 상당한 개선을 얻을 수 있습니다.

본 연구의 주요 기여는 다음과 같습니다.

1. 자동화를 위해 새로운 3D-CNN 모델 기반의 전략적 하이퍼파라미터 튜닝 기법을 개발했습니다. MRI 영상에서 특징을 추출하여 파킨슨병 진단의 정확도와 효율성을 향상시킵니다.
2. 3D-CNN, 3D-ResNet, Vision Transformer 및 EfficientNet 모델에 대한 종합적인 분석을 수행하여 3D-CNN과 3D-ResNet이 파킨슨병 진단에서 정확도와 견고성 측면에서 다른 모델들보다 일관되게 우수한 성능을 보였음을 입증했습니다.
3. CCA를 사용하여 3D-CNN 및 3D-ResNet 모델의 특징을 융합하여 특징 표현력을 향상시켰습니다. WOA를 적용한 생체모방 메타휴리스틱 기반의 최적화된 특징 선택 방식을 사용하여 성능을 개선했습니다.
4. 전뇌 영상 기법을 활용하여 파킨슨병을 분류하기 위해 딥러닝과 머신러닝 기법을 통합한 지능형 시스템을 개발했습니다. 이 접근 방식은 다양한 특징 통합 기법을 활용하여 분류 정확도를 향상시켰습니다.
5. 제안된 융합 접근법을 통해 성능 지표와 정확도가 크게 향상되었음을 입증하여 파킨슨병 진단에서의 효과를 검증하였다.

본 연구 논문의 구성은 다음과 같습니다. "**관련 연구**" 섹션에서는 파킨슨병 진단 분야의 최신 연구 동향을 소개합니다. "**재료 및 방법**" 섹션에서는 연구 결과와 수행 과정을 상세히 설명합니다. "**결과**" 섹션에서는 기존 문헌에 제시된 모델들과 비교하여 제안된 모델의 성능을 분석합니다. "**고찰**" 섹션에서는 본 연구의 주요 성과를 요약합니다. "**결론**" 섹션에서는 연구 방법론, 알고리즘 기법 및 사용된 데이터셋에 대한 개요를 제시합니다.

관련 작품

최근 몇 년 동안 인공지능 기술은 비약적인 발전을 이루었고, 많은 의료 산업 분야에서 널리 활용되고 있습니다. 특히 의료 분야에서는 이러한 기술 발전과 고도의 학습 방법을 적극적으로 도입하여 알츠하이머병이나 파킨슨병과 같은 질병을 다양한 형태의 데이터를 활용해 진단하고 있다는 점이 주목할 만합니다. 지난 20년간 연구자들은 파킨슨병 진단 정확도를 향상시키기 위해 다양한 고급 머신러닝 접근법을 적용해 왔습니다.

참고 [문헌 11](#)에서는 저자들이 엔트로피 가중치를 K-최근접 이웃(KNN) 알고리즘과 통합하는 새로운 방법을 제시하여 기존 방법보다 정확도를 향상시킨 것을 확인할 수 있다. 이 알고리즘의 성능은 랜덤 포레스트(RF), 나이브 베이즈, 그리고 일반 KNN 알고리즘과 비교했을 때 우수하다. [참고 문헌 12](#)에서는 MRI 스캔을 전처리한 후 순환 신경망(RNN) 아키텍처를 사용하여 분류하는 새로운 질병 예측 방법을 개발했다. 이 접근 방식은 미상핵과 핵과 같은 특정 뇌 영역에서 속성을 추출하는 것을 포함하며, 의료 영상 분석에서 딥러닝 기술의 잠재력을 보여준다.

신경델라민 민감성 MRI(NMS-MRI) 슬라이스를 활용하여 파킨슨병(PD) 환자와 건강한 대조군(HC)을 구분하는 방법이 개발되었으며, 이 방법에서는 2D 합성곱 신경망(2D-CNN)을 구현하여 뇌 형태 구조의 관심 영역 내에서 예후 및 진단 바이오마커를 식별합니다.¹³ [14](#) 저자들은 딥러닝 기반 PD 분류에서 관심 영역(ROI)으로 피질하 영역인 흑질(SN)을 식별하는 방법을 제안했습니다. CNN 및 기타 아키텍처를 활용한 이 연구는 질병 탐지 정확도 향상에 있어 정확한 특징 선택의 중요성을 강조합니다.¹⁵

파킨슨병 진행 표지자 이니셔티브(PPMI) 데이터베이스를 활용하여 3D ResNet 모델의 질병 분류 정확도를 평가했습니다. 본 연구는 5겹 교차 검증 전략을 통해 더 높은 정확도를 달성했으며, 설명 가능성 프레임워크를 사용하여 특징 맵 편향을 분석하고 시각적 표현을 생성했습니다. 또한, 본 연구에서는 설명 가능한 인공지능을 구현하기 위해 특징 맵을 생성하여 분류 작업에 가장 크게 기여하는 뇌 영역을 강조했습니다.

또한, 다양한 전이 학습 방법을 통합한 딥러닝 모델이 파킨슨병 환자와 건강한 대조군 참가자를 정확하게 구분하기 위해 제안되었습니다. 이 모델은 변형 필드와 필수적인 임상 특징을 통합한 크고 다양한 데이터베이스에서 훈련되어 파킨슨병 진단에서 견고성과 정확성을 향상시킵니다.¹⁶ 더불어, 다양한 데이터셋의 MRI 데이터를 사용하여 파킨슨병 환자와 비파킨슨병 환자를 분류하는 데 CNN 기반 접근 방식이 적용되어 79.3%의 정확도를 달성했습니다. 이 방법은 의료 영상 작업에서 CNN의 잠재력을 보여줍니다.¹⁷ [18](#) 연구진은 기능적 자기공명영상(fMRI) 데이터를 이용한 질병 진단을 위해 3D-CNN 모델을 제안했습니다. 전처리 과정에서는 FMRI 소프트웨어 라이브러리(FSL)를 통해 독립 성분 분석(ICA)과 이중 회귀 방법을 사용하여 잡음과 아티팩트를 제거하고 휴식 상태 네트워크(RSN)를 식별합니다. 3D-CNN 모델은 식별된 RSN 또는 3D 공간 맵을 사용하여 10겹 교차 검증 기법으로 훈련됩니다. [19번 논문](#)에서 저자들은 다양한 접근 방식을 통해 뇌종양을 정확하게 분류하는 혁신적인 하이브리드 기법을 제안합니다. 이 전략은 특징 분류를 위한 머신러닝 방법과 특징 추출을 위한 고유한 CNN 모델을 결합합니다. 본 연구에서는 9개의 CNN 모델을 사용하여 CNN 성능을 비교하고 머신러닝 분류 알고리즘의 하이퍼파라미터 값을 최적화합니다.

본 문헌 조사는 질병 탐지 및 분류에서 머신러닝(ML)과 딥러닝(DL) 기법을 융합하는 하이브리드 접근 방식의 중요성을 강조합니다. 또한, 이미징 특징 융합 및 메타휴리스틱 기반 최적화 프로세스를 포함하여 높은 정확도 달성에 중요한 역할을 하는 각 연구의 방법론과 기여도를 중점적으로 다룹니다. 문헌 조사 개요는 표 1에 제시되어 있으며, 다양한 딥러닝 방법을 사용하여 뇌 MRI 영상 분류에 초점을 맞춘 최근 연구들을 요약하고 있습니다.

재료 및 방법

본 절에서는 제안된 연구에서 사용된 방법론과 알고리즘 도구를 간략하게 설명하며, 특히 데이터셋 수집, 다양한 심층 신경망 아키텍처 개발, 그리고 융합 및 최적화 기법 구현에 적용된 알고리즘 변경 사항에 중점을 둡니다. 제안된 전체 방법론은 그림 1의 블록 다이어그램에 나타나 있으며, 다음과 같은 모듈로 구성됩니다. (1) 제안된 3D-CNN 아키텍처, (2) 개선된 ResNet 모델, (3) 정규 상관 관계 기반 융합 및 고래 최적화. 각 모듈은 본 절에서 자세히 설명합니다.

데이터 수집 및 전처리

본 연구에서 사용된 데이터셋은 PPMI 데이터베이스²⁰에서 수집되었으며, 이는 대조군 및 파킨슨병 환자의 다양한 영상 모달리티를 포함하는 오픈 소스 저장소입니다. 제안된 실험 조사에서는 총 303개의 MRI 영상(대조군 110개, 전구기 58개, 파킨슨병 135개)을 사용했습니다. 분석에서는 MRI 영상 품질에 미치는 연령과 성별을 고려했으며, 모델의 효과적인 관리 능력을 입증했습니다.

참고 자료 문제	방법	데이터셋	정확성 (%)
12	이진 분류 CNN-RNN	MRI 및 DaTscan 데이터	98.0
13	이진 분류 2D-CNN 및 CAM	MRI 데이터	80
15	이진 분류 3D-ResNet	PPMI	94.5
17	다중 분류 2D-CNN	PPMI	79.3
18	다중 분류 3D-CNN	타우 우	86.0
19	다중 분류 하이브리드 모델(사전 학습됨) + 2D-CNN MRI 데이터		97.1

표 1. 뇌 MRI 영상 분류에 관한 최근 연구들.

.....




그림 1. 제안된 방법의 전체 구조.

인구통계학적 변이성을 고려하여, 문헌 조사 결과 T2 강조 MRI 데이터가 품질(SN) 영역을 국소화하는 데 널리 사용되는 것으로 나타났습니다. 본 연구에서는 참고문헌21,22에 설명된 대로 뇌 추출, 등록, 정규화 및 데이터 증강과 같은 전처리 단계를 수행했습니다. 참고문헌 23에서는 저자가 피질 하 영역의 구조적 변화를 분석하여 파킨슨병(PD)을 진단하는 데 사용했습니다. 따라서 T1, T2 및 FLAIR 강조 MRI 시퀀스 중 T2 강조 시퀀스만 제안된 방법에 사용했습니다. 현재 의료 시스템에서 제안된 프레임워크의 적용 가능성을 확보하기 위해 다양한 MRI 장비의 MRI 스캔 출력 형식과 해상도를 분석하고 이를 훈련 및 테스트 데이터에 포함했습니다. 데이터 세트에는 1.5T 및 3T MRI 장비의 스캔이 포함되었으며, 일반적으로 3T 영상이 더 높은 공간 해상도와 신호 대 잡음비를 제공합니다.

이는 제안된 분류 모델이 이러한 요인들과 관계없이 정확도를 유지하도록 보장합니다. 다양한 MRI 장비의 주요 요인은 표 2에 나열되어 있습니다.

3D-CNN

3D-CNN 아키텍처를 설계하고 분석하여 입력 MRI 이미지를 대조군-0, 전구기-1, PD-2의 세 가지 클래스로 분류했습니다. 기존 연구에서는 2D-CNN을 이용하여 2D 슬라이스 분류에 대한 MRI 데이터를 광범위하게 연구해 왔습니다.6,12-14 하지만 각 피험자의 MRI 스캔 슬라이스 수가 가변적이기 때문에 아키텍처의 입력 크기를 고정하기 어렵고, 이는 정확도 제한으로 이어집니다. 3D-CNN 아키텍처에서는 3차원 MRI 이미지를 NIFTI 파일 형식으로 직접 입력할 수 있습니다. 본 연구에서는 광범위한 어블레이션 연구를 통해 새로운 3D-CNN 아키텍처를 설계하고 구축했습니다. 제안된 아키텍처는 입력 레이어, 3D ReLU 활성화 함수를 사용하는 3D 컨볼루션 레이어를 포함하여 총 24개의 레이어로 구성됩니다.

MRI 기계	제조사	자기장 세기(T) 출력 형식 DICOM 이미지	품질 요소
MAGNETOM Skyra Siemens Healthineers 3			DICOM 높은 공간 해상도, 높은 신호 대 잡음비, 우수한 아티팩트 감소 효과
MAGNETOM Aera Siemens Healthineers 1.5			DICOM 적당한 공간 해상도, 우수한 신호 대 잡음비, 아티팩트 관리
SIGNA 프리마어 GE 헬스케어		3	DICOM 높은 공간 해상도, 뛰어난 신호 대 잡음비, 고급 시퀀스
디스카버리 MR750 GE 헬스케어		3	DICOM 고해상도, 높은 신호 대 잡음비, 효과적인 아티팩트 감소
잉게니아 엘리션 필립스 헬스케어		3	DICOM 높은 공간 해상도, 높은 신호 대 잡음비, 노이즈 감소 기능
아차에바 필립스 헬스케어		1.5	DICOM 적당한 해상도, 우수한 신호 대 잡음비, 향상된 대비 시퀀스

표 2. 다양한 MRI 장비의 성능 및 영상 품질 비교 개요.




그림 2. 제안된 3D-CNN.

함수, 베이지안 네트워크(BN), 풀링 레이어, 두 개의 완전 연결 레이어, 그리고 마지막으로 소프트맥스 분류 레이어로 구성됩니다. 그림 2는 제안된 3D-CNN 모델의 아키텍처를 보여줍니다.

개선된 3D-ResNet
기존 문헌에서는 MRI 영상 분석 및 분류에 Improved ResNet 모델¹이 사용되었습니다. 본 연구에서는 이 모델을 특징 추출을 위한 하나의 모듈로 활용하고, MRI 데이터 분류 성능을 분석했습니다. 그림 3은 3D 개선 ResNet 모델의 아키텍처를 보여줍니다. 이 신경망 아키텍처는 입력층, 두 개의 conv3D 블록, 맥스 풀링 레이어를 포함하는 다섯 개의 잔차 블록, 완전 연결층, 그리고 SoftMax 레이어를 포함하여 총 15개의 층으로 구성됩니다. 각 "conv3D 블록"은 3D 컨볼루션 레이어, 베이지안 노이즈(BN), 그리고 ReLU 활성화 함수로 이루어져 있습니다. 잔차 블록은 각각 두 개의 3D 컨볼루션 레이어, BN, 그리고 ReLU 활성화 함수로 구성된 세 개의 잔차 유닛을 포함합니다. 잔차 유닛의 중요한 특징은 스킵 연결(skip connection)로, 입력값을 마지막 ReLU 레이어의 출력값에 직접 더하는 방식입니다. 본 연구에서는 출력층 최적화를 위해 Adam 최적화 알고리즘과 범주형 교차 엔트로피 손실 함수를 사용하는 SoftMax 분류기를 적용했습니다. 비선형 함수인 ReLU 활성화 함수는 훈련 중 기울기 소실 또는 폭발 문제를 해결하기 위해 사용됩니다. ReLU 활성화 함수는 식 (1)과 같이 정의할 수 있습니다.

$$f(y)=\begin{matrix}y & \text{가 } 0\text{보다 작으면 } 0 \\ y \geq 0\text{인 경우} & y\end{matrix}$$

(1)

특징 추출
특징 추출은 입력 이미지 데이터에서 관련 패턴을 식별하는 과정입니다. 3D CNN에서 21번째와 22번째 레이어는 완전 연결 레이어로 구성되어 있으며, 이 레이어에서 1000개의 특징이 추출되었습니다. 23번째 레이어에서는 알고리즘적 개선을 통해 특징 연결을 수행하여, 가장 높은 값을 선택함으로써 서로 다른 두 특징 집합을 하나의 벡터로 병합합니다. 또한, 개선된 3D ResNet의 14번째 레이어에서도 1000개의 특징이 추출되었습니다. 최종적으로 두 아키텍처에서 총 2000개의 특징이 추출되었습니다.




그림 3. 개선된 3D-ResNet.

특징 융합

특징 융합은 여러 심층 신경망 아키텍처(예: 3D-CNN 및 3D-ResNet)에서 추출한 특징을 결합하거나 통합하여 머신러닝 모델의 성능 또는 효율성을 향상시키는 과정입니다. 본 연구에서는 CCA 알고리즘을 사용하여 특징 융합을 수행합니다.

특징 연결

특징 연결은 식 (2)에서 언급된 바와 같이 가장 높은 값24를 선택하여 두 개의 서로 다른 특징 집합을 하나의 벡터로 병합하는 것을 포함합니다. 구성된 3D-CNN의 21번째 및 22번째 레이어의 특징을 연결하면 PD 진단의 정확도가 향상됩니다. 합성 벡터 x_3 은 벡터 $x_1 \in FV_1$ 과 $x_2 \in FV_2$ 에서 가장 높은 값을 추출하여 얻습니다. x_1 과 x_2 가 같을 경우, 벡터 x_3 은 이 두 요소 중 하나를 선택하여 요소의 중복을 방지합니다. 이 과정에 대한 의사 코드는 알고리즘 1에 설명되어 있습니다. 특징 벡터 x_3 은 $FV_1 \times 1000$ 및 $FV_2 \times 1000$ 의 크기를 가집니다. 연결된 특징 맵은 다음과 같이 표현됩니다.

$$x_3 = x_3 \leftarrow \max(x_1, x_2) \text{ 및 } x_3 \in \text{중복되지 않음} \quad (2)$$

```
1: Input:
2:  $x_1, x_2$ : Feature vector from space  $FV_1$  and  $FV_2$ 
3:  $w_1, w_2$ : Weight for  $x_1$  and  $x_2$ 
4:
5: Normalization:
6: Normalize ( $x_1$  and  $x_2$ )
7:
8: Initialization:
9:  $x_3$  = empty vector for the length of  $x_1$ 
10: used features = empty set
11:
12: Feature Concatenation Loop:
13: for  $j = 0$  to  $\text{length}(x_1) - 1$  do
14:   Calculate weighted  $x_1\text{value} = w_1 \times x_1[j]$ 
15:   Calculate weighted  $x_2\text{value} = w_2 \times x_2[j]$ 
16:   if weighted  $x_1\text{value} > \text{weighted } x_2\text{value}$  and  $x_1[j]$  not in used features then
17:     Set  $x_3[j] = x_1[j]$ 
18:   else if weighted  $x_2\text{value} \geq \text{weighted } x_1\text{value}$  and  $x_2[j]$  not in used features then
19:     Set  $x_3[j] = x_2[j]$ 
20:   else
21:     Set  $x_3[j] = \text{fallback logic}()$ 
22:   end if
23:   Upload  $x_3[j]$  to used features
24: end for
25:
26: Output:
27:  $x_3$ : Concatenated feature vector with unique elements
```

알고리즘 1. 특징 연결을 위한 의사 코드

정준 상관 분석
본 연구에서는 CCA를 사용하여 두 특징 집합 간의 상관관계를 분석합니다. 25, 26 3D Resnet 모듈과 3D CNN 모듈에서 총 2000개의 특징을 추출했습니다. 본 연구에서는 상관관계 기반 분석을 수행하기 위해 CCA를 사용합니다. CCA는 두 변수 집합 간의 연관성을 분석하는 데 사용됩니다. $A \in \mathbb{R}^{p \times n}$ 및 $B \in \mathbb{R}^{q \times n}$ 이라는 두 행렬이 있고, 각각 두 개의 서로 다른 아키텍처에서 추출한 n 개의 훈련 특징 벡터를 포함한다고 가정합니다. 즉, 각 샘플에서 $(p + q)$ 개의 특징이 추출되었습니다.

$SAA = \mathbb{R}^{p \times p}$ 및 $SBB = \mathbb{R}^{q \times q}$ 라고 하자. , 이는 A 와 B 의 공분산 행렬 집합을 나타내며 , $SAB = \mathbb{R}^{p \times q}$ 입니다.
 $SBA = ST$ 일 때, 집합 간 공분산 행렬을 나타냅니다. AB. S로 표시되는 포괄적인 $(p + q) \times (p + q)$ 공분산 행렬은 식 (3) 에 표시된 것처럼 특징 쌍 간의 연관성에 관한 모든 정보를 캡슐화합니다 .

$$S = \begin{bmatrix} \text{cov}(A) & \text{cov}(A, B) \\ \text{cov}(B, A) & \text{cov}(B) \end{bmatrix} = \begin{bmatrix} \text{사아} & \text{사브} \\ \text{SBA} & \text{SBB} \end{bmatrix}$$

(3)

본 연구에서는 선형 조합을 최적으로 계산하도록 설계된 CCA(Convection Coding Assessment)를 특징 융합에 사용합니다. 이를 $A = WT$ 로 나타냅니다.
 A 와 $B = WT$ 비 B는 두 데이터 세트 간의 쌍별 상관관계를 최대화하는 결과를 가져옵니다.
식 (4)에 나타낸 바와 같습니다.

$$\text{corr}(A, B) = \frac{\text{cov}(A, B)}{\sqrt{\text{여기서}(A) \cdot \text{여기서}(B)}}$$

(4)

여기서 $\text{cov}(A, B) = WT$ 비 SABWB, $\text{var}(A) = WT$ 비 SAAWA 및 $\text{var}(B) = WT$ 비 SBBWB. 최대화는 라그랑주 승수를 사용하여 $\text{var}(A) = \text{var}(B) = 1$ 제약 조건을 준수하면서 A 와 B 사이의 공분산을 최대화하는 것을 목표로 합니다. 변환 행렬 WA 와 WB는 식 (5)를 사용하여 표현됩니다.

$$\begin{aligned} S^{-1} A A S A B S^{-1} B B S B A w A &= \lambda_2 w A, \\ S^{-1} B B S B A S^{-1} A A S A B w B &= \lambda_2 w B. \end{aligned}$$

(5)

여기서 고유값의 대각행렬, 즉 정규상관의 제곱은 λ_2 로 표시되고 고유벡터는 w_A 와 w_B 로 표현됩니다. 0이 아닌 고유값에 대한 계산된 고유벡터는 변환 행렬을 형성합니다. 수정된 특징 벡터들은 연결되거나 합산되어 특징 수준 융합을 수행하고 융합 벡터 Z를 얻습니다. 여기서 Z1 과 Z2 는 정규상관 판별 특징입니다.

(CCDFs)는 식 (6, 7)에 언급되어 있습니다. 융합 벡터 (Z) 는 최적화 기반 특징 제거 모듈에 적용되어 모델의 예측 정확도에 크게 기여하는 중요한 특징을 정제하고 선택합니다.

$$Z1=(A \quad | \quad B) = (WT \ A \ A) \mid (WT \ B \ B) = \begin{matrix} 0 \text{ 개 중} \\ 0 \text{ WB} \end{matrix} \begin{matrix} \text{티} \\ \text{에이} \\ \text{비} \end{matrix} \quad (6)$$

$$Z2=A \quad + \quad B \quad = \text{WT} \quad \begin{matrix} \text{에이} \\ \text{비} \end{matrix} \quad A + \text{WT} \quad \begin{matrix} \text{티} \\ \text{에이} \\ \text{비} \end{matrix} = \begin{matrix} \text{의} \\ \text{WB} \end{matrix} \begin{matrix} \text{티} \\ \text{에이} \\ \text{비} \end{matrix} \quad (7)$$

가능 최적화

특징 최적화의 주요 목표는 시스템의 계산 부하와 데이터 처리량을 줄이는 동시에 예측에 중요한 영향을 미치는 특징을 식별하는 것입니다. 최적화 후 특징 차원이 축소되면 데이터 관리가 간소화되고 대규모 데이터 세트에 대한 학습 및 예측 프로세스 처리가 용이해집니다.

WOA의 수학적 모델

Mirjalili와 Lewis는 흑등고래의 거품 그물 먹이 전략^{27,28}에서 영감을 받아 고래 최적화 알고리즘(WOA)을 개발했습니다. 고래가 원형 패턴의 거품을 사용하여 먹이를 잡는 이 방법은 복잡한 최적화 문제에 대한 해법 탐색을 최적화하기 위해 WOA에 적용되었습니다.

먹이 포위: 흑등고래는 사냥 전략에서 먹이를 찾아 포위합니다. 이러한 행동은 WOA에 반영되어 있으며, WOA는 현재 최적의 솔루션이 최적 솔루션에 근접한다고 가정합니다.²⁹ 최적의 탐색 에이전트가 식별되면 다른 에이전트들은 고래의 포위 행동을 모방하여 해당 에이전트로 수렴합니다.

이 과정은 수학적으로 식 (8,9)에 표현됩니다. 여기서 Z (u)는 에이전트의 위치를 나타내고, u는 반복 횟수를 나타내며, Z 는 에이전트의 위치를 나타냅니다.

최적해를 나타냅니다. 식 (10, 11)에서 A 와 D는 수렴값을 나타냅니다.

난수는 s[0, 1] 이고, s는 반복 과정에서 2에서 0으로 선형적으로 감소하는 벡터를 나타냅니다.

$$Z \ (u + 1) = Z \ ^{*} \ (u) \ A \ \cdot \ F \ , \quad (8)$$

$$F \ = \ D \ \cdot \ (Z \ ^{*} \ (u) \ Z \ (u)) \ , \quad (9)$$

$$A \ = 2 \ a \ s \ - \ a \ , \quad (10)$$

$$D \ = 2 \ s \quad (11)$$

흑등고래가 사용하는 거품 그물 공격 방식은 탐색 영역을 좁히기 위해 먹이를 향해 몸을 축소하고 나선형으로 움직이는 것을 포함합니다. WOA에서는 이를 a 값을 감소시켜 시뮬레이션합니다 (식 11 참조). 이는 탐색 공간을 좁히고 먹이 포획 행동을 모방합니다. A는 a에 의존하므로 2에서 0까지 선형적으로 감소합니다. 먹이를 포획하는 데 중요한 고래의 나선형 이동 패턴은 식 (12, 13)에서 수학적으로 모델링됩니다.

$$F \ = Z \ (u) \ Z \ (u) \ , \quad (12)$$

$$Z \ (u + 1) = e^{bk \cos(2\pi k)F} \ * \ + \ Z \ (u) \quad (13)$$

이 사이의 거리는 상수로 표시되며 l은 [-1, 1] 사이의 임의 값입니다. 흑등고래 F . 매개변수 b는 로그 나선입니다. 고래와 목표 먹이 사이의 거리를 향해 나선형 접근 또는 직접 좁혀가는 접근 중 하나를 선택할 확률이 50%입니다. 매개변수는 식 (14)에서 두 이동 패턴 중 하나를 선택할 확률을 결정하며, [0, 1] 사이의 임의 값입니다.

$$Z \ (u + 1) = \begin{matrix} Z \ A \ \cdot \ F, p < 0.5 \text{인 경우} \\ e^{bk \cos(2\pi k)F} \ + \ Z \ (u), p \geq 0.5 \text{인 경우} \end{matrix} \quad (14)$$

WOA의 탐색 단계에서 A 는 [-1, 1] 사이의 값을 무작위로 할당받아 탐색 에이전트가 기존 고래로부터 벗어나도록 유도합니다. 이는 탐색 에이전트의 업데이트된 위치가 다른 에이전트를 무작위로 선택하여 결정되므로 전역 탐색을 촉진합니다. 이 탐색 메커니즘의 수학적 공식은 식 (15, 16)에 설명되어 있으며, 여기서 Z rand는 현재 개체군에서 무작위로 선택된 고래의 무작위 위치입니다.

$$Z \ (u + 1) = Z \ rand \ A \ \cdot \ F, \quad (15)$$

$$F \ = |C \ \cdot \ (Z \ rand \ Z \)| \quad (16)$$

가능 선택을 위한 WOA

본 연구는 생체모방 알고리즘에서 영감을 얻은 WOA를 사용하여 파킨슨병 분류를 위한 특징 선택을 개선하고자 한다. 3D-CNN 모델의 FC-3 레이어와 3D ResNet 모델의 FC-4 레이어에서 각각 2000개의 특징을 추출하였다.

모델에서 효과적인 특징 선택은 데이터 표현을 개선하고 특정 기준에 따라 성능을 향상시키는 데 매우 중요합니다. 최적의 특징 선택은 모델을 단순화할 뿐만 아니라 추정기의 일반화 능력, 학습 속도 및 전반적인 성능을 향상시킵니다. 일반적인 문제로는 지역 최적점에서의 정체와 높은 계산 비용이 있습니다. 따라서 특징 선택 문제를 해결하기 위해 효율적인 전역 탐색 전략을 사용하는 것이 필수적입니다. WOA(Whale Optics Algorithm)에서 각 특징 부분집합은 탐색 공간 내 고래의 위치에 비유됩니다. 각 부분집합은 원래 데이터 세트의 개수에 해당하는 최대 N 개의 특징을 포함할 수 있습니다. 각 솔루션의 품질은 특징 개수와 분류 정확도라는 두 가지 기준에 따라 평가됩니다. 특징 개수가 적을수록, 정확도가 높을수록 더 나은 솔루션입니다. 솔루션은 K-최근접 이웃(KNN) 분류기를 사용하여 얻은 정확도와 선택된 특징 개수라는 두 가지 목표를 결합한 적합도 함수를 사용하여 평가됩니다.

해법 표현은 메타휴리스틱 알고리즘 설계에서 매우 중요한 과제입니다. 본 연구에서는 해법을 N 개의 요소를 가진 1차원 벡터로 표현합니다. 여기서 N은 데이터셋의 특징 개수와 일치합니다. 벡터의 각 요소는 "1" 또는 "0"으로 표시되는 이진 값입니다. "1"은 해당 특징의 선택을 나타내고, "0"은 제외를 나타냅니다. 이러한 이진 접근 방식은 솔루션 집합에서 특징의 포함 및 제외를 효율적으로 구분합니다. 제안된 방법의 적합도 함수는 선택된 특징의 수(최소화)와 분류 정확도(최대화) 사이의 균형을 맞추도록 신중하게 설계되었습니다. 이 함수는 식 (17)과 같이 정의됩니다.

$$f_0 = \alpha \gamma R(D) + (1 - \alpha) \frac{|R|}{|N|} \quad (17)$$

여기서 f_0 는 적합도 함수이고, $\gamma R(D)$ 는 KNN 분류기를 사용한 분류 오류율을 나타냅니다. $|R|$ 은 선택된 부분집합의 크기이고, $|N|$ 은 데이터셋의 전체 특징 개수입니다. 매개변수 α 는 분류 정확도의 중요도를 균형 있게 조절하고, $\beta = (1 - \alpha)$ 는 부분집합 크기에 부여되는 가중치를 조정합니다. α 와 β 값은 이 두 가지 측면 간의 균형을 반영하여 도출되며, 잠재적 해를 효과적으로 평가할 수 있도록 합니다. 30 최적화 과정은 계수 벡터 A와 D를 초기화하고 초기 최적해 벡터 Z를 무작위로 선택된 해로 설정하는 것으로 시작합니다. 이 과정은 미리 정의된 반복 횟수만큼 진행되며, 각 고래의 위치는 식 (8, 9)에 따라 업데이트됩니다. 각 위치의 적합도는 지정된 적합도 함수를 사용하여 평가됩니다. 어떤 반복에서든 더 나은 해가 발견되면 최적해 벡터 Z가 그에 따라 업데이트됩니다. 이 최적화 주기는 지정된 횟수만큼 독립적으로 반복됩니다. 지정된 반복 횟수에 도달하면 프로세스가 종료되어 최적해 탐색이 완료됩니다. 특징 선택을 위한 WOA의 상세 흐름도는 그림 4에 나와 있습니다.

결과

모델-1(3D-CNN) 아키텍처 분석

PPMI 데이터셋 저장소에서 서로 다른 세 가지 클래스에 속하는 DICOM(Digital Imaging and Communication in Medicine) 형식의 MRI 이미지 총 303개를 수집했습니다. 각 DICOM 이미지는 피험자 한 명당 100~200개의 다양한 슬라이스로 구성됩니다. 수집된 각 피험자의 DICOM 이미지는 단일 3D Nifti(Neuroimaging Informatics Technology Initiative) 형식 파일로 변환됩니다. 변환된 Nifti 파일은 MRI 데이터 품질 향상을 위해 두개골 제거 및 자기장 보정 등의 전처리 과정을 거칩니다. 31 마지막으로, 후속 분석을 위해 입력 파일 크기를 56x56x56으로 변환합니다.

절제술 연구

본 연구에서는 먼저 표 3에 나타난 바와 같이 기본적인 3D-CNN 아키텍처를 분석했습니다. 어블레이션 연구는 목표 정확도 측면에서 바람직한 성능을 달성하기 위해 최적의 컨볼루션 및 맥스 풀링 레이어 수를 선택하는 데 중점을 두었습니다. 연구는 여러 단계로 진행되었습니다. 1단계에서는 입력 레이어를 시작으로 두 개의 3D-컨볼루션(3D-conv) 레이어, 활성화 레이어, 풀링 레이어, 배치 정규화(BN) 레이어, 플랫텐 레이어, 그리고 완전 연결 소프트맥스 레이어로 구성된 총 8개의 레이어를 가진 기본 모델을 설계했으며, 그 결과 82.02%의 모델 정확도를 얻었습니다. 2단계에서는 기본 모델을 약간 수정한 변형 1 아키텍처를 설계했습니다. 이 아키텍처는 입력 레이어, 세 개의 3D-컨볼루션 레이어, 활성화 레이어, 풀링 레이어, BN 레이어, 플랫텐 완전 연결 레이어, 그리고 소프트맥스 레이어로 구성된 총 9개의 레이어를 가지고 있으며, 그 결과 85.75%의 모델 정확도를 달성했습니다. 3단계에서, Variant 2는 입력층, 두 개의 3D 컨볼루션 레이어, 활성화 레이어, 풀링 레이어, 배치 정규화(BN) 레이어, 세 개의 3D 컨볼루션 레이어, 활성화 레이어, 풀링 레이어, BN 레이어, 플랫텐 레이어, 그리고 SoftMax 레이어를 포함하는 17개 레이어 구조로 설계되어 88.76%의 정확도를 달성했습니다. Variant 3은 입력층, 두 개의 3D 컨볼루션 레이어, 활성화 레이어, 풀링 레이어, BN 레이어, 세 개의 3D 컨볼루션 레이어, 활성화 레이어, 풀링 레이어, BN 레이어, 두 개의 3D 컨볼루션 레이어, 활성화 레이어, 풀링 레이어, BN 레이어, 그리고 마지막으로 플랫텐 레이어와 SoftMax 레이어로 구성된 24개 레이어 구조로, 89.43%의 최고 정확도를 달성했습니다.

최적의 아키텍처를 선정하기 위해 기본 모델과 세 가지 변형 모델을 사용하여, 본 연구에서는 광범위한 시뮬레이션을 통해 적절한 하이퍼파라미터 선택에 초점을 맞추어 추가 연구를 수행했습니다. 하이퍼파라미터는 연구 2의 표 3에 나열된 다양한 기준에 따라 선택되었습니다. 본 연구의 목표는 하이퍼파라미터 변경을 통해 정확도를 극대화하는 최적의 구성을 찾는 것입니다. 이를 위해 각 모델(기본 모델, 변형 1, 변형 2, 변형 3)에 대해 다양한 파라미터 조합을 실험했습니다. 이러한 파라미터에는 풀링 레이어 유형, 활성화 함수, 배치 크기, 플랫텐 레이어 방식, 옵티마이저, 학습률이 포함됩니다. 모든 접근 방식 중에서 변형 3이 다양한 평가 기준에서 다른 모델들보다 우수한 성능을 보였습니다. 어블레이션 연구를 통해 이를 입증했습니다.




그림 4. WOA를 이용한 특징 선택 과정.

이는 매우 효과적인 것으로, 제안된 모델의 분류 능력을 89.43%에서 93.41%로 향상시켜 3.98%의 상당한 개선을 보여주었습니다.

파킨슨병 예측을 위한 3D-CNN의 특징 추출 레이어 성능 비교
의료 진단 분야에서 평가 기준은 재현율(민감도/참양성률/TPR), 정확도, 정밀도(양성 예측값/

PPV), 그리고 F1 점수. 분석 1에서는 3D-CNN의 21번째 레이어인 FC-1에서 추출한 특징에 초점을 맞추고, 더 나은 분류 결과를 얻기 위해 다양한 머신러닝(ML) 방법을 적용하고 탐색했습니다. 표 4에 나타난 바와 같이, 다양한 ML 모델과 그 성능을 분석한 결과, 랜덤 포레스트(RF) 모델이 88.7%로 가장 높은 정확도를 달성했습니다. 분석 2에서는 3D-CNN의 22번째 레이어인 FC-2에서 추출한 특징을 다양한 ML 분류기를 사용하여 추가 처리했습니다. 그 결과, 그래디언트 부스팅(GB) 분류기가 90.1%의 정확도를 달성하여 다른 분류기보다 우수한 성능을 보였습니다. 분석 3에서는 FC-1과 FC-2 레이어의 특징을 결합한 FC-3을 생성하고, 추출된 특징을 다양한 ML 방법을 사용하여 분류했습니다. 이러한 특징 융합을 통해 정확도가 향상되었으며, GB는 다른 분류기에 비해 93.5%의 높은 정확도를 달성하여 훨씬 우수한 성능을 보였습니다. 본 분석에서는 정확도, 분류기의 성능을 평가하기 위해 정밀도, 재현율 및 F1 점수를 사용했습니다. 이러한 결과는 파킨슨병 예측 정확도를 향상시키기 위해 적절한 특징 추출 레이어를 선택하는 것이 중요하다는 것을 보여줍니다.

모델-2 (3D-ResNet)

3D-ResNet의 상세한 모델 아키텍처는 그림 3과 같습니다. 특징은 완전 연결 계층인 FC-4에서 추출되었으며, 다양한 머신러닝 모델을 사용하여 분류에 초점을 맞춰 처리되었습니다.

그래디언트 부스팅 기반 머신러닝 알고리즘은 최대 90%의 정확도를 달성했습니다. 다양한 머신러닝 모델의 자세한 성능 분석은 표 4에 제시되어 있습니다.

모델 개발 및 최적화

3D CNN과 3D ResNet 모델은 MRI 스캔 데이터를 사용하여 학습되었으며, 3D CNN은 풀링, 활성화 함수 및 컨볼루션 레이어를, 3D ResNet은 잔차 블록을 사용했습니다. 데이터 증강 기법도 적용되었습니다.

연구 1: 컨볼루션 레이어와 맥스 풀링 레이어 수정				
모델	컨볼루션 레이어 수	풀링 레이어 수	테스트 정확도(%) 결과	
기본 모델 2		1	82.02	가장 낮은 정확도
변형 1	3	1	85.75	중급
변형 2	2+3	1+1	88.76	중급
변형 3	2+3+2	1+1+1	89.43	제일 높은
연구 2: 네 가지 접근 방식에 대한 다양한 매개변수 수정				
매개변수 기본 모델		변형 1	변형 2	변형 3
풀링 레이어				
1. 최대 ✓			✓	
2. 평균		✓		✓
활성화 기능				
1. ReLu ✓		✓	✓	✓
2. 서곡				
배치 크기				
1. 32				✓
2. 64	✓	✓	✓	
레이어를 평평하게				
1. 평평하게 만들기 ✓			✓	
2. 글로벌 최대		✓		✓
최적화 도구				
1. 아담 ✓		✓	✓	✓
2. 성가프로 달리				
학습률				
1. 0.01	✓		✓	
2. 0.001		✓		✓
시대				
시대	30	30	30	30
평가 지표				
정확성	84.96	88.25	90.28	93.41
정도	87.34	89.93	91.83	95.76
상기하다	81.54	84.28	87.72	88.98
F1 점수	85.32	87.43	90.81	91.68

표 3. 구축된 3D-CNN 아키텍처의 제거 연구.

견고성을 향상시키기 위해, 하이퍼파라미터는 Adam 및 SGD와 같은 기법을 조기 종료와 함께 사용하여 그리드 탐색 및 교차 검증을 통해 최적화되었습니다. 과적합을 모니터링하기 위해 별도의 데이터셋에서 모델을 검증하고 정확도, 정밀도, 재현율 및 F1 점수와 같은 지표를 사용하여 평가했습니다. 두 모델 모두에서 학습률을 낮추면 모델의 정밀도와 안정성이 향상되어 과적합을 방지하고 더 나은 수렴을 보장합니다. 모델 학습 및 하이퍼파라미터 튜닝에 대한 자세한 비교는 표 5에 종합적으로 제시되어 있습니다.

모델-3 (최적화 제외)

본 연구에서는 3D-CNN 모델의 FC-3 레이어와 3D ResNet 모델의 FC-4 레이어에서 특징을 추출했습니다. 추출된 두 가지 아키텍처의 특징들은 CCA(Critical Characterization Assessment)를 이용하여 결합했습니다. 이러한 융합 기법은 두 모델에서 얻은 상호 보완적인 정보를 통합하여 분류 정확도를 향상시키기 위해 수행되었습니다. 융합 과정 후, 가장 높은 정확도를 보인 GB 모델을 15겹 교차 검증 기법을 사용하여 성능 향상을 검증한 결과, 정확도가 4.8% 추가 향상되었습니다.

모델-4 (최적화 포함)

CCA를 이용한 융합 접근 방식은 높은 차원과 이상치에 대한 민감성이라는 한계를 가지고 있습니다. 따라서 새로운 최적화 전략을 통해 최적의 특징을 선택하는 것이 시급합니다. 본 연구에서는 생체 모방 최적화 기법인 WOA를 적용하여 최적의 융합 특징을 선택합니다. 이 최적화는 특징 표현을 개선하고 모델 성능을 향상시키는 것을 목표로 합니다. 최적화된 특징을 사용하여 15겹 교차 검증을 수행한 GB 알고리즘은 97.2%의 향상된 정확도를 달성했습니다.

이러한 우수한 성능은 최적화된 특징들이 더욱 견고하고 일반화 가능한 모델을 만들어낸다는 것을 분명히 보여줍니다. 모델 3과 모델 4의 성능 분석 결과는 표 6에 제시되어 있습니다.

방법 정확도 재현율 정밀도 F1 점수				
분석 1: 3D-CNN FC-1 레이어에서 추출한 특징을 이용한 PD 예측				
SVM	85.6	82.4	88.5	86.3
KNN	84.2	82.2	86.2	83.7
영국	87.1	83.0	88.5	87.2
RF	88.7	85.2	89.3	87.6
분석 2: 3D-CNN FC-2 레이어에서 추출한 특징을 이용한 PD 예측				
SVM	85.9	84.0	86.4	84.3
KNN	86.2	82.2	87.2	83.9
영국	90.1	86.0	92.0	88.9
RF	88.3	85.9	89.3	87.6
분석 3: FC-1 및 FC-2 레이어의 특징 융합(즉, FC-3)을 사용한 PD 예측				
SVM	90.5	88.0	91.9	89.1
KNN	88.9	86.2	90.2	87.4
영국	93.5	91.0	96.2	92.5
RF	91.8	87.4	93.3	90.3
분석 4: 3DResNet 특징을 이용한 PD 예측				
SVM	85.3	82.1	86.3	85.1
KNN	88.1	83.2	89.9	87.4
영국	90.0	88.3	92.5	91.0
RF	87.2	85.7	89.1	86.2
분석 5: EfficientNet 특징을 이용한 PD 예측				
SVM	92.0	89.0	96.0	92.5
KNN	91.5	88.5	95.5	92.0
영국	92.8	90.0	97.0	93.5
RF	93.0	89.8	96.8	93.3
분석 6: Vision Transformer 특징을 이용한 PD 예측				
SVM	91.5	89.5	96.5	93.0
KNN	92.5	89.0	96.0	92.5
영국	92.0	90.5	97.5	94.0
RF	91.2	90.2	97.2	93.7

표 4. 서로 다른 아키텍처 모델 및 특징 추출 방법을 사용한 PD 예측 성능 비교 분석.

상들	3D CNN	3D ResNet
훈련 데이터 분할	훈련용 70%, 테스트 및 검증용 15%	훈련용 70%, 테스트 및 검증용 15%
학습률	0.001	0.0001
에포크 수	30	30
k겹 교차 검증	5	5
정규화(가중치 감소) L2 정규화(0.0001)		L2 정규화(0.0001)
최적화 방법	그리드 검색	그리드 검색
검증 성능	최적의 검증 성능을 바탕으로 최적의 하이퍼파라미터를 선택했습니다.	최적의 검증 성능을 바탕으로 최적의 하이퍼파라미터를 선택했습니다.

표 5. 3D CNN과 3D ResNet 모델의 훈련 및 검증 세부 정보 비교.

논의

이 섹션에서는 파킨슨병 진단을 위해 서로 다른 네 가지 방법론을 사용하여 얻은 결과를 중점적으로 다룹니다. 모델-1(3D CNN) 아키텍처를 설계 및 구축하고 여러 차례의 어블레이션 연구를 통해 개선했습니다. 이 네트워크는 자동 특징 추출이 가능하며, 93.5%의 정확도, 91.0%의 정밀도, 96.2%의 재현율, 그리고 92.5%의 전체 F1 점수를 통해 그 효과를 입증했습니다. 이전 연구15에서는 개선된 3D ResNet 아키텍처를 사용하여 파킨슨병 초기 단계 예측에 있어 유망한 결과를 보여주었습니다. 모델-2 접근 방식은 자동 특징 추출을 위해 개선된 ResNet을 사용한 후 분류를 수행하는 방식입니다.

일련번호	교차 검증 정확도 재현율	정밀도 F1 점수			
모델 3 (최적화 제외)					
1	5배	0.916	0.886	0.935	0.905
2	10배	0.924	0.882	0.928	0.918
3	15배	0.948	0.904	0.956	0.938
모델 4 (최적화 포함)					
1	5배	0.959	0.907	0.986	0.929
2	10배	0.962	0.893	0.988	0.934
3	15배	0.972	0.906	0.985	0.931

표 6. 모델 3과 모델 4의 성능 분석.

알고리즘	매개변수	값
PSO	인자적 요인(c1)	2
	사회적 요인(c2)	2
	관성 중량(w)	0.9
GSA	중력 상수(G0)	100
	상수(알파)	20
에게	교차율(CR)	0.8
	돌연변이율(MR)	0.01
	토너먼트 규모(Ts)	3
ACO	페로몬 값(타우)	1
	휴리스틱 바람작성(eta)	1
	제어 페로몬(알파)	1
	제어 휴리스틱(베타)	0.1
	페로몬 흔적 감쇠 계수(rho) 0.2	
와아	상수(b)	1
	한계점	0.5
검색 설정	인구 규모	100
	반복 횟수	200
	하한 및 상한	0과 1
	독립 실행 횟수	20

표 7. 모든 알고리즘의 매개변수 값.

다양한 머신러닝 알고리즘을 사용하여 모델을 개발했습니다. 이 모델은 90%의 정확도를 달성했습니다. 모델 2의 성능은 모델 1만큼 뛰어나지는 않지만, T2 강조 영상에서 파킨슨병을 식별하는 데 만족스러운 결과를 보여주며 여전히 효과적입니다.

모델 성능을 더욱 향상시키기 위해 3D-CNN과 3D-ResNet 모델의 특징을 결합하는 융합 기법을 적용했습니다. 이 접근 방식은 두 모델의 상호 보완적인 정보를 결합하여 성능을 향상시킵니다. 이 융합 기법은 모델 1 대비 정확도를 2% 향상시키는 결과를 가져왔습니다. 그러나 이러한 통합은 계산 복잡성 증가 및 과적합 문제를 야기할 수 있습니다. 이러한 문제를 완화하기 위해 본 연구에서는 특징 최적화 방법을 탐구했습니다.

제안된 모델-4는 생체 모방 WOA 최적화 기법을 사용하여 개발되었으며, 그 성능은 다른 네 가지 최적화 방법인 입자군 최적화(PSO), 중력 탐색 알고리즘(GSA), 유전 알고리즘(GA), 개미 군집 최적화(ACO)와 비교되었습니다. 이러한 방법들은 메타휴리스틱 최적화 문제를 해결하는 효율성을 기준으로 비교 대상으로 선정되었습니다. 각 알고리즘의 매개변수 값은 표 7에 제시되어 있습니다.

이러한 최적화 알고리즘의 성능은 정확도, 최적 적합도, 평균 적합도, 선택 크기 및 시간 등 여러 평가 기준에 따라 평가됩니다. 그림 5는 다양한 지표에 따른 알고리즘 성능 비교를 보여줍니다. 비교 결과 WOA가 다른 최적화 기법에 비해 더 높은 정확도를 나타내는 것을 분명히 알 수 있습니다. 성능에 영향을 미치는 다른 요소로는 계산 시간 복잡성, 선택된 최적화 특징의 크기 및 비용 함수의 값이 있습니다.

본 비교 분석을 바탕으로 WOA 알고리즘이 다른 메타휴리스틱 알고리즘보다 우수한 성능을 보인다는 결론을 내릴 수 있다.

그림 6은 PPMI 데이터셋에 대해 서로 다른 최적화 알고리즘을 사용하여 생성된 수렴 곡선을 보여줍니다. 이 곡선들은 모든 메타휴리스틱 최적화 알고리즘에 대해 200회 반복 동안 얻은 적합도 값을 나타냅니다. 비교 결과, WOA 알고리즘이 GA 및 PSO에 비해 가장 낮은 적합도 값을 달성하여 적합도 측면에서 상대적으로 더 나은 성능을 보임을 알 수 있습니다.




그림 5. 다양한 지표에 따른 알고리즘의 전반적인 성능 비교 (a) 정확도, (b) 평균 적합도, (c) 최고 적합도, (d) 선택 크기, (e) 시간.




그림 6. PPMI 데이터 세트에 대해 다양한 알고리즘을 사용하여 생성된 수렴 곡선.

WOA 방법을 사용한 제안된 모델-4는 모델-1에 비해 5%의 상당한 성능 향상을 보여줍니다. 이러한 최적화 단계를 통해 성능 지표가 크게 향상되어 정확도 97.2%, 정밀도 90.6%, 재현율 98.5%, F1 점수 92.1라는 인상적인 결과를 달성했습니다. 이러한 결과는 최적의 특징 선택 전략을 적용함으로써 성능이 크게 향상됨을 보여줍니다. 본 연구에서 사용된 다양한 모델 성능 지표의 비교는 그림 7에 나타나 있습니다.

표 8은 제안된 접근 방식과 기존 문헌의 최첨단 방법들을 비교한 결과를 보여줍니다. 비교는 정확도를 주요 지표로 사용하여 수행되었습니다. 각 연구에서 사용된 데이터셋은 세 번째 열에 설명되어 있으며, 본 연구에서 사용된 모델과 다른 최첨단 기법들은 네 번째 열에 자세히 설명되어 있습니다.




그림 7. 제안된 방법의 성능 지표 비교.

참고 자료	연도 데이터 세트		방법	정확성 (%)
32		2020 PPMI	양상불 방법	96.4
33		2024 Figshare 및 Brats 전차 융합	Shepard CNN 스택형 최소 오토인코더 +	94.0
34		2022 PPMI	DL 93.3	
35		2020 PPMI	ML	95.3
36		2021 PPMI	ML + DL	90.0
37		2023 PPMI	다국적 기법 네트워크	95.5
제안된 프레임워크				
3D-CNN	-	PPMI	3D-CNN	93.4
3D-ResNet	-	PPMI	3D-ResNet	97.2
최적화 없이 -		PPMI	ML(그래디언트 부스팅)	90.0
최적화를 통해	-	PPMI	ML(그래디언트 부스팅)	95.0

표 8. 제안된 접근 방식과 기존 연구 비교.

결론

본 논문에서는 서로 다른 두 개의 심경망 아키텍처에서 특징을 추출하고, CCA(Cellular Correlation Assessment)를 이용하여 이러한 특징 정보를 융합하는 새로운 방법을 제안합니다. 융합된 특징 중에서 생체 모방 최적화 전략, 특히 WOA(Whale Optimization Algorithm)를 사용하여 최적의 특징을 선택함으로써 97.2%의 향상된 분류 정확도를 달성했습니다. 여러 차례의 어블레이션 연구를 통해 개선된 ResNet과 특별히 설계된 3D-CNN 아키텍처라는 두 모델을 사용하여 전처리된 MR 영상에서 새로운 특징을 추출했습니다. ResNet과 제안된 3D-CNN 아키텍처를 사용했을 때의 분류 정확도는 각각 90%와 93.4%였습니다. CCA를 이용한 특징 융합과 WOA 기반 최적 특징 선택을 통해 정확도를 2% 향상시켰습니다. 최적 특징 선택 알고리즘은 WOA, PSO, GA, GSO, ACO를 포함한 메타휴리스틱 알고리즘들과 비교했습니다. 수렴 다이어그램을 기반으로 한 비교 연구 결과, WOA가 기존 문헌의 최첨단 방법들보다 우수한 결과를 나타냈습니다.

1.5T와 3T MRI 스캔 간에 모델 정확도에서 약 1~1.3%의 약간의 차이가 관찰되었습니다. 하지만 제안된 프레임워크는 높은 정확도와 일반화 능력을 유지하며 다양한 이미지 품질에 걸쳐 견고함을 입증했습니다.

제안된 프레임워크는 높은 정확도와 일반화 가능성을 비롯한 여러 장점을 제공하여 다양한 MRI 영상 품질에서 안정적인 성능을 보입니다. 그러나 효과적인 구현을 위해서는 데이터 개인정보 보호 및 기기 상호 운용성과 같은 과제를 해결해야 합니다. 현재 모델은 연구에 공개된 PPMI 데이터를 사용하여 학습 및 테스트되었으며, 실시간으로 구현하고 실시간 데이터로 지속적으로 업데이트하는 과정에서 모든 환자로부터 사전 동의를 받았습니다. 연구에는 선별된 MRI 특징만 사용될 것이라는 점을 명확히 설명하여 투명성과 개인정보 보호를 보장했습니다. 또한, 본 모델을 도입하려면 로컬 서버에 대한 투자가 필요할 수 있으며, 향후 연구에서는 클라우드 기반 솔루션을 활용하여 데이터 처리를 간소화하고 로컬 인프라의 필요성을 없애는 데 집중할 수 있습니다. 학습 과정에서는 데이터 입력 전에 전자 노이즈, 아티팩트 또는 환자 움직임으로 인해 손상된 스캔과 같은 실패한 스캔을 식별하고 제외하는 데 중점을 두어야 합니다. 본 프레임워크는 MRI 영상에서 추출한 필수 특징만 저장함으로써 환자의 개인정보 보호를 강화합니다.

WOA를 사용하면 원본 이미지나 원시 데이터를 저장하지 않아 무단 접근을 최소화하고 규정을 준수할 수 있습니다.

향후 연구에서는 최적화 알고리즘을 개선하고, 다목적 최적화를 구현하며, 모델의 해석 가능성을 향상시키는 데 중점을 둘 것입니다. 제안된 프레임워크는 알츠하이머병 및 헌팅턴병과 같은 다른 신경퇴행성 질환 진단에도 확장 적용될 수 있으며, 이러한 질환들은 본 연구에서 추출한 특징 외에도 아밀로이드 및 타우 영상과 같은 추가적인 특징들을 활용하여 정확한 진단이 가능합니다.

알츠하이머병 신경영상 연구(ADNI)와 같은 데이터셋을 통합하고 특정 영상 특징을 포함하도록 프레임워크를 조정함으로써 질병 특이적 민감도를 향상시킬 수 있습니다. 또한, 사물인터넷(IoT) 및 인공지능(AI) 기술의 통합을 통해 파킨슨병 관련 의료 애플리케이션을 개선하고자 합니다. 여기에는 지속적인 모니터링을 위한 웨어러블 센서 활용과 진단 및 맞춤형 치료를 개선하기 위한 데이터 분석에 AI 알고리즘을 적용하는 것이 포함됩니다.

데이터 가용성

본 연구에 사용된 훈련 및 테스트 데이터는 공개 액세스 데이터베이스인 파킨슨병 진행 표지자 이니셔티브(PPMI)에서 이용할 수 있습니다.

접수일: 2024년 5월 3일; 승인일: 2024년 9월 25일

Published online: 08 October 2024

참고 자료

- Parkinson, J. 떨림마비에 관한 에세이. Arch. Neurol. 20, 441–445. <https://doi.org/10.1001/archneur.1969.00480100117017> (1969).
- Amoroso, N., La Rocca, M., Monaco, A., Bellotti, R. & Tangaro, S. 복잡한 네트워크가 파킨슨병의 초기 MRI 지표를 밝혀낸다. J. Med. Image Anal. 48, 12–24. <https://doi.org/10.1016/j.media.2018.05.004> (2018).
- Ali, R. et al. 딥러닝을 이용한 파킨슨병 진단: 문헌정보 분석 및 문헌 검토. Ageing Res. Rev. 96, 102285. <https://doi.org/10.1016/j.arr.2024.102285> (2024).
- Ullah, F. et al. 수작업 합성 신경망을 이용한 MRI 이미지로부터의 뇌종양 분할. Diagnostics 13, 1–15. <https://doi.org/10.3390/diagnostics13162650> (2023).
- Chakraborty, S. et al. 정지 이미지에서 인간 행동 인식을 위한 미세 조정을 통한 전이 학습. Clin. Park. Relat. Disord. 80, 100094. <https://doi.org/10.1007/s11042-021-10753-y> (2021).
- Bakator, M. & Radosav, D. 딥러닝과 의료 진단: 문헌 고찰. Multimodal Technol. Interact. 2, 47. <https://doi.org/10.3390/mti2030047> (2018).
- Zhang, Z., Li, G., Xu, Y. & Tang, X. 인간 뇌 신경 및 정신 질환의 MRI 분류 작업에 인공지능을 적용한 사례: 범위 검토. Diagnostics 11, 56. <https://doi.org/10.3390/diagnostics11081402> (2021).
- Zheng, B. et al. 구조적 자기공명영상을 이용한 알츠하이머병 분류를 위한 수정된 3D EfficientNet. IET Image Proc. 17, 77–87. <https://doi.org/10.1049/ipr2.12618> (2023).
- Dai, Y., Gao, Y. & Liu, F. Transmed: Transformers는 다중 모드 의료 영상 분류를 발전시킵니다. Diagnostics 11, 1–15. <https://doi.org/10.3390/diagnostics11081384> (2021).
- Anwar, R., Abrar, M. & Ullah, F. 뇌종양 분류에서의 전이 학습: 도전 과제, 기회 및 미래 전망. Int. Conf. ICT 융합 24–29. <https://doi.org/10.1109/ICTC58733.2023.10392830> (2023).
- Fang, Z. 파킨슨병 진단을 위한 정보 엔트로피를 활용한 개선된 KNN 알고리즘. 2022년 국제 기계 학습 및 지식 공학 컨퍼런스(MLKE) 98–101. <https://doi.org/10.1109/MLKE55170.2022.00024> (2022).
- Kollias, D., A. Tagaris, A. Staphylopathy, S. Kollias & Tagaris, G. 의료 예측을 위한 심층 신경망 아키텍처. Complex Intell. Syst. 4, 119–131. <https://doi.org/10.1007/s40747-017-0064-6> (2018).
- Shinde, S. et al. 신경멜라닌 민감 MRI를 이용한 심층 신경망 기반 파킨슨병 예측 마커. NeuroImage Clin. 22, 101748. <https://doi.org/10.1016/j.nicl.2019.101748> (2019).
- Bhan, A., Kapoor, S. & Gulati, M. 이미지 향상, ROI 추출 및 딥러닝 알고리즘을 이용한 파킨슨병 초기 진단. 2021년 제2회 국제 지능형 공학 및 관리 컨퍼런스(ICIE) 521–525. <https://doi.org/10.1109/ICIE51511.2021.9445381> (2021).
- Yang, M., Huang, X., Huang, L. & Cai, G. 3D ResNet 기반 파킨슨병 진단: 전두엽이 중요하다. Biomed. 신호 처리. 제85, 104904. <https://doi.org/10.1016/j.bspc.2023.104904> (2023).
- Abdullah, S. 외. 최적화된 특징 선택을 이용한 심층 전이 학습 기반 파킨슨병 탐지. IEEE Access 11, 3511–3524. <https://doi.org/10.1109/ACCESS.2023.3233969> (2023).
- Camacho, M. 외. 대규모 다기관 데이터베이스로 학습된 딥러닝을 이용한 파킨슨병의 설명 가능한 분류 t1-가중 MRI 데이터 세트. NeuroImage Clin. 38, 103405. <https://doi.org/10.1016/j.nicl.2023.103405> (2023).
- Islam, NU, Khanam, R. & Kumar, A. 휴식 상태 fMRI 데이터로부터 파킨슨병 분류를 위한 3D CNN 사용. J. Eng. 응용과학 70, 1–13. <https://doi.org/10.1186/s44147-023-00236-2> (2023).
- Celik, M. & Inik, O. 뇌를 위한 딥러닝 및 최적화된 머신러닝 알고리즘 기반 하이브리드 모델 개발. 중앙 다중 분류. 전문가 시스템 응용 238, 122159. <https://doi.org/10.1016/j.eswa.2023.122159> (2024).
- 파킨슨병 진행 표지자 이니셔티브(Parkinson's Progression Markers Initiative). 파킨슨병 진행 표지자 이니셔티브(PPMI) 데이터베이스. 웹사이트(2010년 접속). 2020–2022년).
- Priyadharshini, S. et al. 설명 가능한 인공지능 기반 기계 학습 기술을 사용한 파킨슨병 진단을 위한 포괄적 프레임워크. Alex. Eng. J. 107, 568–582. <https://doi.org/10.1016/j.aej.2024.07.106> (2024).
- Ullah, F. et al. 뇌암 등급 및 분류를 위한 진화 모델. IEEE Access 11, 126182–126194. <https://doi.org/10.1109/ACCESS.2023.3330919> (2023).
- Marino, S. et al. 파킨슨병의 초기 진단을 위한 자기공명영상 표지자. 신경 재생 연구 7, 611–619. <https://doi.org/10.3969/j.issn.1673-5374.2012.08.009> (2012).
- Hamza, A. et al. 융합 지원 심층 베이지안 최적화 및 grad-cam 시각화를 기반으로 한 흉부 X선 이미지를 이용한 Covid-19 분류. Front. Public Heal. 10, 85. <https://doi.org/10.3389/fpubh.2022.1046296> (2022).
- Hamza, A. et al. D2bof-covidnet: 흉부 X선 및 MRI 스캔을 이용한 코로나19 분류를 위한 심층 베이지안 최적화 및 융합 지원 최적 심층 특징 프레임워크. Diagnostics 13, 101. <https://doi.org/10.3390/diagnostics13010101> (2022).
- Haghighat, M., Abdel-Mottaleb, M. & Alhalabi, W. 완전 자동 얼굴 정규화 및 단일 샘플 얼굴 인식 제약 없는 환경. 전문가 시스템 응용 47, 23–34. <https://doi.org/10.1016/j.eswa.2015.10.047> (2016).
- Mirjalili, S. & Lewis, A. 고래 최적화 알고리즘. Adv. Eng. Softw. 95, 51–67. <https://doi.org/10.1016/j.advengsoft.2016.01.008> (2016).

28. Li, X. et al. 앙상블 hwoa-lssvm을 활용한 6축 힘/토크 센서의 온도 보상 방법 개선된 트리밍 백킹. *Sensors* 22, 4809. <https://doi.org/10.3390/s22134809> (2022).
29. Ay, , Ekinci, E. & Garip, Z. 심장 관련 질환의 ml 기반 분류에 대한 특징 선택을 위한 메타휴리스틱 최적화 알고리즘의 비교 분석. *J. Supercomput.* 79, 11797–11826. <https://doi.org/10.1007/s11227-023-05132-3> (2023).
30. Emary, E., Zawbaa, H. & Hassanien, A. 특징 선택을 위한 이진 개미사자 접근법. *Neurocomputing* 213, 54–65. <https://doi.org/10.1016/j.neucom.2016.03.101> (2016).
31. Smith, S. 빠르고 견고한 자동 뇌 추출. *Hum. Brain Mapp.* 17, 143–155. <https://doi.org/10.1002/hbm.10062> (2002).
32. Wang, W., Lee, J., Harrou, F. & Sun, Y. 딥러닝 및 머신러닝을 이용한 파킨슨병의 조기 진단. *IEEE Access* 8, 147635–147646. <https://doi.org/10.1109/ACCESS.2020.3016062> (2020).
33. Balasubramanian, S., Mandala, J., Rao, T. & Misra, A. RF-ShCNN: 뇌종양 탐지를 위한 두 개의 딥러닝 모델 조합 MRI를 사용합니다. *Biomed. Signal Process. Control* 88, 105656. <https://doi.org/10.1016/j.bspc.2023.105656> (2024).
34. Pahuja, G. & Prasad, B. 다중 모달 특징을 이용한 파킨슨병 탐지를 위한 딥러닝 아키텍처. *Comput. Biol. Med.* 146, 105610. <https://doi.org/10.1016/j.combiomed.2022.105610> (2022).
35. Chakraborty, S., Aich, S. & Kim, H.-C. 인공 신경망을 이용한 파킨슨병 진단을 위한 3T MRI 스캔에서 관심 복셀의 3D 텍스처, 형태학적 및 통계적 분석. *Healthcare* 8, 34. <https://doi.org/10.3390/healthcare8010034> (2020).
36. Salmanpour, M., Shamsaei, M. & Rahmim, A. 파킨슨병의 하위 유형을 최적으로 식별하고 예측하기 위한 특징 선택 및 기계 학습 방법. *Comput. Methods Programs Biomed.* 206, 106131. <https://doi.org/10.1016/j.cmpb.2021.106131> (2021).
37. Huang, L., Ye, X., Yang, M., Pan, L. & Zheng, S. MNC-Net: 조기 파킨슨병 진단을 위한 노드 클러스터링 기반 다중 작업 그래프 구조 학습. *Comput. Biol. Med.* 152, 106308. <https://doi.org/10.1016/j.combiomed.2022.106308> (2023).

감사의 말씀

저자들은 본 연구 과제(CRG/2021/006697)에 대한 재정 지원을 제공해 주신 인도 정부 산하 과학기술부(DST) 과학기술연구위원회(SERB)에 감사드립니다. 또한, 본 연구의 성공적인 수행을 위해 필요한 자원과 지원을 제공해 주신 인도 SASTRA 대학교에도 감사드립니다. 본 연구는 인도 푸네 소재 Symbiosis International 대학교의 연구 지원 기금(RSF)의 지원을 받았습니다.

저자 기여

PS: 개념 정립, 방법론, 원고 작성. R. K: 개념 정립, 검토 및 편집. SV: 소프트웨어 개발, 검증, 형식 분석. NK: 데이터 정리, 조사. VS: 형식 분석, 자료 제공. MP: 자료 제공, 데이터 정리, 시각화. KK: 감독, 프로젝트 관리, 자금 확보.

선언

이해 상충

저자들은 이해 충돌이 없음을 선언합니다.

추가 정보

문의사항 및 자료 요청은 SV 또는 KK에게 보내주시기 바랍니다.

재인쇄 및 허가 정보는 www.nature.com/reprints 에서 확인할 수 있습니다 .

출판사 주: 스프링거 네이처는 출판된 지도 및 기관 소속과 관련된 관할권 주장에 대해 중립적인 입장을 유지합니다.

본 논문은 크리에이티브 커먼즈 저작자표시 4.0 국제 라이선스(Creative Commons Attribution 4.0 International License)에 따라 이용, 공유, 수정, 배포 및 복제가 허용됩니다. 단, 원저작자 및 출처를 명시하고, 크리에이티브 커먼즈 라이선스 링크를 제공하며, 변경 사항이 있는 경우 이를 표시해야 합니다. 본 논문에 포함된 이미지 및 기타 제3자 자료는 별도의 출처 표기가 없는 한 본 논문의 크리에이티브 커먼즈 라이선스에 포함됩니다. 자료가 본 논문의 크리에이티브 커먼즈 라이선스에 포함되지 않고, 귀하의 사용 목적이 법적 규정에 의해 허용되지 않거나 허용된 사용 범위를 초과하는 경우, 해당 저작권 소유자로부터 직접 허가를 받아야 합니다. 본 라이선스의 사본을 보려면 <http://creativecommons.org/licenses/by/4.0/> 을 방문하십시오.

© 저작권자(들) 2024